

AX Award 지원서

I. 개요															
지원부문	제조 AX 부문														
팀 / 그룹	제조기술센터 품질기술그룹	대표자	홍길동												
제목	완전한 품질 AI Agent Orchestration 구축 — 감지부터 판단·조치·자동조치까지 스스로 수행하는 살아있는 품질 관리 시스템														
적용시점	2026-09-01 ~ 2028-08-31 (24 개월) — 1 차년 구축·검증 / 2 차년 확산·자동화														
형전개 범위	1 차년 포토 1 개 공정 → 2 차년 etch·CMP 3 개 공정 → 품질·공정 엔지니어 약 1,000 명 · DRAM·NAND 전 제품군. 확산 표준안으로 타 조직 이관.														
II. Process															
문제 정의	1. 새벽 이상 1 건의 실제 동선 — 검출은 2 초, 그러나 원인을 아는 사람이 없었다 ▼ 6/28 PM 변경점 02:14 검출 03:10 단순 보정 trend 만 원위치 — 원인(PM 후 재보정 누락)은 남는다 이 판정 하나에 필요한 지식은 셋이다 — ① 이 item 의 trend 이력 ② 직전 변경점(PM·레시피·자재) ③ 같은 조합에서 과거에 났던 불량. 새벽·주말 취약시간에는 ②③을 아는 사람이 현장에 없다. 그래서 단순 파라미터 보정으로 trend 만 스펙 안으로 되돌리고 넘어간다. 숫자는 정상처럼 보이지만 원인은 그대로 남는다 — 같은 불량이 재발·확산된 뒤에야 주간에 드러난다. 이것이 매년 반복되는 사고의 전형이다. 02:14→08:30 무대응 공백 6h — 야간 알람은 "이상이다"에서 멈춘다 인수·파악 — 전달 손실 교차 조사 4h+ — SPC·YMS·MES·EngrNote 수십 화면 수동 대조 보고·결재 — 회의·품의 16 시가 되어야 lot 처리가 결정된다. 특별한 사고가 아니라 매일의 기본 동선이다. 단계 시간은 산정치 — 가동 후 처리 시간 로그로 실측 보정. 2. 동선 안에 반복되는 구조 결함 4 — 측정 가능한 문제로 적는다 조사 공수가 크다 — 판정 한 건에 SPC·MES·YMS·EngrNote 를 다 띄워놓고 손으로 대조한다. 반나절짜리 공수가 매일 반복된다 · 계속: 건당 처리 시간 판단이 상황 평준화되지 않는다 — 같은 trend 를 봐도 베테랑과 신임의 결론이 다르다. 기준이 시스템이 아니라 사람 머릿속에 있다 · 계속: 동일 현상 판정 일치율 취약시간에 사고가 난다 — 야간·주말엔 변경점·과거 사례를 아는 사람이 없어 trend 만 맞추는 임시 대응이 나온다 · 계속: 발생→조사 착수 시각차 기록 없이 각자 알아서 변경한다 — 근거가 문서로 안 남아 개인 판단으로 보정하고 지나간다. 당당이 바뀌면 같은 조사를 처음부터 · 계속: 담당 교체 후 재조사 건수 3. 기존 대안 검토 — 셋은 기각, 하나는 트리거로 편입 <table> <tr> <td>사내 LLM API</td> <td>기각</td> <td>질문을 넣으면 일반 지식으로 답할 뿐 — SPC·MES 조회, Map·SEM 판독, 변경점 대조를 할 손이 없다. 물어보는 사람의 지식만큼만 나온다</td> </tr> <tr> <td>사내 공용 RAG</td> <td>기각</td> <td>문서를 통째 백터로 넣는 구조 — 설비 ID·공정 약어가 임베딩에서 뭉개져 검색 정확도가 낮고, 반도체 사전·용어 병기·메타 필터 같은 손잡이가 없다</td> </tr> <tr> <td>BI·대시보드</td> <td>기각</td> <td>보는 화면만 늘어난다 — 대조·판단·조치는 여전히 사람 공수로 남는다</td> </tr> <tr> <td>규칙 기반 SPC 알람</td> <td>편입</td> <td>spec·rule 기반이라 정해진 임계만 잡는다 — 완전한 drift·복합 이상은 통과. 상시 감지는 Trend Agent 가 대신하고, SPC 알람은 무인 기동 트리거로만 쓴다</td> </tr> </table>			사내 LLM API	기각	질문을 넣으면 일반 지식으로 답할 뿐 — SPC·MES 조회, Map·SEM 판독, 변경점 대조를 할 손이 없다. 물어보는 사람의 지식만큼만 나온다	사내 공용 RAG	기각	문서를 통째 백터로 넣는 구조 — 설비 ID·공정 약어가 임베딩에서 뭉개져 검색 정확도가 낮고, 반도체 사전·용어 병기·메타 필터 같은 손잡이가 없다	BI·대시보드	기각	보는 화면만 늘어난다 — 대조·판단·조치는 여전히 사람 공수로 남는다	규칙 기반 SPC 알람	편입	spec·rule 기반이라 정해진 임계만 잡는다 — 완전한 drift·복합 이상은 통과. 상시 감지는 Trend Agent 가 대신하고, SPC 알람은 무인 기동 트리거로만 쓴다
	사내 LLM API	기각	질문을 넣으면 일반 지식으로 답할 뿐 — SPC·MES 조회, Map·SEM 판독, 변경점 대조를 할 손이 없다. 물어보는 사람의 지식만큼만 나온다												
	사내 공용 RAG	기각	문서를 통째 백터로 넣는 구조 — 설비 ID·공정 약어가 임베딩에서 뭉개져 검색 정확도가 낮고, 반도체 사전·용어 병기·메타 필터 같은 손잡이가 없다												
	BI·대시보드	기각	보는 화면만 늘어난다 — 대조·판단·조치는 여전히 사람 공수로 남는다												
	규칙 기반 SPC 알람	편입	spec·rule 기반이라 정해진 임계만 잡는다 — 완전한 drift·복합 이상은 통과. 상시 감지는 Trend Agent 가 대신하고, SPC 알람은 무인 기동 트리거로만 쓴다												
문제 정의 (계속)	4. 왜 중요한가 — 상시·대량 업무이고, 오판 비용이 비대칭으로 크다														
	4h / 근무 8h														

Process 재설계	근무의 절반이 판정 조사·대조에 쓰인다 [가정 — 로그로 실측 대체] × 약 1,000 명 만 명 규모 제조 조직의 품질·공정 엔지니어 전원의 매일 업무 오판 비용 — 진성 놓침: 불량 유출, 후공정·고객 클레임으로 증폭 / 가성 Hold: 엄청난 라인 정지, 수율·TAT 직접 손실. 양쪽 다 크니 판정은 낮고 보수적이 된다. 오탐이 잦으면 현업이 알람을 꺼 시스템이 사장된다 — 알람 신뢰를 관리 지표로 둔다. 5. 왜 지금인가 ① 데이터 자산 임계 도달 — 사고 이력 RDB·EngrNote·문서저장소·SPC/MES/YMS/EES/QMS 가 학습·검색 자산으로 쓸 양에 도달 ② 공개 모델 성숙 — 사내 반입 가능한 모델이 판단·판독 요구 수준에 도달 ③ 검증 체계 완비 — 회귀 러너·recall 실측까지 서 있다. 백지 출발이 아니다 지금 시작
	1. E2E 전체 대체 — 6 단계 업무가 무엇을 받아 무엇을 내는지까지 설계했다 인지 조사 판정 조치 결정 보고 이력 등록 사람 ≈ 14h Q-Agent 수 초 × 개인 기록 — 휘발 수 분 수십 분 반나절 수십 분 수 시간 adapter investigator judgment action answer 다섯 정거장이 통째로 내려온다 — 자율 tool calling, 합산 수 초 register 사람이 확정 확정 이력 — 다음 사건의 검색 근거로 환류 adapter 알람 JSON·질문 → 표준 사건 카드 investigator 도구 5~15 회 → 증거 묶음 judgment 검증 5 척 통과분만 판정서로 action 조치안+등급+파라미터 가드 answer 근거 3 종 인용 보고서 register 사람 승인·수정·반려 → 확정본이 코퍼스·재학습 라벨 2. 조치 권한 승격 구조 — 무엇을 실행하고, 누가 확정하고, 무엇을 넘어야 올라가나 1 차년 즉시 개방 — 통보성 (되돌릴 것 없음) L1 알람 이상 통보 — 야간에도 교대자에게 L2 소견 공유 유형·유사 사고 소견 첨부 L3 점검 권고 조치안 제시 — 실행은 현업 판단 확정 주체: 시스템 발신 · 사람은 수신·채택 → 채택·반려 이력 축적 사람 승인 후 실행 L4 lot Hold 승인 전 미실행 — 승인·반려가 기록 확정 주체: 담당 엔지니어 → 승인율·오탐율 기준 통과 2 차년 개별 심의 승격 L5 자동조치 되돌릴 수 있는 조치안 · 전건 사후 리뷰 설비 제어성 조치는 2 차년에도 승인 대상 3. 시작·중간·끝이 모두 바뀐다 — 끝이 다음 시작을 키운다 시작 — 사람이 아니다 Chat 질문 · 우인 감지 이벤트 → 중간 — 코어 하나 조사→판정→조치안 · 검증 통과분만

기술적 해결 방안	→
	끝 — 자산이 된다
	승인·등록 확정분이 코퍼스·라벨로
	4. 현업 활용·확산 — 코어는 그대로, 조사규칙과 색인만 늘린다
	● 확산 표준안 = 조사 코어 + 공정별 조사규칙 템플릿 + 골든셋 구축 절차. 2 차년 통과 조건 — 코어 변경 0 · 반례를 상습 없음. 공정이 3 개로 늘어도 추가 자원을 요청하지 않는다.
	● 현업 뒤 — 조사규칙 초안(3Q·공정 담당) · 조치 승인·반례(상시) · 골든셋 확정(분기). 노하우가 등록될수록 시스템이 그 팀에 맞게 자란다. 오탕 남발은 이벤트 그룹핑·수신자 피드백으로 조정(조회는 정보계 경유 전용 — 1Q 통과 조건).
	1 차년 · 구축·검증
	3Q 그림자 → Chat 파일럿 포토 공정 담당 엔지니어
	1 차년 · 구축·검증
	4Q 무인 접수 개시 야간·주말 누락 0 건 · 채택률 집계 2 차년 · 확산·자동화 5·6Q etch·CMP 확산 3 개 공정 — 코어 변경 0 2 차년 · 확산·자동화 8Q 약 1,000 명 전면 표준안으로 자원 증설 없이 이관

III. Tech	
기술적 해결 방안	품질 AI Agent Orchestration — 전체 동작 한 장 감지·질문에서 조치 실행·이력 등록·재학습까지, 한 코어로 닫힌다
	① 입구
	SPC 알람 무인 기동 · 24h
	Chat 질문 이미지 첨부 가능
	그룹핑·중복 제거 → 표준 사건 카드
	→
	② 조사 — Router 자율 루프 (5~15 회)
	Router LLM_{T=0} 도구 선택 → 인자 생성 → 반환 해석 → 가설 갱신 → 계속/종단 Trend 2-stage 감지·변화점 Image contrastive 유사도 Agentic RAG 원장 → meta → 문서 사내 DB 설비·MES 조회 전용
	▶ 반향이 증거 스택에 누적 — 원장 행 · 인용 원문 · 판독 라벨 · 변화점 · 설비 이력
	→
	③ 판정
	Q/A LLM_{T=0.3} 스택 전체로 판정서 작성 — 수치·인용은 반환값 복사
	검증기 5 척 — 탈락 시 재생성, 반복 실패는 판단 불가로 강등
	→
	④ 조치
	등급 L1~L5 규칙 결정 + 파라미터 가드 (변경 한도·횟수) L1~L3 즉시 발산 · L4 승인 후 실행 · L5 는 2 차년 승격분만
	→
	⑤ 사함 · 등록
	승인 · 수정 · 반례 현장 조치는 승인 후에만
	확정 이력 등록 EngrNote · 판정 이력
	↙ 원류 확정본이 검색 코퍼스 + 학습 라벨 로 — 검색기 파인튜닝 · SFT · DPO/KTO 월 4 회, 골든셋 회귀 통과분만 배포 할수록 정확해진다 ↗
	1. 왜 Agent Orchestration 인가 — 규칙·분류기·단일 LLM 이 각각 실패하는 지점 조사 순서를 미리 못 정한다 — 다음에 볼 데이터가 직전 결과에 따라 달라진다. 고정 파이프라인은 분기가 폭발한다. 이중 모달이 한 사안에 섞인다 — 시계열·이미지·문서·정형 DB, 각 모달은 전용 모델이 정확하고, 종합은 LLM 이 한다.

정답이 라벨이 아니라 근거 있는 설명이다 — 분류기는 Hold/Release 만 찍는다. 판정은 결론보다 근거가 감사 대상이다.
임계 기반으로는 안 걸린다 — 임계 아래로 완만히 흐르는 shift 는 규칙 알람이 못 잡는다. 변화점 검정이 필요하다.

2. 아키텍처 — Router 가 결과를 보고 다음 도구를 정하는 tool calling 루프

Chat 질문 "PHOD03 CD 왜 튀었나"

이상감지 이벤트 SPC 알람 JSON — 무인 기동

Router — 마스터 AgentLLM · GLM-5.2 + ReAct(LangGraph)
증상 분류 → 조사 계획 → tool calling 루프: 호출 → 반환값 보고 다음 도구 결정 (5~15 회) → 증거 종합. LLM 은 연결·추론만 — 수치 계산은 아래 전문 모델·코드가 한다. 매 턴 Router 가 하는 일: 도구 선택 → 호출 인자 생성 → 반환 JSON 해석 → 가설 갱신 → 계속/종단 판단. 더 부를 도구가 없다고 판정되면 멈추고 Q/A 역할로 넘긴다 — 도구를 고르는 역할(T=0)과 답을 쓰는 역할(T≈0.3)은 시스템 프롬프트로만 걸린다(엔진은 하나 — 앞부분 캐시 공유). 더 부를 도구가 없다고 판정되면 멈추고 Q/A 역할로 넘긴다 — 도구를 고르는 역할(T 0)과 답을 쓰는 역할(T 0.3)은 시스템 프롬프트로만 걸린다(엔진은 하나, 캐시 공유).

↓ get_spc_trend(lot·구간)
↓ classify_wafer_map(map)
↓ search_incidents → search_engr_notes
↓ get_interlock_history(설비)

Trend Agent 비 LLM 전문모델
1 단 양·불 감지 게이트 + 2 단 유형 분류·LLM 판독
만환 {t:02:14, Δ:+0.8nm, type:drift}
Image Agent 비 LLM 전문모델
ConvNeXt V2 분류 + PatchCore 이미 검출·유사 검색
만환 {pat:edge_ring, conf:0.92, 유사사고 top-5}
Agentic RAG · Eng'r Inform 검색기+LLM
meta 로 문서 선별 → 재작성 → 하이브리드(Emb+BM25) → 리랭크 → 재검색
만환 {사고번호, 원인·조치, 근거 문장}
사내 시스템 Tool 조회 전용
SPC·MES·YMS·EES·QMS 정보계 뷰 — 가드·타임아웃
만환 {PM 이력, 변경점, 레시피}

↑ 수차·라벨·사고번호·원문 인용만 Router 로 반환 — LLM 이 숫자를 만들 자리가 없다
↓ 도구 종료 판정 — Q/A 역할이 스택 전체를 받아 판정서 작성

검증기 5 칩 근거 실재·사실 대조 통과분만

→

조치 등급 + 파라미터 가드 변경 한도·횟수 제한

→

사람 승인 → 등록 확정분이 코퍼스·라벨로

등록 확정분 → 검색 코퍼스 증식 + 재학습 월 4 회(검색기 파인튜닝·선호학습, 골든셋 회귀 통과분만 배포) • 쓸수록 정확해진다

3. 무엇이 새로운가 — 이 설계의 기술적 신규성 셋

01

검증 게이트 오케스트레이션

채택 조건이 "그럴듯함"이 아니라 코드 관문 통과다. 탈락은 판단 불가로 강등 — 침묵 실패가 구조적으로 없다.

02

2 단 확정 검색

유사도는 후보 생성까지만 — 확정은 메타·경로 키의 RDB 조회. 벡터의 모호함이 인용·판정에 유입될 수 없다.

03

업무가 곧 라벨링인 페루프

승인·수정·반려가 그대로 학습 라벨 — 별도 라벨링 조직 없이 SFT·선호학습(DPO·KTO)·검색기 파인튜닝이 월 4 회 돈다.

4. 전문 모델의 밀단 — 이미지·Trend 두 갈래 모두 자체 개발로 이미 돌고 있다

이미지 · unknown-contrastive — 라벨 없이 배우는 대비학습

무라벨 SEM·Failbit 이미지 쌍으로 같은 것은 가깝게, 다른 것은 멀게(InfoNCE — Global·Local·Queue·위음성 필터 4 부품). ConvNeXt V2+TAPT, 384* → 128-d 좌표. 사고 대표는 클래스당 30 장 평균 anchor, 운영 확정은 composite map·멤버 이미지 육안 — 지표가 육안을 대체하지 않는다.

Global 6.20%
+Local 3.93
+Queue 1.31
+필터 0.52

부품 사다리 실측 — 오직재 6.20→0.52% · 군집 ARI 0.823→0.860 (43 class·900 wafer)

Trend · anomaly-detection — 라벨 한계를 생성 데이터로 돌파

실데이터에 라벨이 없는 불량 구간을 합성 주입(mean_shift·drift·spike·level_step 등)해 학습하고, 현업이 불량으로 오인하던 복귀형 파형은 정상 클래스에 추가 — "우측 끝이 깨끗한가"로만 갈리게 설계했다.

1 단양·불 전용 감지 모델 — 판정 범위를 좁혀야 감지 성능이 최대가 되므로, 여기서는 양불만 가른다

2 단 LLM 판독 — 변경점 이력은 프롬프트로, trend 원고는 JSON(장구간은 일 평균 다운샘플)으로 투입 → 변화 시점 특정 + 어떤 설비 작업과 연관인지까지 연결한다

운영 장치 — Grad-CAM 으로 모델이 본 구간을 시각 근거로 남기고, AUROC·임계 스윙(FN/FP 표)으로 게이트 기준을 잠그며, 현업 CSV 추가학습으로 라인별 적응한다.

기술적
해결
방안
(계속)

5. 실행 트레이스 두 갈래 — 데이터가 실제로 이렇게 흐른다 (호출 → 틀 내부 동작 → 반환값 ← 프롬프트 적재)

A · 불량 이미지(EDS-SEM) 진입 — 유사도 → 경로·meta → 문서
입력
eds_0731.png 첨부 — "이 불량 위치? 과거 유사 사고 있었나?"
스택 = [system · 도구 스키마 10 종 · 판정서 스키마]
1
Router "이미지가 있으니 유사도부터" → analyze_defect_image(img)
틀 내부 — contrastive 384²→128-d L2 → 사고 이미지 스토리지 갤러리 코사인 top-10 → 임계 0.82 컷
← {top1:edge_ring, sim:0.93, incident:PHOD01-2847, path:/rpt/2847.pptx}
스택 += 판독 라벨 · 이미지 경로 · meta 키
2
Router "경로·meta 나왔으니 그 키로 문서" → search_engr_notes(meta)
틀 내부 — ① meta 조회로 참조 문서 먼저 선별 ② 그 안에서만 tsvector || halfvec ③ RRF 융합 ④ 리랭크 top-20
스택 += 참조문서 3건 · 인용 원문 문장
3
Router "원인·대책 원본 필요" (필요시) → get_incident("PHOD01-2847")
← {규모:lot 3 · 피해:yield -1.2% · 원인·대책:잘못된 점}
스택 += 사고 현장 형 — 담당 엔지니어가 직접 쓴 확정 필드
4
병렬 Trend · 사내 DB · Eng'r Inform 동시 호출 (서로 독립이라 병렬)
스택 += Trend 반환 · 설비 이력 — 과거 원인이 이번 설비에서 재현됨을 교차 확인
종료
근거 3 종 확보 · 미결 질문 없음 → 도구 루프 종료, Q/A 역할로 인계
B · 사고 문의·알람 진입 — 원장 → meta 선별 → 문서
입력
SPC 알람 {param:CD, lot:L42, Δ:+0.8nm, t:02:14} 또는 "이 사고 어떻게 됐었나" 질문
1
Router "사고 건이므로 원장이 첫 조회 — 검색이 아니라 조회다" → search_incidents(drift, PHOD)
틀 내부 — 담당 엔지니어가 손으로 쓴 RDB: 사고명·규모·피해·원인·대책·조치·잘못된 점. 신뢰 최상이라 여기부터
← {2847: 원인 PM 후 재보정 누락 · 대책 offset -0.4 · yield -1.2%}
스택 += 사고 현장 형 (확정 사실)
2
Router 사고명·meta로 참조 문서 선별 → search_engr_notes(meta) — A의 2 단계와 동일 경로 (진입만 다르다)
스택 += 참조문서 · 인용 원문
3
Trend Agent 2-stage — 1 단 양·불 게이트, 2 단 LLM 이 변경점 이력 + 일평균 JSON 판독
← {변화점 02:14, drift 형, 6/28 PM 연관 의심}
스택 += 변화 시점·변화량·연관 작업
4
사내 DB Agent get_interlock_history(SCN-07) ← PM 06/28 후 재보정 기록 없음
스택 += 설비 이력 — 가설이 실제 이력과 맞들림
종료
근거 부족 시 최대 3 회 재검색, 그래도 모자라면 "확인 불가"를 스택에 적고 넘긴다

역할별 temperature — 같은 엔진, 다른 온도

Router LLM · T = 0

내는 것 — 도구 이력 + 인자 JSON (문장이 아니다)

온도를 조금만 줬도 72h 가 48h 로, lot 범위가 다른 값으로 흔들려 같은 사건에 다른 조사 경로가 나온다 — 감사에서 재현이 안 되면 판정이 무효다

top_p 1.0 · seed 고정 → 호출 시퀀스 재현

Q/A LLM · T ≈ 0.3

내는 것 — 스택을 읽고 쓴 문장 (판정서 서술)

argmax 만 이으면 표현이 굳어 원인이 달라도 서술이 안 갈린다. 0.3 은 서술만 풀어주는 쪽 — 수치·사고번호·인용문은 스택에서 복사하므로 온도가 값을 못 흔들다

top_p 0.9 · 새는 건 검증기 ⇄ 사실 대조가 잦다

최종 Q/A 호출에 실제로 들어가는 것 — 4 층 스택

① 고정층 — system: 조사규칙·판정서 스키마 (프릭스 캐시 적중)

② 사건층 — 질문 원문 또는 알람 JSON · 첨부 이미지 형들

③ 증거층 — 도구 반환 누락 5~15 회: 현장 형 · 참조문서 인용 · 판독 라벨 · Trend · 설비 이력

④ 출력 지시층 — 스택 밖 사실 금지 · 수치는 반환값 그대로 복사 · 근거 3 종 · 부족분은 "확인 불가"

↓ Q/A LLM T 0.3 → 판정서 → 검증기 5 회

답의 수준은 모델이 아니라 스택이 정한다 — 3 단계를 뚫면 "과거에 비슷한 게 있었다"에서 멈추고, 4 단계를 뚫면 "이번 설비가 그랬는지"를 못 쓴다.

6. 조치안 출력 — 무엇을 얼마나 바꿀지, 한도와 사이드 이펙트까지가 한 세트다

판정서 #Q-1042 · PHOD03 CD drift 신뢰도 High · 근거 3 종 · L3 권고

원인 — Scanner SCN-07 Focus 드리프트 (PM 06/28 후 재보정 누락 · 과거 PHOD01-2847 동일 패턴)

조치 — Focus offset -0.4 재보정 권고 || 가드: 1 회 변경 한도 |Δ|≤0.5 · PM 주기당 1 회 · 한도 초과 입력은 자동 반려

사이드 이펙트 — 과보정 시 center CD 역방향 shift 위험 → 모니터 lot 2 매 선행 확인 후 분류 적용

근거 인용 — ① Trend {02:14, +0.8nm} ② Map edge_ring 0.92 ③ PHOD01-2847 보고서 p.14 조치 문장

● 조치가 곧 명령이 아니다 — 파라미터 가드(변경량 상한·횟수 제한·되돌림 가능성)를 조치 등급표가 강제한다. "많이 바꾸는" 답은 구조적으로 못 나간다.

● 근거 사실이 실물에 달는다 — 유사도는 후보만, 확정은 메타·경로 키로 RDB 에서. 인용은 원문 문장 그대로.

7. Agent 를 하나씩 열어줄 때마다 답이 자란다 — 프롬프트에 무엇이 들어가 답이

어떻게 달라지나 (ablation · 같은 사례 실험)

LLM 단독 ctx: 알람 원문본

"02 시경부터 CD 가 오르는 것으로 보입니다. 계속 재확인을 권장합니다."

모호 — 시점·근거 없음

+ Trend Agent+{02:14, +0.8nm, drift}

"02:14 에 변화점, +0.8nm drift 형입니다. 순간 펄스 아니라 지속 이동 — 계속 오류가 아닙니다."

시점·변화량 확보

+ Image Agent+{edge_ring, 0.92}

"같은 시각 Map 이 edge ring 패턴(0.92) — 공간 분포까지 검증합니다. Focus 계열 이상이 의심됩니다."

불량 유형 특정

+ 유사사례 RAG+사고번호·원인·조치 문장

"PHOD01-2847 과 동일 패턴입니다. 당시 원인은 PM 후 Scanner Focus 재보정 누락이었습니다."

원인 후보 확보

+ 설비 이력 Tool+PM·인터락 기록

	"SCN-07 은 06/28 PM 이후 재보정 기록이 없습니다 — 가설이 설비 이력과 맞물립니다. 원인 확정." 교차 검증 완료 + 조치 생성 +조치 등급표·가드 한도 "Focus offset -0.4 재보정을 권고합니다. 한도 $\Delta \leq 0.5$·PM 주기당 1 회, 모니터 lot 2 매 선행 확인." 실행 가능 최종 프롬프트 스택 = system(조사규칙·판정서 스키마) + 사건 카드 + tool 반환 JSON 5~15 개 + 인용 원문 발췌 — 이 스택 전체가 판단서 생성의 입력이다. 답의 수준 차이는 모델이 아니라 스택에 쌓인 증거의 차이이다. 원장 2 사고 건이면 여기가 1 번 search_incidents · get_incident SQL 5 get_spc_trend · commonality_analysis · get_master_info · get_interlock_history · search_fab_data Vision 2 classify_wafer_map · analyze_defect_image RAG 1 search_engr_notes 도구는 조회 전용 — 통계·공통성 분석은 코드가 계산한다. 도구를 하나 빼면 답이 어느 단계로 후퇴하는지가 그대로 보인다.
--	---

- 4 -

기술적 해결 방안 (계속)	8. 그럴듯한 오답은 코드가 거른다 — 다섯 관문 판단서 초안 → 스키마 × 형식 위반 근거 실재 × 없는 증거 인용 사실 대조 × 원문에 없는 수치 신뢰도 × 근거 3 개 미만 공백 금지 × 부족분 미명시 → 채택 탈락 시 재생성, 반복 실패는 판단 불가로 강등해 사람에게 넘긴다. 침묵 실패가 없다 — 모르는 것은 모른다고 적는 것까지가 관문이다. 9. Agentic RAG 설계 — 사람이 정리한 사고 DB 가 항상 먼저고, 확정은 키 조회다 트랙 ① 텍스트 ① 사고 원장 RDB — 무조건 1 번 담당 엔지니어가 손으로 쓴 원장 — 규모·피해·원인·대책·잘못된 점까지, 신뢰 최상 → ② 사고 고유번호 이후 모든 검색의 필터 키 → ③ meta 조회로 문서 선별 → 범위 내 검색 사고명·번호·공정·설비·기간 meta 로 후보를 뽑힌 뒤, 그 안에서만 tsvector(BM25) halfvec(임베딩) → ④ RRF 융합 → cross-encoder 리랭크 top-20 → ⑤ 부족 시 재검색 질의 재작성 후 ③으로 루프 트랙 ② 이미지 ① 신규 불량 이미지 현장 SEM·Failbit 첨부 → ② contrastive 임베딩 128-d L2 좌표화 → ③ 갤러리 코사인 top-10 유사 사고 이미지 지정 → ④ 그 이미지의 경로·메타 키 사고번호·클래스 확보 ⑤ 경로·meta 로 RAG DB 조회 사고 DB 는 필요시 유사도는 후보만 — 확정은 언제나 키 조회. 합류점은 사고번호가 아니라 Router 에 쌓이는 증거 스택이다 — 최종 인용은 원문 문장 그대로. Router 에 tool 반환이 계속 쌓이고 — 필요시 Trend·Image·사내 DB·EngrNote agent 까지 — 더 무를 도구가 없을 때 Q/A LLM 이 답을 달는다. 이 파이프는 세 갈래로 배운다 — 승인·수정·반려가 그대로 라벨 (월 4 회 · 끝낸셋 회귀 통과분만 배포) 검색기 파인튜닝확정 판정·문서 쌍으로 임베딩·리랭커 튜닝 · 전: "ACI 급등" 질의에 일반 세정 문서가 상위 → 후: 세정 후 계속 문서가 top-1 — 현장 용어를 배운다 SFT 지시학습확정 판단서를 지시·응답 쌍으로 · 전: "CD 상승 원인은 다양할 수 있습니다" 서술 → 후: 원인·근거 3 종 인용·조치 코드의 판정서 스키마로만 답한다
-------------------------	---

	recall@10 0.500 골든 4 건/색인 50 건 · 회귀 러너 실측
	선행 프로토타입 군집 품질 AMI 0.956 · ARI 0.860 노이즈 0.52% · 43 class·900 wafer — RAG 전 요소·유사 검색·메타 키 조회 가동
	설계 설계 문서 31 종 시스템설계서·로드맵·Tool 카탈로그·조사규칙
	2Q 그림자 운영 조치 미실행 공정 담당 판정을 정답으로 일치율 기준선·4h 가정 실측
	→
	4Q 무인 접수 2주 연속 누락 0 건 처리 시간·누락·조치 승인을 분기 보고
	→
	2 차년 자동조치 개방 전건 감사 승인율·오탐율 기준 넘은 시나리오만 개별 심의 승격