

AX Award 지원서

I. 개요			
지원부문	【확인필요 - 사내 공고상 지원부문 기입】		
팀/그룹	【확인필요】	대표자	【확인필요】
제목	품질 이상감지 · 판단 AI Agent(Q-Agent) - 계측 Trend · Wafer Map · Defect Image 이상의 감지부터 판정 · 조치 · 재학습까지 품질 판정 E2E Process 전 구간 대체		
분류	적용시점	【확인필요 - 예: 2026 년 4 분기 가동 (H100 반입 일정 동기)】	
	항전개 범위	메모리사업부 제조기술센터 품질 · 공정 엔지니어 약 1,000 명 / FAB · EDS 전 공정 / DRAM · NAND 전 제품군. 1 차 계측 Trend 판정 → 2 차 FDC Interlock Release · EDS Bin Map 판정 · 설비 PM 초도 검증으로 도구 카탈로그 교체만으로 확산	
II. Process			
문제 정의	1. 현상 - 품질 이상 1 건의 판정이 여전히 '사람의 시스템 순회'로만 이뤄진다 계측 Trend 이상 · Wafer Map 패턴 · Defect Image 가 발생하면 엔지니어는 SPC · FDC 경보를 확인한 뒤, GPM 기준정보 / 설비 · 공정 변경점 이력 / Map · Image 뷰어 / 과거 유사 사례(informnote · 작업 Note)를 서로 다른 시스템에서 하나씩 조회 · 대조한다. 건당 4~6 개 시스템을 오가며, 무엇을 다음에 볼지와 최종 판정 품질이 담당자 개인의 경험에 좌우된다. 판정 근거는 대개 구두나 개인 메모로만 남는다. 2. 중요도 - 판정 지연과 오판이 곧 수율 · 납기 손실이다 - 대상 규모 : 제조기술센터 품질 · 공정 엔지니어 약 1,000 명, FAB · EDS 전 공정, DRAM · NAND 전 제품군에서 매일 발생하는 상시 · 대량 업무다. - 업무 부하 : 이상 분석 · 판정에 1 인당 일 4 시간, 총 근무 8 시간의 50%가 이 한 가지 업무에 묶인다. - 오판 비용 : 진성 불량을 놓치면 불량 유출 · 고객 클레임으로 이어지고, 가성 불량을 Hold 하면 불필요한 라인 정지와 Lot 대기가 발생한다. 판정 1 건이 수율 보호와 TAT 에 직접 연결된다. 3. 개선 필요성 - 현재 구조로는 세 가지가 '구조적으로' 해결되지 않는다 ① 감시 공백 : 이상은 야간 · 휴일을 가리지 않지만 수작업 분석은 근무 시간에 묶인다. 특히 임계값을 넘지 않고 완만하게 흐르는 shift 는 규칙 정보에 걸리지 않아 며칠 뒤에야 발견된다. ② 판정 노하우의 유실 : 베테랑의 판단 기준이 개인 경험에 머물러 인력 이동 시 조직에서 사라진다. 판정 근거가 구조화되어 남지 않아 감사 · 재발 분석 대응도 매년 처음부터 다시 한다. ③ 기존 수단의 한계 : 규칙 기반 SPC · FDC 정보는 '값이 넘었다'만 알려줄 뿐 원인을 설명하지 못한다. 사내 공용 LLM API · 공용 RAG 는 문서 질의응답 전용이라, DB 조회 · 이미지 판독 · 시계열 분석을 결합한 도구 호출형 분석과 사내 용어 · 판정 논리의 도메인 학습이 불가능하다. 4. 그래서 무엇을 바꿔야 하는가 - 화면 개선이 아니라 Process 대체 조회 화면 하나를 편하게 만드는 개선으로는 위 세 가지가 그대로 남는다. '감지 → 정보 수집 → 원인 분석 → 판단 → 조치 → 기록 · 활용'이라는 판정 업무 전 구간을, 사람이 시스템을 순회하던 방식에서 Agent 가 스스로 필요한 도구를 호출해 근거와 함께 답을 내고 그 결과가 다시 학습으로 돌아오는 방식으로 재설계해야 한다.		

	- 확산 대상 : 제조기술센터 품질 · 공정 엔지니어 약 1,000 명 (FAB · EDS 전 공정, DRAM · NAND 전 제품군)
--	--

III. Tech

기술적 해결 방안

1. 왜 AI Agent 여야 하는가 - 단순 로직 · 기존 자동화로 풀리지 않는 이유

- 조회 순서를 미리 못 정한다 : 무엇을 다음에 볼지가 사안마다 다르다(설비 이력을 먼저 볼지, 유사 사례를 먼저 볼지). 규칙으로 쓰면 분기 조합이 폭발하고, 새 공정 · 신제품이 들어올 때마다 규칙이 발산한다. '다음에 무엇을 조회할지'를 상황에 따라 스스로 정하는 것이 Agent 를 쓰는 유일한 이유다.
- 입력이 이종(異種) 모달이다 : 시계열 · 이미지 · 자연어 문서 · 정형 DB 를 한 사안에서 함께 봐야 한다. 하나의 규칙 언어나 단일 모델로 표현되지 않는다.
- 정답이 라벨이 아니라 '근거를 갖춘 설명'이다 : 분류 모델은 Hold/Release 를 찍을 수는 있어도 왜 그런지를 원문 인용과 함께 낼 수 없다. 품질 판정은 결론보다 근거가 감사 대상이다.
- 임계 기반 자동화의 한계 : 기존 SPC · FDC 룰은 값이 넘어야만 올린다. 임계 아래에서 완만히 흐르는 shift 는 잡지 못한다.

2. 알고리즘 선택 근거

과제	선택 알고리즘	선택 근거
판단 · 오케스트레이션	GLM-5.2 743B-A39B MoE (FP8)	도구 호출(tool call) 안정성과 장문 근거 종합 능력이 필요한 유일한 자리. MoE 라 활성화 파라미터 39B 만 연산해 743B 급 판단력을 추론 비용 없이 쓴다. 판단 · 코딩 · 도구 호출을 단일 서빙으로 묶고 시스템 프롬프트로만 역할을 분기해 prefix cache 를 공유한다.
Trend 이상탐지	PatchTST(~5M) + CUSUM / BOCPD	'언제부터, 얼마나' 라는 수치 특성은 LLM 이 잘 못하고 통계 · 시계열 모델이 잘한다. 층 1 에서 변화 시점 · 변화량을 수치로 찍고, 층 2 에서 LLM 이 원인을 설명하는 2 층 구조. 시계열 원본을 LLM 에 통째로 넣지 않아 토큰 · 오독을 동시에 줄인다. 채널별 경량 학습이라 확산 비용이 낮다.
불량 · Map 분류	ConvNeXt V2 Large/Base	라벨이 있는 기지(既知) 불량은 분류 모델이 가장 싸고 정확하다. 여기에 VLM 을 쓰는 것은 비용 낭비다.
미지 불량 검출	PatchCore + WRN-50-2	학습 라벨이 없는 신규 패턴이 실제 사고의 다수다. 정상 특징 메모리뱅크와의 거리로 처음 보는 불량을 잡는다 - 분류 모델로는 구조적으로 불가능한 영역.
문서 검색	Qwen3-Embedding-8B + Qwen3-Reranker-8B + BM25 하이브리드	판정 근거는 사내 informnote · 작업 Note 라는 자연어에 있고 약어 · 표기 흔들림이 심하다. 의미(벡터)와 정확 일치(BM25)를 함께 써야 놓치지 않는다. 리랭커는 cross-encoder 라 검색기 계열과 무관하게 결합된다.
이미지 판독	Qwen3.5-397B-A17B(정밀) / Qwen3.6-35B-A3B(상시)	정밀 판독은 무거운 모델이 필요하지만 상시 호출까지 무겁게 갈 이유는 없다. 학습 중에도 경량 모델이 상주해 이미지 기능이 무중단으로 유지된다.

3. 성능 지표 - 측정 체계와 게이트

- 고정 지표 4종 : ①검색 recall@10 ②골든 시나리오 판정 정답률 ③건당 도구 호출 수 · 처리 시간 ④근거 인용 정확도(인용 원문이 실제 판정을 뒷받침하는가).
- 회귀 게이트 : 모델 · 프롬프트 · 색인 중 무엇을 바꾸든 골든 시나리오 회귀 평가에서 recall@10 과 판정 정답률을 전후 비교해 통과한 버전만 배포한다. H100 20 장 중 1 장을 회귀 평가 전용으로 상시 배정했다.
- 현재 상태 : 골든 시나리오 4건 확보, 30 건으로 확장 중이며 평가 러너를 구축하는 단계다. 실측 수치는 【확인필요 - 가동 후 골든셋 실측으로 기입】. 지어낸 수치는 기재하지 않는다.

4. 알고리즘 개선을 위해 수행한 과정

- 검색 3층 분기 설계 : 한 원문에서 ①원문(LLM 반환용) ②병기 확장문 임베딩 ③형태소 색인어(tsvector)를 각각 독립으로 만든다. 한쪽 출력이 다른 쪽 입력이 되면 오염이 누적되므로 상호 참조를 금지했다.
- 사내 용어 사전 병기 : ACI → 'After Clean Inspection, 세정 후 계측' 식으로 표준키 · 변형 · 병기문을 관리한다. 실제 그 용어가 등장한 문서에만 적용해 IDF 붕괴를 막았고, 최대 수혜자는 BM25 다.
- 색인 정규화 함수 통일 : 설비 ID(PHO-D03 등)를 통짜로 보호한 뒤 Kiwi 형태소 분석 → 품사 필터 → 원형 복원 순으로 처리하고, 적재와 질의에 반드시 같은 함수를 쓰도록 강제했다. 원문을 보존하므로 사전 · 필터가 바뀌면 재색인 배치 한 번으로 전량 반영된다.
- 하이브리드 + 리랭커 : 벡터 + BM25 + 메타 조건으로 후보 약 200 건을 만든 뒤 Reranker-8B 로 상위 20 건을 고른다. 벡터 색인은 halfvec 채택으로 크기를 절반으로 줄였다.
- 캐시 사고 방지 : 판단 결과에는 semantic cache 를 금지했다(지난주의 답을 재사용하면 그 자체가 사고). 조회성 결과만 짧은 TTL 로 캐시한다.
- 학습 루프 : 엔지니어 피드백(채택/수정/기각)을 데이터셋으로 쌓아 월 4 회 SFT → DPO/GRPO 로 반영하고, 회귀 통과 시에만 배포한다. 모든 판정에 근거 · 신뢰도 · 모델 버전을 함께 기록해 재현성과 감사 대응을 확보했다.

IIII. 경영효과

예상 성과

※ 본 과제는 신규 구축 과제로, 아래는 산출 공식이 명시된 예상 성과다.

유형 효과 (정량)	무형 효과 (정성)
① 운영 인건비 절감 △200 억원/년 산출식 : [(개선 전 4h ÷ 8h) - (개선 후 2h ÷ 8h)] × 평균 연봉 80,000,000 원 × 1,000 명 = 20,000,000,000 원/년 근거 : 품질 · 공정 엔지니어 1,000 명의 이상 분석 · 판정 업무가 1 인당 일 4 시간. Agent 의 자동 감지 · 근거 수집 · 조치안 제시로 2 시간으로 단축. ② 투자 대비 효과 투자 : 347,794,165 원/년 (BIG VM 5 대 + NAS 100TB + OBJ 50TB, 사내 과금 단가) ROI : 200 억 ÷ 3.48 억 ≒ 약 57.5 배 / 투자 회수 기간 약 6.4 일 ③ 별도 산정 예정 오판 감소 효과(진성 불량 유출 방지 · 가성 불량의 불필요 Hold 저감)와 Lot 대기 감소에 따른 TAT 개선분은 위 금액에 포함하지 않았다. 가동 후 실측으로 별도 산정한다.	① 24 시간 감시 공백 제거 야간 · 휴일에 발생한 이상도 즉시 포착된다. 임계 아래에서 완만히 흐르는 shift 까지 변화 시점을 수치로 특정해 조기 대응 기회를 되찾는다. ② 판정 노하우의 조직 자산화 개인 경험에 머물던 판단 기준이 판정 이력과 피드백으로 축적되어 학습에 반영된다. 인력 이동과 무관하게 조직에 남는다. ③ 판정 일관성 확보 같은 현상에 담당자마다 다른 결론이 나오던 편차가 줄어든다. 신규 인력도 첫날부터 베테랑의 판정 논리를 참조한다. ④ 감사 · 재발 분석 대응력 모든 판정에 근거 원문 인용 · 신뢰도 · 사용 모델 버전이 함께 기록된다. 사후에 '왜 그렇게 판정했는가'를 재현할 수 있다. ⑤ 신제품 램프업 가속 판정 근거가 자산으로 남아 신제품 초기 판정 기준이 빠르게 안정화된다. ⑥ 확산 기반 확보 감지→수집→분석→판단→조치→학 습 골격이 고정되어 있어, 다른 품질 Process 는 도구 어댑터와 용어 사전만 교체하면 된다.

검증 · 확산 계획

- 파일럿 : 골든 시나리오 30 건 기반 회귀 평가 통과 후, 특정 공정 · 설비군을 대상으로 엔지니어 승인(HITL) 전제의 제한 운영을 먼저 수행한다.
- 현업 검증 : 판정 정답률과 건당 처리 시간을 실측하고, 인건비 환산 기준으로 분기별 검증 보고한다.
- 확산 : 검증 통과 후 제조기술센터 품질 · 공정 엔지니어 약 1,000 명 대상으로 확대하고, FDC Interlock Release · EDS Bin Map 판정 등 유사 Process 로 순차 확산한다.