

AX Award 지원서

I. 개요			
지원부문	제조 AX 부문		
팀/그룹	제조기술센터 품질기술그룹	대표자	홍길동
제목	반도체 품질 이상감지·판단 AI Agent Orchestration 구축 - 확인 → 판단 → 조치까지 스스로 수행하는 살아있는 품질 관리 시스템		
분류	적용시점	2026-09-01 ~ 2028-08-31 (24 개월) - 2 개년 단계 과제 : 1 차년 구축·검증 / 2 차년 확산·자동화	
	형진개 범위	1 차년 포토 1 개 공정 → 2 차년 etch·CMP 확산(3 개 공정) → 품질·공정 엔지니어 약 1,000 명 · FAB·EDS 전 공정 · DRAM·NAND 전 제품군. 2 차년 산출물 확산 표준안(코어 + 공정별 조사규칙 템플릿 + 골든셋 구축 절차)으로 타 조직 이관	
II. Process			
문제 정의	1. 현행 업무 - 불량 하나를 판단하는 데 네 가지가 반복된다 불량 하나를 판단하려면 SPC 트렌드·wafer map·결함 이미지·Inform Note 조치이력·MES·YMS 기준정보를 서로 다른 기간시스템에서 하나씩 열어 대조해야 한다.		
	시간	시스템 사이클 오가며 손으로 대조하는 데 판정 시간의 대부분이 쓰인다. 정작 판단 자체에 쓰는 시간은 그 일부다	
	편차	무엇을 봤고 무엇을 안 봤는지가 사람마다 달라, 같은 현상에 다른 결론이 나온다	
	공백	야간·주말은 대응이 다음 근무까지 밀린다. 그 사이 같은 원인의 불량이 계속 생산된다	
	휘발	판단 근거가 사람 머릿속에 남아 담당자가 바뀌면 처음부터 다시 푼다	
	2. 기존 대안으로는 해결되지 않는다		
	대안	왜 부족한가	
	사내 LLM API	사내 DB 조회·이미지 판독을 못 한다. 검색기 파인튜닝·에이전트 토큰 구조가 없어 우리 데이터로 정확해지는 경로가 없다	
	사내 공용 RAG	용어 병기(ACI → 세정 후 계측), 설비 ID 통째 보호(PHO-D03), 형태소 색인, 메타 필터, 리랭커 교체, recall 열람이 모두 불가하다	
	BI·대시보드	불 화면을 늘릴 뿐 판단을 대신하지 않는다	
규칙 기반 SPC 알람	이상이다까지만 말한다. 대체 대상이 아니라 트리거 입력으로 그대로 쓴다		
3. 현업 관점의 중요도 - 상시·대량 업무이고, 오판 비용이 크다 - 대상·부하 : 품질·공정 엔지니어 약 1,000 명이 1 인당 일 4 시간, 근무 8 시간의 50%를 이 업무에 쓴다. - 오판 비용 : 진성을 놓치면 유출·고객 클레임, 가성을 Hold 하면 라인 정지와 Lot 대기. 판정 1 건이 수율 보호와 TAT 에 직접 연결된다.			
4. 지금 시작해야 하는 이유 - 세 조건이 동시에 맞는 시점이다 판정 이력과 Inform Note 가 학습 자산으로 쓸 만한 양에 도달했고, 오픈 LLM 이 MoE·FP8 형태로 사내 온프레임 서빙이 가능한 수준까지 성숙했으며, 사내			

	GPU 수요등록 체계로 확보 경로가 열려 H100 20 장 등록을 완료했다.
--	--

3. 확산 계획 - 코어를 다시 만들지 않는다

- 확산 방법 : 공정을 늘릴 때 조사규칙 문서(md)와 시스템지도만 추가한다.
코어도 모델도 인프라도 늘지 않는다.
- 검증 장치 : 2 차년 5Q(etch) · 6Q(CMP) 확산의 통과 조건에 코어 변경 0 을
넣어 이 주장을 실증한다.
- 타 조직 이관 : 8Q 산출물인 확산 표준안(조사 코어 + 공정별 조사규칙
템플릿 + 골든셋 구축 절차)을 다른 조직이 받아 자기 공정에 적용할 수
있게 만드는 것이 2 차년의 명시적 목표다.

III. Tech

기술적 해결 방안

1. 왜 AI Agent 여야 하는가 - 단순 로직 · 기존 자동화로 풀리지 않는 이유
 - 조사 순서를 미리 정할 수 없다 : 무엇을 다음에 볼지가 사안마다 다르다. 규칙으로 쓰면 분기 조합이 폭발하고 새 공정 · 신제품이 들어올 때마다 발산한다. 결과를 보고 다음을 정하는 ReAct 루프가 필요한 이유다.
 - 입력이 이중 모달이다 : 시계열 · 이미지 · 자연어 문서 · 정형 DB 를 한 사안에서 함께 봐야 한다. 하나의 규칙 언어나 단일 모델로 표현되지 않는다.
 - 정답이 라벨이 아니라 근거를 갖춘 설명이다 : 분류 모델은 Hold/Release 를 찍을 수는 있어도 왜 그런지를 원문 인용과 함께 낼 수 없다. 품질 판정은 결론보다 근거가 감사 대상이다.
 - 임계 기반 자동화의 한계 : 기존 SPC · FDC 룰은 값이 넘어야 울린다. 임계 아래에서 완만히 흐르는 shift 는 잡지 못한다. 그래서 대체하지 않고 트리거 입력으로 그대로 쓴다.

2. 알고리즘 선택 근거

과제	선택	선택 근거
판단 · 도구 호출 (주 모델)	GLM-5.2 743B-A39B MoE (FP8)	도구 호출 안정성과 장문 근거 종합이 동시에 필요한 유일한 자리. MoE 라 활성 39B 만 연산해 743B 급 판단력을 추론 비용 없이 쓴다. 판단 · 코딩 · 도구 호출을 단일 서빙으로 묶고 역할은 시스템 프롬프트로만 분기해 프롬프트 캐시 적중률을 확보한다.
조사 제어	ReAct 루프 (LangGraph)	도구 호출 순서를 사전 정의하지 않고 결과를 보고 다음을 정하게 한다. 더 부를 도구가 없으면 조사를 종료한다 - 조사 깊이가 사안에 따라 자동으로 조절된다.
Trend 이상탐지	PatchTST + CUSUM / BOCPD	언제부터 얼마나 라는 수치 특징은 통계 · 시계열 모델이 잘하고 LLM 이 못한다. 변화 시점 · 변화량을 코드가 찍고 LLM 은 그 결과를 읽어 연결만 한다. 시계열 원본을 LLM 에 넣지 않는다.
불량 · Map 분류	ConvNeXt V2 Large / Base	라벨이 있는 기지 불량은 분류 모델이 가장 싸고 정확하다. 여기에 VLM 을 쓰는 것은 비용 낭비다.
미지 불량 탐지	PatchCore + WRN-50-2	라벨이 없는 신규 패턴이 실제 사고의 다수다. 정상 특징 메모리뱅크와의 거리로 처음 보는 불량을 잡는다 - 분류 모델로는 구조적으로 불가능한 영역.
문서 검색	Qwen3- Embedding-8B + Reranker-8B + BM25	판정 근거는 Inform Note 라는 자연어에 있고 약어 · 표기 흔들림이 심하다. 의미(벡터)와 정확 일치(BM25)를 함께 써야 놓치지 않는다. 리랭커는 cross-encoder 라 검색기 계열과 무관하게 결합된다.
이미지 판독	Qwen3.5-397B-A17B / Qwen3.6-35B-A3B	정밀 판독은 무거운 모델이 필요하지만 상시 호출까지 무겁게 갈 이유는 없다. 학습 중에도 경량 모델이 상주해 이미지 기능이 무중단으로 유지된다.

3. 틀린 판단이 조치로 이어지지 않게 - 두 겹으로 막는다

판단 - 검증기 5 칩 (LLM 이 아니라 코드가 검사한다)

스키마	정해진 형식이 아니면 거부
근거 실재	존재하지 않는 증거를 인용하면 거부
사실 대조	도구가 돌려준 원문에 없는 수치를 쓰면 거부
신뢰도 규칙	High 를 주장하려면 근거 3 개 이상, 반증 0
공백 금지	가설이 없으면 무엇이 부족한지를 명시하게 강제

조치 - 등급표 + 권한별 승인 (등급을 LLM 이 정하지 않는다. 조치는 감사 대상이고 감사는 설명 가능한 규칙을 요구한다)

등급	조치	1 차년	2 차년
L0	정보 제공 - 분석 답변 · 리포트	즉시	즉시
L1	알림 - 담당자 통보 · 교대 브리핑	즉시	즉시
L2	현장 영향 조치 제안 - Lot Hold, dose 보정	전건 승인 후 실행	전건 승인 후 실행
L3	자동 조치 - 되돌릴 수 있는 저위험만	개방하지 않음	화이트리스트 개별 승격

4. 성능 지표 - 측정 체계와 배포 게이트

- 실측치 : 검색 recall@10 = 0.500 (골든 4 건 / 색인 50 건). 회귀 러너로 측정했다. 판정 정답률은 1 차년 2Q 그림자 운영에서 기준선을 실측한 뒤 목표치를 확정한다 - 임의의 퍼센트를 지금 적지 않는다.
- 고정 지표 : 골든셋 판정 일치율 · 검색 recall@10 · MRR · precision@3 · 건당 처리 시간 · 이벤트 처리 누락 건수 · 조치 승인율 · 반려율.
- 배포 게이트 : 프롬프트 · 모델 · 임베딩 · 색인을 바꿀 때마다 골든셋 회귀 러너를 돌리고, 직전 측정값 대비 하락이 있으면 배포하지 않는다. 금지 조치를 건드리면 즉시 실패 처리한다. H100 20 장 중 1 장을 회귀 평가 전용으로 상시 배정했다.
- 차단 검증 : 검증기의 날조 · 왜곡 · 과장 3 종 재현 테스트를 변경 시마다 돌려 3 종 모두 차단을 확인한다.

5. 알고리즘 개선을 위해 수행한 과정

- 환각 발생원 제거 : 통계 계산 · 공통성 분석 · wafer map 분류 · SQL 조회를 전부 코드로 옮기고 LLM 에는 결과만 넘겼다. LLM 이 숫자를 만들어낼 자리가 구조적으로 없다.
- 검색 3 층 분기 : 한 원문에서 원문(LLM 반환용) · 병기 확장문 임베딩 · 형태소 색인어를 각각 독립으로 만든다. 한쪽 출력이 다른 쪽 입력이 되면 오염이 누적되므로 상호 참조를 금지했다.
- 사내 용어 사전 병기 : ACI → After Clean Inspection, 세정 후 계측 식으로 관리하되 실제 그 용어가 등장한 문서에만 적용해 IDF 붕괴를 막았다. 최대 손해자는 BM25 다.
- 색인 정규화 통일 : 설비 ID(PHO-D03)를 통짜로 보호한 뒤 Kiwi 형태소 → 품사 필터 → 원형 복원 순으로 처리하고, 적재와 질의에 반드시 같은 함수를 쓰도록 강제했다. 원문을 보존하므로 사전이 바뀌면 재색인 배치 한 번으로 전량 반영된다.
- 하이브리드 + 리랭커 : 벡터 + BM25 + 메타 필터로 후보 약 200 건을 만든 뒤 Reranker-8B 로 상위 20 건을 고른다. 벡터 색인은 실측 pgvector 0.8.1 에서 halfvec 을 채택해 크기를 절반으로 줄였다.
- 캐시 사고 방지 : 판단 결과에는 semantic cache 를 금지했다. 지난주의 답을 재사용하면 그 자체가 사고다. 조회성 결과만 짧은 TTL 로 캐시한다.

	- 학습 루프 : 엔지니어 피드백(채택/수정/기각)을 데이터셋으로 쌓아 월 4 회 SFT → DPO/GRPO 로 반영하고 회귀 통과분만 배포한다. 모든 관정에 근거 · 신뢰도 · 모델 버전을 기록해 재현성과 감사 대응을 확보했다. - 기간계 보호 : 운영계에 직접 붙지 않고 정보계(DW · ODS)를 경유하며, 조회 전용 계정 · 허용 뷰 · statement_timeout · 행 수 제한 · 사건당 캐시를 건다.
--	---

IIII. 경영효과

예상 성과

※ 2개년 단계 과제로, 아래는 산출식이 명시된 예상 성과다. 1차년(포토 1개 공정)은 실측 구간으로 두고 전면 산정에 넣지 않는다.

유형 효과 (정량)

[(개선 전 4h ÷ 8h) - (개선 후 2h ÷ 8h)] × 연봉 80,000,000 원 × 1,000 명 = 연 200 억 원

연간 기대효과	200 억 원 (3 개 공정 확산 완료 후 1,000 명 전면 적용 기준)
연간 투자	347,794,165 원 - BIG VM 5 대 + NAS 100TB + OBJ 50TB (사내 과금). GPU 는 수요등록 체계로 별도 배정
2개년 총투자	695,588,330 원. 2차년에 공정이 3 개로 늘어도 인프라 증설을 요청하지 않는다
연간 ROI	약 57.5 배 - 투자 회수 약 6.3 일
총투자 기준 회수	약 12.7 일 (완전 가동 1년 효과로 2개년 투자 회수)

민감도 - 목표를 절반만 달성해도 남는다

목표 판정 시간	절감 비율	연간 기대효과	연간 ROI
2.0 시간 (기준)	25.0%	200 억	57.5 배
2.5 시간	18.8%	150 억	43.1 배
3.0 시간	12.5%	100 억	28.8 배
3.5 시간	6.3%	50 억	14.4 배

하루 4 시간에서 3.5 시간, 즉 30 분만 줄어도 ROI 14 배다.

선행 추진 실적 - 백지에서 시작하지 않는다

설계 문서	시스템설계서 · 구축 로드맵 · Tool 카탈로그 · 그라운드링 설계 · 조사규칙 5 종 · 구현명세서 등 31 종
구현	LangGraph 조사 코어 스켈레톤 실행 확인, 검증기 5 칩 구현, prod 백엔드 4 종
평가	골든 시나리오 4 건 + 회귀 러너 구축 · 회귀 검출 동작 확인. 검색 recall@10 = 0.500 실측
DB	테스트 VM 에 PostgreSQL 16.14 + pgvector 0.8.1 구축, 스키마 · 가드 · 평가 동작 확인. halfvec 확정
인프라	GPU 수요등록 완료(H100 20 장), BIG VM 5 대 산출근거 제출, 스토리지 신청 포함

설계 · 스켈레톤 · 평가 체계 · DB 까지는 이미 서 있다. 이 과제는 그 위에 실데이터와 실도구를 연결해 두 공정 더 확산하는 단계이며, 될지 안 될지 모르는 구간은 이미 지나 있다.

무형 효과 (정성)

① 24 시간 공백 소멸	야간 · 주말에 발생한 이상도 무인 접수로 즉시 조사된다.
② 판단 편차 축소	같은 현상에 같은 조사 경로가 적용되어 담당자별 결론 차이가 줄어든다.
③ 감사 대응력	모든 판정에 근거 원문 인용 · 신뢰도 · 모델 버전이 남아 사후 재현이 가능하다.
④ 노하우 자산화	조사규칙 문서와 확정 Inform Note 로 남아 담당자 교체에 흔들리지 않는다.
⑤ 학습 곡선	신규 엔지니어가 선배의 판단 경로를 그대로 따라 볼 수

	단축	있다.
	⑥ 확산 기반	확산 표준안으로 타 조직이 코어 개발 없이 자기 공정에 적용할 수 있다.
검증 방법 - 산정치를 실측으로 대조한다 - 1 차년 2Q 그림자 운영(조치 미실행)에서 AI 판단 대 엔지니어 판단 일치율 기준선을 실측한다. - 가동 후 건당 처리 시간·골든 시나리오 정답률·이벤트 처리 누락·조치 승인율을 로그로 실측해 분기 단위로 보고하고, 산정치와 차이가 나면 그때 조정한다. - 2 차년 7Q 부터 자동 실행 로그를 전건 감사하고 오관율을 측정·공개한다.		