

AX Award 지원서

I. 개요			
지원부문	제조 AX 부문		
팀/그룹	제조기술센터 품질기술그룹	대표자	홍길동
제목	완전한 품질 AI Agent Orchestration 구축 - 감지부터 판단·조치·자동조치까지 스스로 수행하는 살아있는 품질 관리 시스템		
분류	적용시점	2026-09-01 ~ 2028-08-31 (24 개월) · 2 개년 단계 과제 - 1 차년 구축·검증 / 2 차년 확산·자동화	
	형전개 범위	1 차년 포토 1 개 공정 → 2 차년 etch·CMP 확산(3 개 공정) → 품질·공정 엔지니어 약 1,000 명 · FAB·EDS 전 공정 · DRAM·NAND 전 제품군. 확산 표준안(코어 + 공정별 조사규칙 템플릿 + 골든셋 구축 절차)으로 타 조직 이관	
II. Process			

Process
재설계

1. 대상 E2E Process - 코어는 하나, 입구는 둘	
입력은 두 갈래다. 엔지니어가 Chat 으로 묻거나, 이상감지 시스템이 스스로 찾아내 질문으로 바꾼다. 이후 진행은 같다. 아래는 "PHO-D03 CD 가 갑자기 올랐는데 원인이 뭐야" 한 건이 어떻게 흘러가는지 비교한 것이다.	
입구 ① Chat - 엔지니어가 묻는다	입구 ② 이상감지 - 시스템이 스스로 찾아 기동한다

▼ 조사 코어 (LangGraph) - 마스터 Agent 가 하위 Agent · 도구를 부린다

adapter 증상 분류	investigat or 하위 Agent · 도 구	judgment 검증기 5 칩	action 등급 · 승인	answer 근거 인용	register 현업 확정
------------------	--	------------------------	-------------------	-----------------	-------------------

※ 붉은 영역 = 엔지니어 수작업을 Agent 가 그대로 대체한 구간 / ⑤ 실행은 승인 뒤에만

단계	AS-IS - 엔지니어 수작업	TO-BE - Agent 가 수행
① 트렌드 확인	SPC 화면을 열어 lot · chamber 를 바꿔가며 trend 를 직접 본다 (수 분)	Trend Agent 가 07/26 02:14 부터 CD +0.8nm 변화점을 자동 검출한다 (수 초)
② 불량 Map 판독	이번 lot Failbit Map 을 열어 불량 분포를 눈으로 확인한다 (수십 분)	Image Agent 가 edge 국부 집중을 판독하고 Focus 편차형 소견을 붙인다 (수 초)
③ 과거 사례 대조	어디서 본 패턴인데 - 과거 사고 이미지와 Note 를 뒤져 하나씩 대조한다 (반나절)	이미지 유사도로 닮은 사고를 좁히고, 그 메타 키로 원인 · 조치 이력을 정확히 끌어온다 (수 초)
④ 설비 이력 조회	의심 시점 확인차 MES · SPC 에 접속해 PM · 변경점 이력을 조회한다 (수십 분)	사내 시스템 조회 도구가 PM 직후 Focus 재보정 누락을 찾아낸다 (수 초)
⑤ 결론 · 조 치	보고서를 쓰고 회의를 소집한 뒤 조치 품의 · 결재를 올린다 (수 시간)	근거 3 종을 인용한 판정 보고서와 조치안을 생성한다. 실행은 승인 뒤 기간시스템에 반영한다 (수 초)

2. 조치는 다섯 단계로 올라간다 - 마지막 단계가 자동조치다

단계	하는 일	1 차년	2 차년
① 알림 통보	CD 급등 발생 - 이상 알림만 전달	즉시	즉시
② 참고 공유	불량 유형(edge 집중) 소견을 함께 통보	즉시	즉시
③ 권고	노광계 우선 점검을 권고	즉시	즉시
④ Hold	해당 lot Hold 와 점검 요청	전건 승인 후 실행	전건 승인 후 실행
⑤ 직접 실행	기간시스템에 인터락 · 조치 코드 발행, 보고서 공유	열지 않음	화이트리스트 승격 후

모든 시나리오는 승인 대상으로 시작한다. 제안과 승인을 반복해 시나리오별 승인율과 오답율이 쌓이면 기준을 넘긴 것만 개별 심의로 자동조치에 올린다. 승격 뒤에도 실행 내역은 전건 사후 리뷰하고, 설비 제어성 조치는 2 차년에도 승인 대상으로 남긴다.

3. 단일 기능 개선이 아니다 - 시작 · 중간 · 끝을 모두 바꿨다

- 시작 : 사람이 경보를 보고 인지하던 트리거를 무인 접수로 바꿨다. 업무의 출발점이 사람이 아니다.
- 중간 : 시스템 순회라는 노동 자체가 사라졌다. 화면을 편하게 만든 게 아니라 화면 여는 일을 없앴다.
- 끝 : 판정이 근거 · 신뢰도 · 모델 버전이 붙은 이력으로 남고, 확정된 Inform Note 가 다음 사건의 검색 자산이 된다. 업무의 끝이 다음 업무의 성능이 된다.

4. 확산 계획 - 코어를 다시 만들지 않는다

- 확산 방법 : 공정을 늘릴 때 조사규칙 문서와 시스템지도만 추가한다. 코어도 모델도 늘지 않고, 공정이 3 개로 늘어도 추가 자원을 요청하지 않는다.
- 검증 장치 : 2 차년 etch · CMP 확산의 통과 조건에 코어 변경 0 을 넣어 이 주장을 실증한다.
- 타 조직 이관 : 확산 표준안(코어 + 공정별 조사규칙 템플릿 + 골든셋 구축 절차)을 다른 조직이 받아 자기 공정에 적용하게 만드는 것이 2 차년의 명시적 목표다.

III. Tech

기술적 해결 방안

1. 왜 AI Agent Orchestration 이어야 하는가

- 조사 순서를 미리 정할 수 없다 : 무엇을 다음에 볼지가 사안마다 다르다. 규칙으로 쓰면 분기 조합이 폭발하고 새 공정이 들어올 때마다 발산한다. 결과를 보고 다음을 정하는 구조라야 한다.
- 한 사안에 이중 모달이 섞인다 : 시계열 · 이미지 · 자연어 문서 · 정형 DB 를 함께 봐야 한다. 하나의 규칙 언어로도 단일 모델로도 표현되지 않는다. 그래서 전문 Agent 를 나누고 오케스트레이션한다.
- 정답이 라벨이 아니라 근거를 갖춘 설명이다 : 분류 모델은 Hold 나 Release 나를 찍을 수는 있어도 왜 그런지를 원문 인용과 함께 내지 못한다. 품질 판정은 결론보다 근거가 감사 대상이다.
- 임계 기반 자동화로는 안 걸린다 : 기존 룰은 값이 넘어야 울린다. 임계 아래에서 완만히 흐르는 shift 는 잡지 못한다. 그래서 대체하지 않고 트리거 입력으로 함께 쓴다.

2. 오케스트레이션 구성 - 마스터 Agent 가 전문 Agent 와 사내 시스템을 부린다

마스터 Agent supervisor	증상을 분류해 조사를 설계하고, 하위 Agent 와 도구를 스스로 골라 반복 호출한다. 증거를 모아 판단과 조치까지 한 흐름으로 끌고 가며, 더 부를 것이 없으면 조사를 끝낸다
Trend Agent	계측 · FDC 시계열을 상시 감시한다. 변화 시점과 변화량을 수치로 특정해 조사를 자동 기동하고 그 수치를 마스터에게 넘긴다
Image Agent	wafer map 공간 패턴을 분류하고 결함 이미지 유형을 판독한다. 이미지 저장소에서 임베딩 유사도로 닮은 과거 불량을 좁힌 뒤, 그 이미지에 붙은 메타데이터와 파일 경로를 키로 삼아 해당 사고의 원인 · 조치를 RDB 에서 정확히 끌어온다. 유사도로 좁히고 키로 확정한다
Agentic RAG	엔지니어 Inform 이력과 사내 지식 문서를 찾는다. 질의를 스스로 다시 쓰고 하이브리드 검색으로 후보를 모아 리랭커로 추리며, 근거가 부족하면 질의를 바꿔 다시 찾는다. 문서만 보지 않는다 - 과거 사고 리스트와 원인 · 조치가 정리된 RDB 메타데이터까지 함께 조회해 정형과 비정형을 한 근거팩으로 묶는다
사내 시스템 Tool Calling	SPC · MES · YMS · EES · QMS 를 조회 전용으로 호출한다. 트렌드 조회, 불량 lot 의 공통 설비 · 챔버 추출, 기준정보, 인터록 이력, 가드된 비정형 조회까지 다섯 갈래다

3. 도구 구성의 근거 - 하나씩 붙여 답이 어떻게 달라지는지 비교했다

도구를 왜 이렇게 나눴는지는 하나씩 붙여 보면 드러난다. 같은 질문에 대한 답이 도구가 추가될 때마다 어떻게 달라지는지 실제로 비교했다.

붙인 도구	같은 질문에 대한 답
기본 LLM	7/26 02 시부터 CD 가 급등했습니다
+ Trend Agent	7/26 02:14 부터 CD +0.8nm - 시점과 변화량이 수치로 특정됩니다
+ Image Agent	Map 상 edge 국부 집중 - Focus 편차형 불량이 의심됩니다
+ 유사사례 검색	과거 PHO-D01 사례와 같은 패턴이며, 당시 원인은 Scanner Focus 드리프트였습니다
+ 설비 이력 조회	7/26 Scanner PM 직후 Focus 재보정 누락을 확인 - 원인이 특정됩니다
+ 조치 생성	원인은 PM 후 재보정 누락입니다. 근거 3 종을 인용해 진행

	<table border="1" data-bbox="363 230 1382 266"><tr><td data-bbox="363 230 592 266"></td><td data-bbox="592 230 1382 266">금지 · 조치 코드 발행 · 보고서 공유까지 제안합니다</td></tr></table> 도구를 하나 빼면 답이 어느 단계로 후퇴하는지가 그대로 보인다. 이것이 도구 구성을 이렇게 정한 근거다.		금지 · 조치 코드 발행 · 보고서 공유까지 제안합니다
	금지 · 조치 코드 발행 · 보고서 공유까지 제안합니다		

기술적
해결 방안

4. 알고리즘 선택 근거

과제	선택	선택 근거
판단 · 오케스트레이션	GLM-5.2 743B-A39B MoE	도구 호출 안정성과 장문 근거 종합이 동시에 필요한 유일한 자리다. MoE 라 활성 파라미터만 연산해 대형 모델의 판단력을 추론 비용 증가 없이 쓴다. 역할은 시스템 프롬프트로만 갈라 하나의 서빙을 공유하고 프롬프트 캐시를 살린다.
조사 제어	ReAct 루프 (LangGraph)	호출 순서를 미리 정하지 않고 결과를 보고 다음을 정한다. 조사 깊이가 사안에 따라 저절로 조절된다.
Trend 이상탐지	PatchTST + CUSUM / BOCPD	언제부터 얼마나는 통계 · 시계열 모델이 잘하고 LLM 이 못한다. 변화점은 코드가 찍고 LLM 은 읽어서 연결만 한다. 시계열 원본을 LLM 에 넣지 않는다.
Map · 불량 분류	ConvNeXt V2	라벨이 있는 기지 불량은 분류 모델이 가장 싸고 정확하다. 여기에 VLM 을 쓰는 것은 낭비다.
미지 불량	PatchCore + WRN-50-2	라벨 없는 신규 패턴이 실제 사고의 다수다. 정상 특징과의 거리로 처음 보는 불량을 잡는다. 분류 모델로는 닿지 않는 영역이다.
문서 · 사례 검색	Qwen3-Embedding-8B + Reranker-8B + BM25	판정 근거는 Inform Note 라는 자연어에 있고 약어와 표기 혼란이 심하다. 의미와 정확 일치를 함께 써야 놓치지 않는다. 리랭커는 cross-encoder 라 검색기 계열을 가리지 않는다.
이미지 유사 검색	Qwen3-VL-Embedding	이미지끼리 닮은 정도는 텍스트로 옮기면 잃는다. 임베딩 유사도로 후보를 좁히고, 확정은 그 이미지의 메타 키로 RDB 를 조회해 정확히 맞춘다.

5. 그럴듯한 오답이 채택되지 않게 - 코드가 검사한다

품질 시스템에서 그럴듯한 오답은 무응답보다 위험하다. 판단서는 구조화 출력으로 근거 인용을 강제하고, 아래 다섯 가지를 LLM 이 아니라 코드가 검사한다. 실패하면 오류를 붙여 다시 만들고, 계속 실패하면 판단 불가로 강등해 사람에게 넘긴다.

스키마	정해진 형식이 아니면 거부
근거 실재	존재하지 않는 증거를 인용하면 거부
사실 대조	도구가 돌려준 원문에 없는 수치를 쓰면 거부
신뢰도 규칙	High 를 주장하려면 근거 3 개 이상, 반증 0
공백 금지	가설이 없으면 무엇이 부족한지를 명시하게 강제

6. 성능 지표와 배포 게이트

- 실측치 : 검색 recall@10 = 0.500 (골든 4 건 / 색인 50 건). 회귀 러너로 측정했다. 판정 정답률은 1 차년 그림자 운영에서 기준선을 실측한 뒤 목표치를 정한다. 임의의 퍼센트를 지금 적지 않는다.
- 고정 지표 : 골든셋 판정 일치율, 검색 recall@10 · MRR · precision@3, 건당 처리 시간, 이벤트 처리 누락 건수, 조치 승인율과 반려율.
- 배포 게이트 : 프롬프트 · 모델 · 임베딩 · 색인 중 무엇을 바꾸든 골든셋 회귀

러너를 돌린다. 직전 측정값 대비 하락이 있으면 배포하지 않고, 금지 조치를 건드리면 즉시 실패 처리한다.

7. 알고리즘 개선을 위해 수행한 과정

- 환각 발생원 제거 : 통계 계산 · 공통성 분석 · map 분류 · SQL 조회를 전부 코드로 옮기고 LLM 에는 결과만 넘겼다. 숫자를 지어낼 자리가 구조적으로 없다.
- 검색 3층 분기 : 한 원문에서 원문 · 병기 확장문 임베딩 · 형태소 색인어를 각각 독립으로 만든다. 한쪽 출력이 다른 쪽 입력이 되면 오염이 누적되므로 상호 참조를 막았다.
- 용어 사전 병기 : ACI 를 After Clean Inspection, 세정 후 계측으로 함께 적되 그 용어가 실제 나온 문서에만 적용했다. 전 문서에 도장을 찍으면 IDF 가 무너진다. 최대 손해자는 BM25 다.
- 색인 정규화 통일 : 설비 ID 를 통짜로 보호한 뒤 형태소 분석 · 품사 필터 · 원형 복원을 거치고, 적재와 질의에 같은 함수를 쓰도록 강제했다. 원문을 보존하므로 사전이 바뀌면 재색인 한 번으로 반영된다.
- 재검색과 리랭크 : RAG 가 한 번 찾고 끝내지 않는다. 근거가 부족하면 질의를 바꿔 다시 찾고, 후보 200 건을 리랭커로 20 건까지 좁힌다. 벡터 색인은 halfvec 으로 크기를 절반으로 줄였다.
- 캐시 사고 방지 : 판단 결과에는 semantic cache 를 금지했다. 지난주의 답을 재사용하면 그게 사고다.
- 학습 루프 : 엔지니어 피드백을 데이터셋으로 쌓아 월 4 회 반영하고 회귀를 통과한 것만 배포한다. 모든 판정에 근거 · 신뢰도 · 모델 버전을 남겨 재현성과 감사 대응을 확보했다.
- 기간계 보호 : 운영계에 직접 붙지 않고 정보계를 경유한다. 조회 전용 계정, 허용 뷰, 타임아웃, 행 수 제한, 사건당 캐시를 건다.

IIII. 경영효과

예상 성과 2개년 단계 과제로, 아래는 산출식이 명시된 예상 성과다. 1차년은 포토 1개 공정 파일럿이라 효과를 전면 산정에 넣지 않고 실측 구간으로 둔다.

유형 효과 (정량)

[(개선 전 4h ÷ 8h) - (개선 후 2h ÷ 8h)] × 연봉 80,000,000 원 × 1,000 명 = 연 200 억 원

연간 기대효과	200 억 원 - 3 개 공정 확산 완료 후 1,000 명 전면 적용 기준
연간 투자	347,794,165 원 (사내 과금 기준)
2개년 총투자	695,588,330 원. 공정이 3 개로 늘어도 추가 자원을 요청하지 않는다
연간 ROI	약 57.5 배 - 투자 회수 약 6.3 일
총투자 기준 회수	약 12.7 일 (완전 가동 1년 효과로 2개년 투자 회수)

민감도 - 목표를 절반만 달성해도 남는다

목표 판정 시간	절감 비율	연간 기대효과	연간 ROI
2.0 시간 (기준)	25.0%	200 억	57.5 배
2.5 시간	18.8%	150 억	43.1 배
3.0 시간	12.5%	100 억	28.8 배
3.5 시간	6.3%	50 억	14.4 배

하루 4 시간에서 3.5 시간, 30 분만 줄어도 ROI 14 배다.

무형 효과 (정성)

24 시간 공백 소멸	야간 · 주말에 생긴 이상도 무인 접수로 그 자리에서 조사된다
판단 편차 축소	같은 현상에 같은 조사 경로가 적용되어 담당자별 결론 차이가 줄어든다
감사 대응력	판정마다 근거 원문 · 신뢰도 · 모델 버전이 남아 사후에 재현할 수 있다
노하우 자산화	조사규칙과 확정 Inform Note 로 남아 담당자 교체에 흔들리지 않는다
학습 곡선 단축	신규 엔지니어가 선배의 판단 경로를 그대로 따라 볼 수 있다
확산 기반	확산 표준안으로 타 조직이 코어 개발 없이 자기 공정에 적용한다

선행 추진 실적 - 백지에서 시작하지 않는다

설계	시스템설계서 · 구축 로드맵 · Tool 카탈로그 · 그라운드링 설계 · 조사규칙 5 종 · 구현명세서 등 31 종
구현	LangGraph 조사 코어 스켈레톤 실행 확인, 검증기 5 칩 구현, prod 백엔드 4 종
평가	골든 시나리오 4 건과 회귀 러너 구축, 회귀 검출 동작 확인. 검색 recall@10 = 0.500 실측
검색 기반	스키마 · 조회 가드 · 평가 파이프라인 구축과 동작 확인, 벡터 색인 방식 확정

설계와 스켈레톤, 평가 체계까지는 이미 서 있다. 이 과제는 그 위에 실데이터와 실도구를 연결해 두 공정 더 확산하는 단계다. 될지 안 될지

모르는 구간은 지나 있다.

검증 방법

- 1 차년 그림자 운영에서 AI 판단과 엔지니어 판단의 일치율 기준선을 실측한다. 이 구간에는 조치를 실행하지 않는다.
- 가동 후 건당 처리 시간 · 골든 시나리오 정답률 · 이벤트 처리 누락 · 조치 승인율을 로그로 실측해 분기마다 보고하고, 산정치와 차이가 나면 그때 조정한다.
- 자동조치를 연 뒤에는 실행 로그를 전건 감사하고 오판율을 측정해 공개한다.