

AX Award 지원서

I. 개요

지원부문	제조 AX 부문		
팀/그룹	제조기술센터 품질·공정기술그룹	대표자	홍길동
제목	반도체 품질 이상감지·판단 AI Agent Orchestration 구축 - 확인 → 판단 → 조치까지 스스로 수행하는 살아있는 품질 관리 시스템		
분류	적용시점	2026-09-01 ~ 2028-08-31 (24 개월) · 2 개년 단계 과제 - 1 차년 구축·검증 / 2 차년 확산·자동화	
	형전개 범위	1 차년 포토 1 개 공정 → 2 차년 etch·CMP 확산(3 개 공정). 확산 완료 후 품질·공정 엔지니어 약 1,000 명 · DRAM·NAND 전 제품군 전면 적용. 확산 표준안으로 타 조직 이관	

II. Process

문제 정의

1. 현행 업무 - 불량 하나를 판단하는 데 네 가지가 반복된다

불량 하나를 판단하려면 SPC 트렌드·wafer map·결함 이미지·Inform Note 조치이력·MES·YMS 기준정보를 서로 다른 기간시스템에서 하나씩 열어 대조해야 한다.

시간	시스템을 오가며 손으로 대조하는 데 판정 시간의 대부분이 쓰인다. 판단 자체는 그 일부다
편차	무엇을 봤고 무엇을 안 봤는지가 사람마다 달라, 같은 현상에 다른 결론이 나온다
공백	야간·주말은 다음 근무까지 밀린다. 그 사이 같은 원인의 불량이 계속 나온다
취발	판단 근거가 사람 머릿속에 남는다. 담당자가 바뀌면 처음부터 다시 쏜다

2. 기존 대안으로는 해결되지 않는다

대안	왜 부족한가
사내 LLM API	사내 DB 조회도 이미지 판독도 못 한다. 우리 데이터로 정확해지는 경로가 없다
사내 공용 RAG	용어 병기(ACI→세정 후 계측), 설비 ID 통짜 보호(PHO-D03), 형태소 색인, 메타 필터, 리랭커 교체, recall 열람이 모두 막혀 있다
BI·대시보드	불 화면을 늘릴 뿐 판단을 대신하지 않는다. 화면이 늘수록 대조할 것이 늘어난다
규칙 기반 SPC 알람	이상이다까지만 말한다. 왜 그런가·무엇을 해야 하나에는 답하지 않는다. 대체 대상이 아니라 트리거 입력으로 그대로 쏜다

3. 현업 관점의 중요도 - 상시·대량 업무이고, 오펜 비용이 크다

- 대상·부하 : 품질·공정 엔지니어 약 1,000 명이 1 인당 일 4 시간, 근무 8 시간의 절반을 이 업무에 쓴다.
- 오펜 비용 : 진성을 놓치면 유출·클레임, 가성을 Hold 하면 라인 정지와 Lot 대기. 판정 1 건이 수율과 TAT 에 직접 연결된다.

4. 지금 시작해야 하는 이유

판정 이력과 Inform Note 가 학습 자산으로 쓸 만한 양에 도달했다. 오픈 LLM 도 사내 온프레임에서 돌릴 수준까지 왔고, 설계와 검증 체계는 이미 서 있다.

Process
재설계

1. 대상 E2E Process - 코어는 하나, 입구는 둘

입력은 두 갈래다. 엔지니어가 Chat 으로 묻거나, 이상감지가 스스로 질문으로 바꾼다. 아래는 예시 한 건이다 - PHO-D03 CD 급등.

입구 ① Chat - 엔지니어 질문

입구 ② 무인 감지 - 스스로 기동

▼ 조사 코어 (LangGraph) - 마스터 Agent 가 하위 Agent · 도구를 부른다

adapter
증상 분류

investigator
도구 호출

judgment
검증 5 척

action
등급 승인

answer
근거 인용

register
검색 자산

※ 붉은 칸 = 사람 일을 Agent 가 대체한 구간. register 확정분은 검색 자산이 된다.

단계

AS-IS - 엔지니어 수작업

TO-BE - Agent 가 대체

①트렌드

SPC 화면에서 lot · chamber 조회 (수 분)

Trend Agent 가 02:14 CD +0.8nm 변화점 검출 (수 초)

②Map

Failbit Map 분포를 눈으로 확인 (수십 분)

Image Agent 가 edge 국부 집중 · Focus 편차형 판독 (수 초)

③사례

과거 이미지 · Note 를 뒤쳐 눈으로 대조 (반나절)

이미지 유사도로 사고를 좁히고 메타 키로 원인 · 조치 인용 (수 초)

④이력

MES · SPC 에서 PM · 변경점 이력 조회 (수십 분)

PM 직후 Focus 재보정 누락을 조회 도구가 찾아냄 (수 초)

⑤조치

보고서 작성, 회의 소집, 품의 · 결재 (수 시간)

근거 3 종 인용 보고서 · 조치안 생성 (수 초). 실행은 승인 뒤

판정 업무의 시작부터 끝이다. 1 인 일 4 시간 → 2 시간이 산정 기준선이다.

2. 조치는 다섯 단계로 올라간다 - 마지막 단계가 자동조치다

단계

하는 일

1 차년

2 차년

① 알림

이상 알림만 통보

즉시

즉시

② 공유

불량 유형 소견을 함께 통보

즉시

즉시

③ 권고

노광계 우선 점검 권고

즉시

즉시

④ Hold

해당 lot Hold · 점검 요청

승인 후 실행

승인 후 실행

⑤ 자동조치

인터락 · 조치 코드 발행

열지 않음

승격 후 개방

승인 대상으로 시작한다. 기준을 넘긴 것만 승격하고 전건 사후 리뷰한다.

3. 단일 기능 개선이 아니다 - 시작 · 중간 · 끝을 모두 바꿨다

- 시작 : 인지하던 트리거를 무인 접수로 바꿨다. 출발점이 사람이 아니다.

- 중간 : 시스템 순회라는 노동이 사라졌다. 화면 여는 일 자체를 없앴다.

- 끝 : 근거 · 모델 버전이 붉은 이력이 남아 다음 사건의 검색 자산이 된다.

4. 현업 활용과 확산 - 코어를 다시 만들지 않는다

- 운영 : 그림자 운영 → Chat 파일럿 → 무인 접수 → 2 차년 3 개 공정 정상 운영.

- 파일럿 통과 조건 : 3Q 에 엔지니어 실사용 · 반려율 · 재사용률을 측정한다.

- 확산 일정 : 5Q etch · 6Q CMP · 8Q 확산 표준안 산출. 통과 조건은 코어 변경 0 이다.

- 확산 방법 : 공정마다 조사규칙 문서만 추가한다. 표준안은 타 조직이 받아 쓴다.

- 현업 몫 : 조사규칙 작성, 조치 승인 · 반려, Inform Note 확정, 골든셋 정답

	확정. 현업 노하우가 등록되어야 자라는 구조다.
--	-----------------------------------

III. Tech

기술적 해결 방안

1. 왜 AI Agent Orchestration 이어야 하는가

- 조사 순서를 미리 정할 수 없다 : 무엇을 다음에 볼지가 사안마다 다르다. 규칙으로 쓰면 분기가 폭발하고 새 공정마다 발산한다. 결과를 보고 다음을 정하는 구조라야 한다.
- 한 사안에 이중 모달이 섞인다 : 시계열 · 이미지 · 문서 · 정형 DB 를 함께 봐야 한다. 단일 모델로 안 된다. 그래서 전문 Agent 를 나누고 오케스트레이션한다.
- 정답이 라벨이 아니라 근거를 갖춘 설명이다 : 분류 모델은 Hold 나 Release 나를 찍을 뿐 왜 그런지를 원문 인용과 함께 내지 못한다. 품질 판정은 결론보다 근거가 감사 대상이다.
- 임계 기반으로 안 걸린다 : 룰은 값이 넘어야 울린다. 임계 아래로 완만히 흐르는 shift 는 못 잡는다.

2. 오케스트레이션 구성 - 마스터 Agent 가 전문 Agent 와 사내 시스템을 부린다

마스터 Agent	증상을 분류해 조사를 설계하고 하위 Agent · 도구를 스스로 골라 반복 호출한다. 더 부를 것이 없으면 조사를 끝낸다
Trend Agent	계측 · FDC 시계열을 상시 감시해 변화 시점과 변화량을 수치로 특정하고, 그 자리에서 조사를 자동 기동한다
Image Agent	wafer map 패턴 분류와 결함 이미지 판독. 이미지 저장소에서 임베딩 유사도로 닮은 과거 불량을 좁힌 뒤, 그 메타데이터 · 파일 경로를 키로 삼아 해당 사고의 원인 · 조치를 RDB 에서 정확히 끌어온다. 유사도로 좁히고 키로 확정한다
Agentic RAG	엔지니어 Inform 이력과 사내 지식 문서를 찾는다. 질의를 다시 쓰고 하이브리드 검색 · 리랭크로 추리며 부족하면 재검색한다. 문서만 보지 않고 사고 리스트 · 원인 · 조치 RDB 메타데이터까지 함께 조회해 한 근거팩으로 묶는다
사내 시스템 Tool Calling	SPC · MES · YMS · EES · QMS 를 조회 전용으로 호출한다. 트렌드, 불량 lot 의 공통 설비 · 챔버 추출, 기준정보, 인터록 이력, 가드된 비정형 조회

3. 도구 구성의 근거 - 하나씩 붙여 답이 어떻게 달라지는지 비교했다

도구를 왜 이렇게 나눴는지는 하나씩 붙여 보면 드러난다. 앞의 예시 질문 한 건에 대한 답을 비교했다.

붙인 도구	같은 질문에 대한 답
기본 LLM	7/26 02 시부터 CD 가 급등했습니다
+ Trend Agent	7/26 02:14 부터 CD +0.8nm - 시점과 변화량이 수치로 특정됩니다
+ Image Agent	Map 상 edge 국부 집중 - Focus 편차형 불량이 의심됩니다
+ 유사사례 검색	과거 PHO-D01 과 같은 패턴, 당시 원인은 Scanner Focus 드리프트였습니다
+ 설비 이력 조회	7/26 Scanner PM 직후 Focus 재보정 누락 확인 - 원인이 특정됩니다
+ 조치 생성	원인은 PM 후 재보정 누락. 근거 3 종을 인용해 진행 금지 · 조치 코드 · 보고서까지 제안

도구를 하나 빼면 답이 어느 단계로 후퇴하는지가 그대로 보인다. 이것이 도구 구성의 근거다.

기술적
해결 방안

4. 알고리즘 선택 근거

과제	선택	선택 근거
판단 · 조율	GLM-5.2 743B-A39B MoE	도구 호출 안정성과 장문 근거 종합이 함께 필요한 자리. MoE 라 활성 파라미터만 연산한다
조사 제어	ReAct 루프 (LangGraph)	호출 순서를 미리 정하지 않는다. 결과를 보고 다음 도구를 정한다
Trend 이상탐지	PatchTST + CUSUM/BOCPD	변화점은 코드가 찍고 LLM 은 연결만 한다. 언제부터 얼마나는 통계 모델이 잘한다
Map · 불량 분류	ConvNeXt V2	라벨 있는 기지 불량은 분류 모델이 가장 싸고 정확하다. VLM 을 쓰는 것은 낭비다
미지 불량	PatchCore + WRN-50-2	라벨 없는 신규 패턴이 사고의 다수다. 정상 특징과의 거리로 처음 보는 불량을 잡는다
문서 · 사례 검색	Qwen3 Embedding · Reranker + BM25	근거가 자연어에 있고 약어 · 표기 흔들림이 심하다. 의미와 정확 일치를 함께 써야 놓치지 않는다
이미지 유사 검색	Qwen3-VL-Embedding	답은 정도는 텍스트로 옮기면 읽는다. 유사도로 좁히고 메타 키로 확정한다

5. 그럴듯한 오답이 채택되지 않게 - 코드가 검사한다

품질 시스템에서 그럴듯한 오답은 무응답보다 위험하다. 판단서는 근거 인용을 강제하고 아래를 코드가 검사한다. 계속 실패하면 사람에게 넘긴다.

스키마	정해진 형식이 아니면 거부
근거 실재	존재하지 않는 증거를 인용하면 거부
사실 대조	도구가 돌려준 원문에 없는 수치를 쓰면 거부
신뢰도 규칙	High 를 주장하려면 근거 3 개 이상, 반증 0
공백 금지	가설이 없으면 무엇이 부족한지 명시하게 강제

6. 성능 지표와 배포 게이트

- 실측치 : 검색 **recall@10 = 0.500** (골든 4 건 / 색인 50 건). 질의 재작성 · 리랭커 적용 후 재측정해 상향한다.
- 판정 정답률 : 그림자 운영에서 기준선을 실측한 뒤 목표치를 확정한다. 임의의 퍼센트를 지금 적지 않는다.
- 고정 지표 · 배포 게이트 : 골든셋 일치율 · recall@10 · 건당 처리 시간 · 조치 반려율. 무엇을 바꾸든 회귀 러너를 돌리고 하락하면 배포하지 않는다.

7. 알고리즘 개선을 위해 수행한 과정

- 환각 발생원 제거 : 통계 · 공통성 분석 · map 분류 · SQL 을 코드로 옮기고 LLM 에는 결과만 넘겼다. 검증기 3 종 차단을 재현 테스트로 확인했다.
- 검색 3 층 분기 · 용어 병기 : 원문 · 확장문 임베딩 · 형태소 색인어를 독립으로 만들었다. 병기는 그 용어가 나온 문서에만 적용했다 - 전 문서에 도장을 찍으면 IDF 가 무너진다.
- 색인 · 재검색 : 설비 ID 를 통짜로 보호하고 적재와 질의에 같은 함수를 강제했다. 부족하면 질의를 바꿔 재검색하고 후보 200 건을 20 건까지 좁힌다.
- 학습 루프 : 피드백을 월 4 회 반영하고 회귀를 통과한 것만 배포한다. 판정마다 근거 · 신뢰도 · 모델 버전을 남긴다.
- 확인 : 개선마다 골든셋 회귀 러너로 전후를 비교한다. 러너가 실제 회귀를 검출하는 동작까지 확인했다.

IIII. 경영효과

예상 성과 2개년 단계 과제다. 아래는 산출식이 명시된 예상 성과이며, 1차년 포토 1개 공정 구간은 전면 산정에서 빼고 실측 구간으로 둔다.

유형 효과 (정량)

[4h/8h - 2h/8h] × 연봉 80,000,000 원 × 1,000 명 = 연 200 억 원

연간 기대효과	200 억 원 - 3 개 공정 확산 후 1,000 명 전면 적용 전제
연간 투자	347,794,165 원 (사내 과금) · 2 개년 총투자 695,588,330 원
연간 ROI	약 57.5 배 - 회수 약 6.3 일 / 총투자 기준 12.7 일
기준선 실측	1 인 일 4 시간 → 2 시간. 포토 공정에서 건당 처리 시간 로그로 실측 개시
확산 비용	공정이 3 개로 늘어도 추가 자원을 요청하지 않는다

민감도 - 목표를 절반만 달성해도 남는다

목표 판정 시간	절감 비율	연간 기대효과	연간 ROI
2.0 시간 (기준)	25.0%	200 억	57.5 배
2.5 시간	18.8%	150 억	43.1 배
3.0 시간	12.5%	100 억	28.8 배
3.5 시간	6.3%	50 억	14.4 배

하루 4 시간에서 3.5 시간, 30 분만 줄어도 ROI 14 배다.

무형 효과 (정성)

24 시간 공백 소멸	야간 · 주말에 생긴 이상도 그 자리에서 조사된다
판단 편차 축소	같은 현상에 같은 조사 경로가 적용된다
감사 대응력	판정마다 근거 원문 · 신뢰도 · 모델 버전이 남는다
노하우 자산화	조사규칙 · Inform Note 로 남아 사람에 묶이지 않는다
학습 곡선 단축	신규 엔지니어가 선행의 판단 경로를 그대로 따라 본다

선행 추진 실적 - 백지에서 시작하지 않는다

설계	시스템설계서 · 구축 로드맵 · Tool 카탈로그 · 그라운드 설계 · 조사규칙 5 종 등 31 종
구현	LangGraph 조사 코어 스켈레톤 실행 확인, 검증기 5 칩 구현, prod 백엔드 4 종
평가	골든 시나리오 4 건과 회귀 러너 구축, 회귀 검출 동작 확인. 검색 recall@10 = 0.500 실측. 스키마 · 조회 가드 · 평가 파이프라인 동작 확인

설계 · 스켈레톤 · 평가 체계까지는 서 있다. 이 과제는 그 위에 실데이터와 실도구를 연결해 두 공정 더 확산하는 단계다.

검증 방법

- 2Q 그림자 운영에서 판단 일치율 기준선을 실측한다. 조치는 실행하지 않는다.
- 가동 후 건당 처리 시간 · 이벤트 누락 · 조치 승인율을 로그로 실측해 분기마다 보고한다.
- 자동조치를 연 뒤에는 실행 로그를 전건 감사하고 오판율을 측정해 공개한다.