

AX Award 지원서

I. 개요

지원부문	제조 AX 부문		
팀/그룹	제조기술센터 품질기술그룹	대표자	홍길동
제목	완전한 품질 AI Agent Orchestration 구축 - 감지부터 판단·조치·자동조치까지 스스로 수행하는 살아있는 품질 관리 시스템		
분류	적용시점	2026-09-01 ~ 2028-08-31 (24 개월) · 2 개년 단계 과제 - 1 차년 구축·검증 / 2 차년 확산·자동화	
	형진개 범위	1 차년 포토 1 개 공정 → 2 차년 etch·CMP 확산(3 개 공정)에서 검증. 확산 완료 후 품질·공정 엔지니어 약 1,000 명 · DRAM·NAND 전 제품군 전면 적용. 확산 표준안으로 타 조직 이관	

II. Process

문제 정의

1. 현행 업무 - 불량 하나를 판단하는 데 네 가지가 반복된다

불량 판단에는 SPC·wafer map·결함 이미지·Inform Note·MES·YMS 를 서로 다른 시스템에서 하나씩 열어 대조해야 한다.

시간	시스템을 오가며 손으로 대조하는 데 판정 시간의 대부분이 쓰인다 - 화면 조회 수 분, Map 확인 수십 분, 사례 대조 반나절, 이력 조회 수십 분, 보고·결재 수 시간
편차	무엇을 봤고 무엇을 안 봤는지가 사람마다 달라, 같은 현상에 다른 결론이 나온다
공백	야간·주말은 다음 근무까지 밀린다. 그 사이 같은 원인의 불량이 계속 나온다
회발	판단 근거가 사람 머릿속에 남아 담당자가 바뀌면 처음부터 푼다

2. 기존 대안으로는 해결되지 않는다

대안	왜 부족한가
사내 LLM API	사내 DB 조회도 이미지 판독도 못 한다. 우리 데이터로 정확해지는 경로가 없다
사내 공용 RAG	용어 병기(ACI→세정 후 계측), 설비 ID 통짜 보호(PHO-D03), 형태소 색인, 메타 필터, recall 열람이 막혀 있다
BI·대시보드	볼 화면을 늘릴 뿐 판단을 대신하지 않는다
규칙 기반 SPC 알람	이상이다까지만 말한다. 왜 그런가·무엇을 해야 하나에는 답하지 않는다. 대체 대상이 아니라 트리거 입력으로 그대로 쓴다

3. 현업 관점의 중요도 - 상시·대량 업무이고, 오판 비용이 크다

- 대상·부하 : 품질·공정 엔지니어 약 1,000 명이 1 인당 일 4 시간, 근무 8 시간의 절반을 이 업무에 쓴다. 이 4 시간을 2 시간으로 줄이는 것이 경영효과 산정의 기준선이다. 4 시간은 현업 실무 기준이며 건당 처리 시간 로그로 실측해 보정한다.
- 오판 비용 : 진성을 놓치면 유출·클레임, 가성을 Hold 하면 라인 정지와 Lot 대기. 판정 1 건이 수율과 TAT 에 직접 연결된다.

4. 지금 시작해야 하는 이유

판정 이력과 Inform Note 가 학습 자산으로 쓸 만한 양에 도달했다. 오픈 LLM 도 사내 온프레임에서 돌릴 수준까지 왔고, 설계와 검증 체계는 이미 서 있다.

Process
재설계

1. 대상 E2E Process - 코어는 하나, 입구는 둘 (예시 : PHO-D03 CD 급등)

입구 ① Chat - 엔지니어 질문

입구 ② 무인 감지 - 스스로 기동

▼ 조사 코어 (LangGraph) - 마스터 Agent 가 하위 Agent · 도구를 부린다

adapter →
증상 분류

investigator →
도구 호출

judgment →
검증 5 척

action →
승인(사람)

answer →
근거 인용

register
확정(사람)

※ 붉은 칸이 아래 표의 업무 5 단계를 대신한다. 조치 승인과 등록 확정은 사람 몫이며, 확정분은 다음 사건의 검색 근거로 돌아간다 (← 선순환).

단계	AS-IS - 엔지니어 수작업	TO-BE - Agent 가 대체
①트렌드	SPC 화면에서 lot · chamber 조회 (수 분)	Trend Agent 가 02:14 CD +0.8nm 변화점 검출 (수 초)
②Map	Failbit Map 분포를 눈으로 확인 (수십 분)	Image Agent 가 edge 국부 집중 · Focus 편차형 판독 (수 초)
③사례	과거 이미지 · Note 를 뒤져 눈으로 대조 (반나절)	이미지 유사도로 사고를 좁히고 메타 키로 원인 · 조치 인용 (수 초)
④이력	MES · SPC 에서 PM · 변경점 이력 조회 (수십 분)	PM 직후 Focus 재보정 누락을 조회 도구가 찾아냄 (수 초)
⑤조치	보고서 작성, 회의 소집, 품의 · 결재 (수 시간)	근거 3 종 인용 보고서 · 조치안 생성 (수 초). 실행은 승인 뒤

2. 조치는 다섯 단계로 올라간다 - 마지막 단계가 자동조치다

단계	하는 일	1 차년	2 차년
① 알림	이상 알림만 통보	즉시	즉시
② 공유	불량 유형 소견을 함께 통보	즉시	즉시
③ 권고	노광계 우선 점검 권고	즉시	즉시
④ Hold	해당 lot Hold · 점검 요청	승인 후 실행	승인 후 실행
⑤ 자동조치	되돌릴 수 있는 저위험 조치	열지 않음	승격 후 개방

설비 제어성 조치는 2 차년에도 사람 승인 대상이다.

3. 단일 기능 개선이 아니다 - 시작 · 중간 · 끝을 모두 바꿨다

- 시작 : 인지하던 트리거를 무인 접수로 바꿨다. 출발점이 사람이 아니다.

- 중간 : 시스템 순회라는 노동이 사라졌다. 화면 여는 일 자체를 없앴다.

- 끝 : 근거 · 모델 버전이 붙은 이력이 남아 다음 사건의 검색 자산이 된다.

4. 현업 활용과 확산 - 현업 노하우가 등록되어야 자라는 구조다

- 운영 : 그림자 운영 → Chat 파일럿 → 무인 접수 → 3 개 공정 정상 운영.

- 현업 접점 : 입구는 Chat, 알림 · 승인은 사내 메신저 · 메일로 받는다.

- 파일럿 : 3Q 에 포토 공정 엔지니어가 Chat 으로 직접 쓴다.
실사용 · 반려율 · 재사용률을 측정한다.

- 확산 : 5Q etch · 6Q CMP · 8Q 확산 표준안 = 조사 코어 + 공정별
조사규칙 템플릿 + 골든셋 구축 절차. 통과 조건은 코어 변경 0. 공정이
늘어도 추가 자원을 요청하지 않는다.

- 왜 이 순서인가 : 신뢰부터 → 위험도 순 권한 → 등록은 처음부터.

- 현업 몫 : 조사규칙 작성, 조치 승인 · 반려, Inform Note · 골든셋 확정.

III. Tech

기술적 해결 방안

1. 왜 AI Agent Orchestration 이어야 하는가

- 조사 순서를 미리 정할 수 없다 : 무엇을 다음에 볼지가 사안마다 다르다. 규칙으로 쓰면 분기가 폭발하고 새 공정마다 발산한다. 결과를 보고 다음을 정하는 구조라야 한다.
- 한 사안에 이중 모달이 섞인다 : 시계열 · 이미지 · 문서 · 정형 DB 를 함께 봐야 한다. 단일 ReAct 한 덩어리로 두면 도구 선택이 서로를 방해한다. supervisor 가 전문 Agent 를 나눠 부린다.
- 정답이 라벨이 아니라 근거를 갖춘 설명이다 : 분류 모델은 Hold 나 Release 나를 찍을 뿐 왜 그런지를 원문 인용과 함께 내지 못한다. 품질 판정은 결론보다 근거가 감사 대상이다.
- 임계 기반으로 안 걸린다 : 룰은 값이 넘어야 울린다. 임계 아래로 완만히 흐르는 shift 는 못 잡는다.

2. 오케스트레이션 구성 - 마스터 Agent 가 전문 Agent 와 사내 시스템을 부린다

마스터 Agent	증상을 분류해 조사를 설계하고 하위 Agent · 도구를 스스로 골라 반복 호출한다. 더 부를 것이 없으면 조사를 끝낸다
Trend Agent	계측 · FDC 시계열을 상시 감시해 변화 시점과 변화량을 수치로 특정하고, 그 자리에서 조사를 자동 기동한다
Image Agent	유사도로 좁히고 키로 확정한다. wafer map 패턴 분류와 결합 이미지 판독. 이미지 저장소에서 임베딩 유사도로 닮은 과거 불량을 좁힌 뒤, 그 메타데이터 · 파일 경로를 키로 삼아 해당 사고의 원인 · 조치를 RDB 에서 끌어온다
Agentic RAG	정형 RDB 와 비정형 문서를 한 근거팩으로 묶는다. 엔지니어 Inform 이력과 사내 지식 문서를 찾는다. 질의를 다시 쓰고 하이브리드 검색 · 리랭크로 추리며 부족하면 재검색한다. 사고 리스트 · 원인 · 조치 RDB 메타데이터까지 함께 조회한다
사내 시스템 Tool	SPC · MES · YMS · EES · QMS 를 조회 전용으로 호출한다. 트렌드, 불량 lot 의 공통 설비 · 챔버 추출, 기준정보, 인터록 이력, 가드된 비정형 조회

※ 계획이 아니다 - 질의 재작성, 하이브리드 검색, cross-encoder 리랭커, 재검색 루프, 인용 강제, 이미지 유사 검색이 선행 프로토타입에서 돈다. 검색기는 본 과제에서 Qwen3 계열로 교체한다.

3. 도구 구성의 근거 - 하나씩 붙여 답이 어떻게 달라지는지 비교했다

앞의 예시(PHO-D03 CD 급등) 한 건에 대한 답을 도구별로 비교했다.

붙인 도구	같은 질문에 대한 답
기본 LLM	7/26 02시부터 CD 가 급등했습니다
+ Trend Agent	7/26 02:14 CD +0.8nm - 시점 · 변화량이 잡힙니다
+ Image Agent	Map 상 edge 국부 집중 - Focus 편차형이 의심됩니다
+ 유사사례 검색	PHO-D01 과 같은 패턴, 원인은 Scanner Focus 드리프트
+ 설비 이력 조회	7/26 Scanner PM 직후 Focus 재보정 누락 - 원인 확정
+ 조치 생성	원인은 PM 후 재보정 누락. 근거 3 종을 인용해 진행 금지 · 조치 코드 · 보고서까지 제안

도구를 하나 빼면 답이 어느 단계로 후퇴하는지가 그대로 보인다.

기술적
해결 방안

4. 알고리즘 선택 근거		
과제	선택	선택 근거
판단 · 조율	GLM-5.2 743B-A39B	도구 호출 안정성과 장문 근거 종합이 함께 필요하다. 둘을 한 모델에 묶는다
조사 제어	ReAct 루프 (LangGraph)	순서를 미리 정하지 않는다. 결과를 보고 다음을 정하고 재검색엔 상한을 둔다
Trend 이상탐지	PatchTST + CUSUM/BOCPD	LSTM · Prophet 은 변화 시점을 못 찍는다. 변화점은 코드가 찍는다
Map · 불량 분류	ConvNeXt V2	기지 불량은 라벨이 있다. 분류 모델이 가장 싸고 정확하다. VLM 은 낭비다
미지 불량	PatchCore + WRN-50-2	라벨이 없는 새 불량은 분류 모델이 못 잡는다. 정상 특징과의 거리로 잡는다
이미지 판독	Qwen3.5-397B-A17B / Qwen3.6-35B-A3B	정밀 판독은 대형, 상시 감시는 경량. 분류가 못 읽는 새 유형만 VLM 이 본다
문서 · 사례 검색	Qwen3 Embedding · Reranker	임베딩만으로는 설비 ID 정확 일치를 놓친다. BM25 를 함께 쓰고, 결합 가중치는 실측으로 정했다. 리랭커는 기본 적용
이미지 유사 검색	Qwen3-VL-Embedding	답은 정도는 텍스트로 옮기면 읽는다. 유사도로 좁히고 메타 키로 확정한다

5. 그럴듯한 오답이 채택되지 않게 - 코드가 검사한다

스키마	정해진 형식이 아니면 거부
근거 실재	존재하지 않는 증거를 인용하면 거부
사실 대조	도구가 돌려준 원문에 없는 수치를 쓰면 거부
신뢰도 규칙	High 를 주장하려면 근거 3 개 이상, 반증 0
공백 금지	가설이 없으면 무엇이 부족한지 명시하게 강제

6. 성능 지표와 배포 게이트

- 실측치 : 검색 **recall@10 = 0.500** (골든 4 건 / 색인 50 건)
- 질의 재작성 · 리랭커를 적용한 뒤 재측정해 상향한다.
- 0 건으로 관리한다 : 근거 없는 판단 채택, 미승인 L2 조치 실행, 무인 접수 이벤트 누락. 검증기 차단 로그와 감사 로그로 센다.
- 판정 정답률 : 그림자 운영에서 기준선을 실측한 뒤 목표치를 확정한다. 임의의 퍼센트를 지금 적지 않는다.
- 고정 지표 · 배포 게이트 : 골든셋 일치율 · recall@10 · 건당 처리 시간 · 조치 반려율. 무엇을 바꾸든 회귀 러너를 돌리고 하락하면 배포하지 않는다.

7. 알고리즘 개선을 위해 수행한 과정

- 환각 발생원 제거 : 통계 · 공통성 분석 · map 분류 · SQL 을 코드로 옮기고 LLM 에는 결과만 넘겼다. 검증기 3 종 차단을 재현 테스트로 확인했다.
- 검색 3 층 분기 · 용어 병기 : 원문 · 확장문 임베딩 · 형태소 색인어를 독립으로 만들었다. 병기는 그 용어가 나온 문서에만 적용했다 - 전 문서에 도장을 찍으면 IDF 가 무너진다.
- 색인 · 하이브리드 : 설비 ID 를 통째로 보호하고 적재와 질의에 같은 함수를 강제했다. 후보 200 건을 20 건까지 좁힌다.
- 학습 · 확인 : 피드백을 월 4 회 반영하고 회귀 통과분만 배포한다. 러너가 실제 회귀를 검출하는 동작까지 확인했다.

IIII. 경영효과

예상 성과 2개년 단계 과제다. 아래는 산출식이 명시된 예상 성과이며, 1차년 포토 1개 공정 구간은 전면 산정에서 빼고 실측 구간으로 둔다.

유형 효과 (정량)

[4h/8h - 2h/8h] × 연봉 80,000,000 원 × 1,000 명 = 연 200 억 원

연간 기대효과	200 억 원 - 3 개 공정 확산 후 1,000 명 전면 적용 전제
연간 투자	347,794,165 원(사내 과금). 2 개년 총투자 695,588,330 원
연간 ROI	약 57.5 배 - 회수 약 6.3 일 / 총투자 기준 12.7 일
기준선 실측	포토 공정에서 건당 처리 시간 로그로 실측을 개시한다

민감도 - 목표를 절반만 달성해도 남는다

목표 판정 시간	절감 비율	연간 기대효과	연간 ROI
2.0 시간 (기준)	25.0%	200 억	57.5 배
2.5 시간	18.8%	150 억	43.1 배
3.0 시간	12.5%	100 억	28.8 배
3.5 시간	6.3%	50 억	14.4 배

하루 4 시간에서 3.5 시간, 30 분만 줄여도 ROI 14 배다.

무형 효과 (정성)

24 시간 공백 소멸	야간·주말에 생긴 이상도 그 자리에서 조사된다 - 접수 로그 대조로 확인한다
판단 편차 축소	같은 현상에 같은 조사 경로가 적용된다 - 골든셋 일치율로 확인한다
감사 대응력	판정마다 근거 원문·신뢰도·모델 버전이 남는다 - 감사 로그 전건 리뷰로 확인한다
노하우 자산화	조사규칙·Inform Note 로 남아 사람에게 묶이지 않는다 - 등록 건수 누적으로 본다

선행 추진 실적 - 백지에서 시작하지 않는다

설계	시스템설계서·구축 로드맵·Tool 카탈로그·그라운드링 설계·조사규칙 5 종 등 31 종
구현	LangGraph 조사 코어 스켈레톤 실행 확인, 검증기 5 칩 구현, prod 백엔드 4 종
평가	골든 시나리오 4 건·회귀 러너 구축, 회귀 검출 동작 확인. 검색 recall@10 = 0.500 실측 (골든 4 건 / 색인 50 건)
선행 프로토타입	agentic RAG 전 요소와 이미지 유사 검색·메타 키 조회가 프로토타입에서 동작한다. bge-m3 기준 hit@1 0.957 실측(하드셋 38 질의). 본 과제 검색기는 Qwen3 계열로 교체한다

설계·스켈레톤·평가 위에 실데이터·실도구를 연결해 확산하는 단계다.

검증 방법

- 2Q 그림자 운영에서 판단 일치율 기준선을 실측한다(조치 미실행).
- 건당 처리 시간·이벤트 누락·조치 승인율을 분기마다 보고한다.
- 자동조치 개방 뒤에는 실행 로그를 전건 감사해 오관율을 공개한다.