

AX Award 지원서

I. 개요

지원부문	제조 AX 부문		
팀/그룹	제조기술센터 품질기술그룹	대표자	홍길동
제목	완전한 품질 AI Agent Orchestration 구축 - 감지부터 판단·조치·자동조치까지 스스로 수행하는 살아있는 품질 관리 시스템		
분류	적용시점	2026-09-01 ~ 2028-08-31 (24개월) · 2개년 단계 과제 - 1차년 구축·검증 / 2차년 확산·자동화	
	행진개 범위	1차년 포토 1개 공정 → 2차년 etch·CMP 확산(3개 공정). 확산 완료 후 품질·공정 엔지니어 약 1,000명 · DRAM·NAND 전 제품군 전면 적용. 확산 표준안으로 타 조직에 이관한다.	

II. Process

문제 정의 1. 현행 업무 - 불량 하나를 판단하는 데 네 가지가 반복된다
불량 판단에는 SPC·wafer map·결합 이미지·Inform Note·MES·YMS 를 서로 다른 시스템에서 하나씩 열어 대조해야 한다.

시간 판정 시간의 대부분이 화면을 오가는 데 쓰인다	편차 무엇을 봤는지가 달라 결론이 갈린다	공백 야간·주말은 다음 근무까지 밀린다	회발 근거가 사람 머릿속에 남아 사라진다
--	----------------------------------	---------------------------------	----------------------------------

2. 기존 대안으로는 해결되지 않는다

대안	왜 부족한가
사내 LLM API	사내 DB 조회도 이미지 판독도 못 한다. 우리 데이터로 정확해지는 경로가 없다
사내 공용 RAG	텍스트 적재는 API 로 된다. 다만 BM25·bge-m3·기본 리랭커로 고정된 디폴트 구성이라 손댈 수 있는 것이 tokenizer 정도다. 반도체 용어 사전, 설비 ID 보호, 메타 필터, 리랭커 교체, recall 열람이 안 된다
BI·대시보드	불 화면을 늘릴 뿐 판단을 대신하지 않는다. 화면이 늘수록 대조할 것이 늘어난다
규칙 기반 SPC 알람	이상이다까지만 말한다. 왜 그런가·무엇을 해야 하나에는 답하지 않는다. 대체 대상이 아니라 트리거 입력으로 그대로 쓴다

3. 현업 관점의 중요도 - 상시·대량 업무이고, 오판 비용이 크다

- 대상·부하 : 품질·공정 엔지니어 약 1,000명이 1인당 일 4시간, 근무 8시간의 절반을 이 업무에 쓴다. 이 4시간을 2시간으로 줄이는 것이 **경영효과 산정의 기준선**이다. 4시간은 현업 실무 기준이며 건당 처리 시간 로그로 실측해 보정한다.
- 오판 비용 : 진성을 놓치면 유출·클레임, 가성을 Hold 하면 라인 정지와 Lot 대기. 판정 1건이 수율과 TAT 에 직접 연결된다.

4. 지금 시작해야 하는 이유

판정 이력과 Inform Note 가 학습 자산으로 쓸 만한 양에 도달했다. 오픈 LLM 도 사내 온프레임에서 돌릴 수준까지 왔고, 설계와 검증 체계는 이미 서 있다. 세 조건이 동시에 맞는 시점이다.

Process
재설계

1. 대상 E2E Process - 코어는 하나, 입구는 둘 (예시 : PHO-D03 CD 급등)

입구 ① Chat - 엔지니어 질문	입구 ② 무인 감지 - 스스로 기동
---------------------	---------------------


adapter → 증상 분류	investigator → 도구 호출	judgment → 검증 5 척	action → 조치안	answer → 근거 인용	register 확정(사람)
인지	조사	판정	조치 결정	보고	이력 등록

※ 붉은 칸이 아래 업무 5 단계를 대신한다 - ①~④는 investigator 가, ⑤는 judgment→answer 가 맡는다. 승인과 등록 확정은 사람 몫이다.



확인 ①~④ 반나절 이상 → 수 초. ⑤ 는 보고서·조치안까지 생성하고, 승인과 실행은 사람이 그대로 한다.

2. 조치는 다섯 단계로 올라간다 - 마지막 단계가 자동조치다



승인 이력이 쌓인 시나리오만 개별 심의로 자동조치에 올린다. 승격 뒤에도 전건 사후 리뷰한다.

자동조치는 승격 심의를 통과한 화이트리스트 시나리오만 연다. 설비 제어성 조치는 2 차년에도 사람 승인 대상이다.

3. 단일 기능 개선이 아니다 - 시작·중간·끝을 모두 바꿨다

- 시작 : 인지하던 트리거를 무인 접수로 바꿨다. 출발점이 사람이 아니다.
- 끝 : 근거·모델 버전이 붙은 이력이 남아 다음 사건의 검색 자산이 된다.

4. 현업 활용과 확산 - 현업 노하우가 등록되어야 자라는 구조다

시점	무엇을 여는가	대상
1 차년 3Q	그림자 운영 → Chat 파일럿	포토 엔지니어
1 차년 4Q	무인 접수 - 이벤트 누락 0 건	야간·주말
2 차년 5Q·6Q	etch·CMP 확산 - 코어 변경 0	3 개 공정
2 차년 8Q	확산 표준안 - 자원 증설 없이 이관	약 1,000 명

왜 이 순서인가 : 신뢰가 없으면 아무도 쓰지 않는다. 그래서 조치를 멈춘 그림자 운영으로 일치율부터 본다. 권한은 위험도 순으로 연다.

현업 몫 : 조사규칙 작성, 조치 승인·반려, Inform Note·골든셋 확정.

확산 표준안 = 조사 코어 + 조사규칙 템플릿 + 골든셋 구축 절차.


III. Tech

기술적 해결 방안

1. 왜 AI Agent Orchestration 이어야 하는가

- 조사 순서를 미리 정할 수 없다 : 무엇을 다음에 볼지가 사안마다 다르다. 규칙으로 쓰면 분기가 폭발하고 새 공정마다 발산한다. 결과를 보고 다음을 정하는 구조라야 한다.
- 한 사안에 이중 모달이 섞인다 : 시계열 · 이미지 · 문서 · 정형 DB 를 함께 봐야 한다. 단일 ReAct 한 덩어리로 두면 도구 선택이 서로를 방해한다. supervisor 가 전문 Agent 를 나눠 부린다.
- 정답이 라벨이 아니라 근거를 갖춘 설명이다 : 분류 모델은 Hold 나 Release 나를 찍을 뿐 왜 그런지를 원문 인용과 함께 내지 못한다. 품질 판정은 결론보다 근거가 감사 대상이다.
- 임계 기반으로 안 걸린다 : 룰은 값이 넘어야 울린다. 임계 아래로 완만히 흐르는 shift 는 못 잡는다.

2. 오케스트레이션 구성 - 마스터 Agent 가 전문 Agent 와 사내 시스템을 부린다



- 그림이 못 답는 두 가지 - Image Agent 는 유사도로 후보를 좁힌 뒤 메타데이터 · 파일 경로를 키로 삼아 그 사고의 원인 · 조치를 RDB 에서 확정한다. Agentic RAG 는 문서만 보지 않고 사고 리스트 · 원인 · 조치 RDB 메타데이터까지 함께 조회해 정형과 비정형을 한 근거팩으로 묶는다.

※ 계획이 아니다 - 질의 재작성, 하이브리드 검색, cross-encoder 리랭커, 재검색 루프, 인용 강제, 이미지 유사 검색이 선행 프로토타입에서 돈다. 검색기는 본 과제에서 Qwen3 계열로 교체한다.

설계 결정 : 계산은 시스템, 연결은 LLM / 검증기 통과분만 채택 / 조치는 규칙표와 권한별 승인 / 등록은 현업 확정분만 / 조사규칙은 문서로 관리한다.

3. 도구 구성의 근거 - 하나씩 붙여 답이 어떻게 달라지는지 비교했다

앞의 예시(PHOD03 CD 급등) 한 건에 대한 답을 도구별로 비교했다.

붙인 도구	같은 질문에 대한 답
기본 LLM	7/26 02 시부터 CD 가 급등했습니다
+ Trend Agent	7/26 02:14 CD +0.8nm - 시점 · 변화량이 잡힙니다
+ Image Agent	Map 상 edge 국부 집중 - Focus 편차형이 의심됩니다
+ 유사사례 검색	PHOD01 과 같은 패턴, 원인은 Scanner Focus 드리프트
+ 설비 이력 조회	7/26 Scanner PM 직후 Focus 재보정 누락 - 원인 확정
+ 조치 생성	근거 3 종 인용 - 진행 금지 · 조치 코드 · 보고서 제안

도구를 하나 빼면 답이 어느 단계로 후퇴하는지가 그대로 보인다.

기술적 해결 방안	4. 알고리즘 선택 근거		
	과제	선택	선택 근거
	판단 · 조율	GLM-5.2 743B-A39B	도구 호출 안정성과 장문 근거 종합이 함께 필요하다. 둘을 한 모델에 묶는다
	조사 제어	ReAct 루프 (LangGraph)	결과를 보고 다음 도구를 정한다
	Trend 이상탐지	PatchTST + CUSUM/BOCPD	LSTM · Prophet 은 변화 시점을 못 찍는다. 변화점은 코드가 찍는다
	불량 분류	ConvNeXt V2	라벨 있는 불량엔 VLM 이 낱비다
	미지 불량	PatchCore + WRN-50-2	라벨이 없는 새 불량은 분류 모델이 못 잡는다. 정상 특징과의 거리로 잡는다
	이미지 판독	Qwen3.5-397B-A17B / Qwen3.6-35B-A3B	정밀은 대형, 상시 감시는 경량
	문서 · 사례 검색	Qwen3 Embedding · Reranker	임베딩만으로는 설비 ID 정확 일치를 놓친다. BM25 를 함께 쓴다
	이미지 유사 검색	Qwen3-VL-Embedding	유사도로 좁히고 메타 키로 확정한다
5. 그럴듯한 오답이 채택되지 않게 - 코드가 검사한다			
판단서는 다섯 관문을 통과해야 채택된다 — LLM 이 아니라 코드가 검사한다			
판단서 초안 → 스키마 □ 형식 위반 → 근거 실재 □ 없는 증거 → 사실 대조 □ 원문에 없는 수정 → 신뢰도 근거 3개 미만 → 공백 금지 □ 부족분 미명시 → 채택 탈락 → 오류를 붙여 재생성 → 계속 실패하면 판단 불가로 강등, 사람에게 넘긴다			
※ 검증기 3 종 차단은 재현 테스트로 확인했다.			
6. 성능 지표와 배포 게이트			
- 실측치 : 검색 recall@10 = 0.500 (골든 4 건 / 색인 50 건) - 선행 프로토타입 실측 : bge-m3 기준 hit@1 0.957 (하드셋 38 질의). 본 과제 검색기는 Qwen3 계열로 교체해 재측정한다. - 0 건으로 관리한다 : 근거 없는 판단 채택, 미승인 L2 조치 실행, 무인 접수 누락. 검증기 차단 로그와 감사 로그로 센다. - 판정 정답률은 그림자 운영에서 기준선을 실측한 뒤 정한다. 임의의 퍼센트를 지금 적지 않는다. - 배포 게이트 : 골든셋 일치율 · recall@10 · 처리 시간 · 반려율을 본다. 하락하면 배포하지 않는다.			
7. 알고리즘 개선을 위해 수행한 과정			
- 환각 발생원 제거 : 통계 · 공통성 분석 · map 분류 · SQL 을 코드로 옮기고 LLM 에는 결과만 넘겼다. 숫자를 지어낼 자리가 구조적으로 없다. - 반도체 사전으로 분절을 막는다 : 토큰나이저는 설비 PHOD03 을 PHO/D/03 으로, recipe PH_CD_A01-3 을 조각낸다. 쪼개지면 그 문서는 검색에서 사라진다. EQP · STEP · recipe · 계측 항목을 사전에 등록해 지킨다. - 3 층 분기 · 용어 병기 : 원문 · 확장문 임베딩 · 색인어를 독립으로 만들고 적재와 질의에 같은 함수를 쓴다. 병기는 그 용어가 나온 문서에만 적용한다 - 전 문서에 찍으면 IDF 가 무너진다. - 하이브리드 : 후보 200 건을 20 건으로 좁히고, 벡터와 BM25 결합 가중치는 실측으로 정했다. - 학습 · 확인 : 피드백을 월 4 회 반영하고 회귀 통과분만 배포한다. 러너의 회귀 검출까지 확인했다.			

IIII. 경영효과

예상 성과

2개년 단계 과제다. 아래는 산출식이 명시된 예상 성과이며, 1차년 포토 1개 공정 구간은 전면 산정에서 빼고 실측 구간으로 둔다.


유형 효과 (정량)



[(개선 전 4h ÷ 8h) - (개선 후 2h ÷ 8h)] × 연봉 80,000,000원 × 1,000명 = 연 200억 원

- 투자는 연 347,794,165 원, 2개년 총투자 695,588,330 원이다. 공정이 3개로 늘어도 추가 자원을 요청하지 않는다.
- 1차년은 효과를 계상하지 않는다. 그림자 운영으로 판단 일치율 기준선을 잡고, 무인 접수 2주 연속 누락 0건이 통과 조건이다.

목표를 절반만 달성해도 남는다 — 30분만 줄여도 ROI 14배



무형 효과 (정성)

24 시간 공백 소멸	야간 · 주말에 생긴 이상도 그 자리에서 조사된다
판단 편차 축소	같은 현상에 같은 조사 경로가 적용된다
감사 대응력	판정마다 근거 원문 · 신뢰도 · 모델 버전이 남는다
노하우 자산화	조사규칙 · Inform Note 로 남아 사람에게 안 묶인다
타 조직 이관	확산 표준안으로 코어를 그대로 넘긴다

선행 추진 실적 - 백지에서 시작하지 않는다

설계	시스템설계서 · 구축 로드맵 · Tool 카탈로그 · 그라운드 설계 · 조사규칙 5종 등 31종
구현	LangGraph 조사 코어 스켈레톤 실행 확인, 검증기 5척 구현, prod 백엔드 4종
평가	골든 시나리오 4건 · 회귀 러너 구축, 회귀 검출 동작 확인. 검색 recall@10 = 0.500 실측 (골든 4건 / 색인 50건)
선행 프로토타입	agentic RAG 전 요소와 이미지 유사 검색 · 메타 키 조회가 동작한다. 불량 이미지 임베딩 군집 지표 AMI 0.956 / ARI 0.860 (43 class × 30 장 = 900 wafer)

설계 · 스켈레톤 · 평가 위에 실데이터를 연결하는 단계다. 될지 모르는 구간은 지나 있다.

검증 방법

- 2Q 그림자 운영에서 판단 일치율 기준선을 실측한다(조치 미실행).
- 건당 처리 시간 · 이벤트 누락 · 조치 승인율을 분기마다 보고한다.
- 자동조치 개방 뒤에는 실행 로그를 전건 감사해 오관율을 공개한다.