

AX Award 지원서

I. 개요

지원부문	제조 AX 부문		
팀/그룹	제조기술센터 품질기술그룹	대표자	홍길동
제목	완전한 품질 AI Agent Orchestration 구축 - 감지부터 판단·조치·자동조치까지 스스로 수행하는 살아있는 품질 관리 시스템		
분류	적용시점	2026-09-01 ~ 2028-08-31 (24개월) · 2개년 단계 과제 - 1차년 구축·검증 / 2차년 확산·자동화	
	형진개 범위	1차년 포토 1개 공정 → 2차년 etch·CMP 확산(3개 공정). 확산 완료 후 품질·공정 엔지니어 약 1,000명 · DRAM·NAND 전 제품군 전면 적용. 확산 표준안으로 타 조직에 이관한다.	

II. Process

문제 정의

1. 현행 업무 - 불량 하나를 판단하는 데 네 가지가 반복된다

불량 판단에는 SPC·wafer map·결합 이미지·Inform Note·MES·YMS를 서로 다른 시스템에서 하나씩 열어 대조해야 한다.

시간

판정 시간의 대부분이 화면을 오가는 데 쓰인다

편차

무엇을 봤는지가 달라 결론이 갈린다

공백

야간·주말은 다음 근무까지 밀린다

회발

근거가 사람 머릿속에 남아 사라진다

2. 기존 대안으로는 해결되지 않는다

대안	왜 부족한가
사내 LLM API	사내 DB 조회도 이미지 판독도 못 한다. 우리 데이터로 정확해지는 경로가 없다
사내 공용 RAG	적재는 사내 API로 되지만 검색 품질을 좌우하는 손잡이가 tokenizer 하나뿐이다. BM25·bge-m3·기본 리랭커로 고정이라 반도체 용어 사전, 설비 ID 보호, 메타 필터, 리랭커 교체, recall 열람이 안 된다
BI·대시보드	불 화면을 늘릴 뿐 판단을 대신하지 않는다. 화면이 늘수록 대조할 것이 늘어난다
규칙 기반 SPC 알람	이상이다까지만 말한다. 왜 그런가·무엇을 해야 하나에는 답하지 않는다. 대체 대상이 아니라 트리거 입력으로 그대로 쓴다

3. 현업 관점의 중요도 - 상시·대량 업무이고, 오판 비용이 크다

- 대상·부하 : 품질·공정 엔지니어 약 1,000명이 1인당 일 4시간, 근무 8시간의 절반을 이 업무에 쓴다. 이 4시간을 2시간으로 줄이는 것이 **경영효과 산정의 기준선**이다. 4시간은 현업 실무 기준이며 건당 처리 시간 로그로 실측해 보정한다.
- 오판 비용 : 진성을 놓치면 유출·클레임, 가성을 Hold 하면 라인 정지와 Lot 대기. 판정 1건이 수율과 TAT에 직접 연결된다.

4. 지금 시작해야 하는 이유

판정 이력과 Inform Note가 학습 자산으로 쓸 만한 양에 도달했다. 오픈 LLM도 사내 온프레임에서 돌릴 수준까지 왔고, 설계와 검증 체계는 이미 서 있다.


Process
재설계

1. 대상 E2E Process - 코어는 하나, 입구는 둘 (예시 : PHOD03 CD 급등)

입구 ① Chat - 엔지니어 질문	입구 ② 무인 감지 - 스스로 기동
---------------------	---------------------


adapter → 증상 분류	investigator → 도구 호출	judgment → 검증 5 척	action → 조치안	answer → 근거 인용	register 확정(사람)
인지	조사	판정	조치 결정	보고	이력 등록

※ 붉은 칸이 아래 업무 5 단계를 대신한다 - ①~④는 investigator 가, ⑤는 judgment→answer 가 맡는다. 승인과 등록 확정은 사람 몫이다.



확인 ①~④ 반나절 이상 → 수 초. ⑤ 는 보고서·조치안까지 생성하고, 승인과 실행은 사람이 그대로 한다.

2. 조치는 다섯 단계로 올라간다 - 마지막 단계가 자동조치다




승인 이력이 쌓인 시나리오만 개별 심의로 자동조치에 올린다. 승격 뒤에도 전건 사후 리뷰한다. 설비 제어성 조치는 2차년에도 사람 승인 대상이다.

3. 단일 기능 개선이 아니다 - 시작 · 중간 · 끝을 모두 바꿨다

- 시작 : 인지하던 트리거를 무인 접수로 바꿨다. 출발점이 사람이 아니다.
- 중간 : 화면 다섯을 사람이 대조하던 자리를 도구 자율 호출이 대신한다. 무엇을 볼지 사람이 정하지 않는다.
- 끝 : 근거 · 모델 버전이 붙은 이력이 남아 다음 사건의 검색 자산이 된다.

4. 현업 활용과 확산 - 현업 노하우가 등록되어야 자라는 구조다



왜 이 순서인가 : 신뢰가 없으면 아무도 쓰지 않는다. 실행이 확인된 조사 코어 위에 조치를 멈춘 그림자 운영을 얹어 일치율부터 벌고, 권한은 위험도 순으로 연다.

현업 몫 : 조사규칙 작성(1 차년 3Q 초안), 조치 승인 · 반려(상시), Inform Note · 골든셋 확정(분기).

확산 표준안 = 조사 코어 + 조사규칙 템플릿 + 골든셋 구축 절차.


III. Tech

기술적 해결 방안

1. 왜 AI Agent Orchestration 이어야 하는가

- 조사 순서를 미리 정할 수 없다 : 무엇을 다음에 볼지가 사안마다 다르다. 규칙으로 쓰면 분기가 폭발하고 새 공정마다 발산한다. 결과를 보고 다음을 정하는 구조라야 한다.
- 한 사안에 이중 모달이 섞인다 : 시계열 · 이미지 · 문서 · 정형 DB 를 함께 봐야 한다. 단일 ReAct 한 덩어리로 두면 도구 선택이 서로를 방해한다. supervisor 가 전문 Agent 를 나눠 부린다.
- 정답이 라벨이 아니라 근거를 갖춘 설명이다 : 분류 모델은 Hold 나 Release 나를 찍을 뿐 왜 그런지를 원문 인용과 함께 내지 못한다. 품질 판정은 결론보다 근거가 감사 대상이다.
- 임계 기반으로 안 걸린다 : 룰은 값이 넘어야 울린다. 임계 아래로 완만히 흐르는 shift 는 못 잡는다.

2. 오케스트레이션 구성 - 마스터 Agent 가 전문 Agent 와 사내 시스템을 부린다



- 그림이 못 담는 두 가지 - Image Agent 는 유사도로 후보를 좁힌 뒤 메타데이터 · 파일 경로를 키로 삼아 그 사고의 원인 · 조치를 RDB 에서 확정한다. Agentic RAG 는 문서만 보지 않고 사고 리스트 · 원인 · 조치 RDB 메타데이터까지 함께 조회해 정형과 비정형을 한 근거팩으로 묶는다.

※ 계획이 아니다 - 질의 재작성, 하이브리드 검색, cross-encoder 리랭커, 재검색 루프, 인용 강제, 이미지 유사 검색이 선행 프로토타입에서 돈다.

설계 결정 : 계산은 시스템, 연결은 LLM / 검증기 통과분만 채택 / 조치는 규칙표와 권한별 승인 / 등록은 현업 확정분만 / 조사규칙은 문서로 관리한다.

3. 도구 구성의 근거 - 하나씩 붙여 답이 어떻게 달라지는지 비교했다

앞의 예시(PHOD03 CD 급등) 한 건에 대한 답을 도구별로 비교했다.

기본 LLM	02시부터 급등 — 시점 없음
+ Trend Agent	02:14 CD +0.8nm — 시점·변화량
+ Image Agent	Map edge 국부 집중 — Focus 편차형
+ 유사사례 검색	PHOD01 동일 패턴 — Scanner Focus 드리프트
+ 설비 이력 조회	PM 직후 재보정 누락 — 원인 확정
+ 조치 생성	근거 3종 인용 — 진행 금지·조치 코드

도구를 하나 빼면 답이 어느 단계로 후퇴하는지가 그대로 보인다.

기술적 해결 방안	4. 알고리즘 선택 근거		
	과제	선택	선택 근거
	판단 · 조율	GLM-5.2 743B-A39B	나누면 모델이 늘고 문맥이 끊긴다. 도구 호출 안정성과 근거 종합을 한 모델에 묶는다
	조사 제어	ReAct 루프 (LangGraph)	결과를 보고 다음 도구를 정한다
	Trend 탐지	PatchTST + CUSUM/BOCPD	LSTM · Prophet 은 변화 시점을 못 찍는다. 변화점은 코드가 찍는다
	불량 분류	ConvNeXt V2	라벨 있는 불량엔 VLM 이 낭비다
	미지 불량	PatchCore + WRN-50-2	라벨 없는 새 불량은 분류로 못 잡는다. 정상 특징과의 거리로 잡는다
	이미지 판독	Qwen3.5-397B-A17B / Qwen3.6-35B-A3B	정밀은 대형, 상시 감시는 경량
	문서 · 사례 검색	Qwen3 Embedding · Reranker	사내 용어를 사전으로 통제할 수 있는 계열이라 골랐다. 임베딩만으로는 설비 ID 를 놓쳐 BM25 를 함께 쓴다
	이미지 유사검색	Qwen3-VL-Embedding	유사도로 좁히고 메타 키로 확정한다
5. 그럴듯한 오답이 채택되지 않게 - 코드가 검사한다			
판단서는 다섯 관문을 통과해야 채택된다 — LLM 이 아니라 코드가 검사한다			
판단서 초안 스키마 × 형식 위반 근거 실재 × 없는 증거 사실 대조 × 원문에 없는 수치 신뢰도 × 근거 3개 미만 공백 금지 × 부족분 미명시 채택			
탈락 → 오류를 붙여 재생성 → 계속 실패하면 판단 불가로 강등, 사람에게 넘긴다			
※ 검증기 5 칩 중 3 종 차단은 재현 테스트로 확인했다.			
6. 성능 지표와 배포 게이트			
검색 recall@10 = 0.500 (골든 4 건 / 색인 50 건 · 회귀 러너 실측) - 절대 성능이 아니라 회귀 검출용 기준선이다. - 0 건으로 관리한다 : 근거 없는 판단 채택, 미승인 L2 조치 실행, 무인 접수 누락. 검증기 차단 로그와 감사 로그로 쎌다. - 판정 정답률은 그림자 운영 실측 뒤에 정한다 - 임의의 퍼센트를 지금 적지 않는다. 배포 게이트는 일치율 · recall@10 · 처리 시간 · 반려율이 하락하면 배포를 막는다.			
7. 알고리즘 개선을 위해 수행한 과정			
- 검색기 교체 : 선행 프로토타입은 bge-m3 로 하드셋 38 질의 hit@1 0.957 을 실측했다. 설비 ID 분절을 막으려 Qwen3 계열로 바꿔 재측정한다. - 환각 발생원 제거 : 통계 · 공통성 분석 · map 분류 · SQL 을 코드로 옮기고 LLM 에는 결과만 넘겼다. 숫자를 지어낼 자리가 구조적으로 없다. - 반도체 사전 : 토크나이저가 PHOD03 을 PHO/D/03 으로 쪼개면 그 문서는 검색에서 사라진다. EQP · STEP · recipe 를 사전에 등록해 지킨다. - 3 층 분기 · 용어 병기 : 원문 · 확장문 임베딩 · 색인어를 독립으로 만들고 적재와 질의에 같은 함수를 쓴다. 병기는 나온 문서에만 찍는다. - 하이브리드 · 회귀 : 후보 200 건을 20 건으로 좁히고 결합 가중치는 실측으로 정했다. 피드백은 월 4 회 반영하고 회귀 통과분만 배포한다.			

IIII. 경영효과

예상 성과

2 개년 단계 과제다. 아래는 산출식이 명시된 예상 성과이며, 1 차년 포토 1 개 공정 구간은 전면 산정에서 빼고 실측 구간으로 둔다.

유형 효과 (정량)

200억 원 / 년 확산 완료 후 1,000명 전면 적용	57.5배 연간 ROI 투자 347,794,165원 대비	6.3일 투자 회수 2개년 총투자 기준 12.7일
--	--	--

[(개선 전 4h ÷ 8h) - (개선 후 2h ÷ 8h)] × 연봉 80,000,000원 × 1,000명 = 연 200억 원
연봉 80,000,000원 = 사내 산정 기준값 · 1,000명 = 제조기술센터 품질·공정 엔지니어

- 투자는 연 347,794,165 원(사내 과금), 2 개년 총투자 695,588,330 원이다. 공정이 3 개로 늘어도 추가 자원을 요청하지 않는다.
- 1 차년은 효과를 계상하지 않는다 - 넣으면 그 숫자로 심사를 통과한 뒤 실측치가 다를 때 설명할 방법이 없다. 그림자 운영으로 일치율 기준선을 잡고, 무인 접수 2 주 연속 누락 0 건이 통과 조건이다.

목표를 절반만 달성해도 남는다 — 30분만 줄여도 ROI 14배

2.0시간 (기준)		57.5배 · 200억
2.5시간		43.1배 · 150억
3.0시간		28.8배 · 100억
3.5시간		14.4배 · 50억

무형 효과 (정성)

24시간 공백 소멸	판단 편차 축소	감사 대응력	노하우 자산화	타 조직 이관
야간·주말에 생긴 이상도 그 자리에서 조사된다	같은 현상에 같은 조사 경로가 적용된다	판정마다 근거 원문·신뢰도·모델 버전이 남는다	조사규칙·Inform Note 로 남아 사람에게 안 묶인다	확산 표준안으로 코어를 그대로 넘긴다

선행 추진 실적 - 백지에서 시작하지 않는다

구현	LangGraph 조사 코어 스켈레톤 실행 확인, 검증기 5 칩 구현, prod 백엔드 4 종
평가	골든 시나리오 4 건 · 회귀 러너 구축, 회귀 검출 동작 확인. 검색 recall@10 = 0.500 실측 (골든 4 건 / 색인 50 건)
선행 프로토타입	agentic RAG 전 요소와 이미지 유사 검색 · 메타 키 조회가 동작한다. 불량 이미지 임베딩 군집 지표 AMI 0.956 / ARI 0.860 (43 class × 30 장 = 900 wafer)
설계	시스템설계서 · 구축 로드맵 · Tool 카탈로그 · 그라운드링 설계 · 조사규칙 5 종 등 31 종

설계 · 스켈레톤 · 평가 위에 실데이터를 연결하는 단계다. 될지 모르는 구간은 지나 있다.

검증 방법

- 2Q 그림자 운영에서 판단 일치율 기준선과 건당 처리 시간 4 시간 가정을 함께 실측한다(조치 미실행).
- 건당 처리 시간 · 이벤트 누락 · 조치 승인율을 분기마다 보고한다.
- 자동조치 개방 뒤에는 실행 로그를 전건 감사해 오관율을 공개한다.