

AX Award 지원서

I. 개요

지원부문	제조 AX 부문		
팀/그룹	제조기술센터 품질기술그룹	대표자	홍길동
제목	완전한 품질 AI Agent Orchestration 구축 - 감지부터 판단·조치·자동조치까지 스스로 수행하는 살아있는 품질 관리 시스템		
분류	적용시점	2026-09-01 ~ 2028-08-31 (24개월) · 2개년 단계 과제 - 1차년 구축·검증 / 2차년 확산·자동화	
	형진개 범위	1차년 포토 1개 공정 → 2차년 etch·CMP 확산(3개 공정). 확산 완료 후 품질·공정 엔지니어 약 1,000명 · DRAM·NAND 전 제품군 전면 적용. 확산 표준안으로 타 조직에 이관한다.	

II. Process

문제 정의

1. 현행 업무 - 불량 하나를 판단하는 데 네 가지가 반복된다

시간 시스템을 오가며 손으로 대조하는 데 판정 시간의 대부분이 쓰인다 계측 : 처리 시간 로그	편차 무엇을 봤고 무엇을 안 봤는지가 사람마다 달라 같은 현상에 다른 계측 : 같은 현상의 상이 판정 이력	공백 야간·주말은 다음 근무까지 밀린다. 그 사이 같은 원인의 계측 : 야간 발생 건의 처리 착수 시각	회발 판단 근거가 사람 머릿속에 남아 담당자가 바뀌면 처음부터 푼다 계측 : 담당 교체 후 재조사 건
---	--	--	---

2. 기존 대안으로는 해결되지 않는다

사내 LLM API ❌ 사내 DB 도 이미지도 못 본다. 정확해질 경로가 없다	사내 공용 RAG ❌ 적재는 사내 API 로 된다. 손잡이가 tokenizer 하나뿐이다
BI·대시보드 ❌ 불 화면을 늘릴 뿐 판단을 대신하지 않는다	규칙 기반 SPC 알람 ➡ 이상이다까지만 말한다. 트리거 입력으로 그대로 쓴다

3. 현업 관점의 중요도 - 상시·대량 업무이고, 오판 비용이 크다



4. 지금 시작해야 하는 이유

✓ 판정 이력·Inform Note 학습 자산으로 쓸 만한 양에 도달했다	➡	지금 시작
✓ 공개 모델 사내에 들일 수 있는 모델이 성숙했다		
✓ 설계·검증 체계 이미 서 있다		


Process
재설계

1. 대상 E2E Process - 코어는 하나, 입구는 둘 (예시 : PHOD03 CD 급등)


입구 ① Chat - 엔지니어 질문	입구 ② 무인 감지 - 스스로 기동
---------------------	---------------------

adapter → 증상 분류	investigator → 도구 호출	judgment → 검증 5 척	action → 조치안	answer → 근거 인용	register 확정(사람)
인지	조사	판정	조치 결정	보고	이력 등록

※ 붉은 칸 이 아래 업무 5 단계를 대신한다. 승인과 등록 확정은 사람 몫이다.




2. 조치는 다섯 단계로 올라간다 - 마지막 단계가 자동조치다



승인 이력이 쌓인 시나리오만 개별 심의로 자동조치에 올린다. 승격 뒤에도 전건 사후 리뷰한다. 설비 제어성 조치는 2차년에도 사람 승인 대상이다.

3. 단일 기능 개선이 아니다 - 시작·중간·끝을 모두 바꿨다



4. 현업 활용과 확산 - 현업 노하우가 등록되어야 자라는 구조다



확산 표준안 = 조사 코어 + 공정별 조사규칙 템플릿 + 골든셋 구축 절차

2 차년 통과 조건 - 코어 변경 0 · 반려율 상승 없음. 코어는 공정을 모른다 - 늘어나는 것은 조사규칙 문서와 색인이지만 모델이 아니다. 공정이 3 개로 늘어도 추가 자원을 요청하지 않는다.

현업 몫 - 조사규칙 초안(3Q · 공정 담당 엔지니어) · 조치 승인 · 반려(상시) · 골든셋 확정(분기). 승인 · 반려는 품의 · 결재 확인의 치환이다.

현업 점점 - 질문은 Chat 으로 넣는다. 무인 감지 건은 야간 · 주말에도 교대 근무자에게 통보되고, L2 이상은 승인 전까지 실행되지 않는다. 사내 시스템 조회는 정보계 경유 · 조회 전용이다 - 기간 · 행 수 상한을 걸고, 접속점 확보가 1 차년 1Q 통과 조건이다.


III. Tech

기술적 해결 방안

1. 왜 AI Agent Orchestration 이어야 하는가

- 조사 순서를 미리 정할 수 없다 : 무엇을 다음에 볼지가 사안마다 다르다. 규칙으로 쓰면 분기가 폭발하고 새 공정마다 발산한다.
- 한 사안에 이중 모달이 섞인다 : 시계열 · 이미지 · 문서 · 정형 DB 를 함께 봐야 한다. 단일 ReAct 한 덩어리로 두면 도구 선택이 서로를 방해한다.
- 정답이 라벨이 아니라 근거를 갖춘 설명이다 : 분류 모델은 Hold/Release 를 찍을 뿐 왜인지를 내지 못한다. 판정은 결론보다 근거가 감사 대상이다.
- 임계 기반으로 안 걸린다 : 임계 아래로 완만히 흐르는 shift 는 못 잡는다.

2. 오케스트레이션 구성 - 마스터 Agent 가 전문 Agent 와 사내 시스템을 부린다



근거 사슬 - LLM 이 지어낸 자리가 없다

불량 이미지 투입

- └ 유사도 검색 후보만 좁힌다. 여기서 확정하지 않는다
- └ 메타·경로 키 이 키가 그 사고를 특정한다
 - └ 사고 RDB 현업이 기입한 원본 - 원인·조치가 여기 있다
 - └ 보고서 원문 경로로 찾아 읽고 그 문장을 인용한다

※ 계획이 아니다 - 질의 제작성, 하이브리드 검색, cross-encoder 리랭커, 재검색 루프가 선행 프로토타입에서 돈다.

설계 결정 : 계산은 시스템, 연결은 LLM / 검증기 통과분만 채택 / 조치는 규칙표와 권한별 승인 / 등록은 현업 확정분만 / 조사규칙은 문서로 관리한다.

3. 도구 구성의 근거 - 하나씩 붙여 답이 어떻게 달라지는지 비교했다

예시 시나리오 한 건 - 02:14 CD +0.8nm 급등에 대한 답을 도구별로 비교했다.

기본 LLM	02시부터 급등 — 시점 없음
+ Trend Agent	02:14 CD +0.8nm — 시점·변화량
+ Image Agent	Map edge 국부 집중 — Focus 편차형
+ 유사사례 검색	PHOD01 동일 패턴 — Scanner Focus 드리프트
+ 설비 이력 조회	PM 직후 재보정 누락 — 원인 확정
+ 조치 생성	근거 3종 인용 — 진행 금지·조치 코드

도구를 하나 빼면 답이 어느 단계로 후퇴하는지가 그대로 보인다.

기술적 해결 방안	4. 알고리즘 선택 근거		
	과제	선택	선택 근거
	판단 · 조율	GLM-5.2 743B-A39B	판단 · tool call · 코딩을 한 모델에 묶는 조건에서 골랐다. 나누면 문맥 · 캐시 공유가 깨진다
	조사 제어	ReAct 루프 (LangGraph)	고정 파이프라인은 분기가 폭발한다. 결과를 보고 다음 도구를 정한다
	Trend 탐지	PatchTST + CUSUM/BOCPD	LSTM · Prophet 은 변화 시점을 못 짚는다. 변화점은 코드가 찍는다
	불량 분류	ConvNeXt V2	라벨 있는 불량엔 VLM 이 낱비다
	미지 불량	PatchCore + WRN-50-2	라벨 없는 불량은 분류로 못 잡는다. 정상 특징과의 거리로 잡는다
	이미지 판독	Qwen3.5-397B-A17B · Qwen3.6-35B-A3B	요구 정밀도가 다르다 - 정밀 판독은 대형, 상시 감시는 경량
	문서 · 사례 검색	Qwen3 Embedding · Reranker	임베딩 · 리랭커를 튜닝할 수 있는 계열이다. 임베딩만으로는 설비 ID 를 놓쳐 BM25 를 함께 쓴다
	이미지 유사검색	Qwen3-VL-Embedding	유사도는 후보만 좁힌다. 메타 · 경로 키로 RDB 에서 확정한다
5. 그럴듯한 오답은 코드가 걸러낸다 - 다섯 관문			
판단서 초안 → 스키마 × 형식 위반 → 근거 실재 × 없는 증거 → 사실 대조 × 원문에 없는 수치 → 신뢰도 × 근거 3개 미만 → 공백 금지 × 부족분 미명시 → 채택			
※ 탈락하면 재생성하고, 계속 실패하면 판단 불가로 강등해 사람에게 넘긴다.			
6. 성능 지표와 배포 게이트			
검색 $\text{recall@10} = 0.500$ (골든 4 건 → 30 건 확장 예정 / 색인 50 건 · 회귀 러너 실측) - 회귀 검출용 기준선이다.			
- 0 건으로 관리한다 : 근거 없는 판단 채택 · 미승인 L2 조치 실행 · 무인 접수 누락. 검증기 차단 로그와 감사 로그로 센다. - 판정 정답률은 그림자 운영 실측 뒤에 정한다 - 임의의 퍼센트를 지금 적지 않는다. 일치율(AI 판단 대 엔지니어 판단, 조치 미실행) · recall@10 · 처리 시간 · 반려율이 떨어지면 배포를 막는다.			
7. 알고리즘 개선을 위해 수행한 과정			
- 검색기 교체 : 색인 5,291 청크 / 103 문서 규모로 선행 프로토타입을 검증했다. 다음은 Qwen3 임베딩 · 리랭커 교체와 재측정이다. - 환각 발생원 제거 : 통계 · 공통성 분석 · map 분류 · SQL 을 코드로 옮기고 LLM 에는 결과만 넘겼다. 숫자를 지어낸 자리가 구조적으로 없다. - 반도체 사전 : 토큰라이저가 PHOD03 을 PHO/D/03 으로 쪼개면 그 문서는 검색에서 사라진다. EQP · STEP · recipe 를 사전에 등록해 지킨다. - 재학습 : 대상은 검색기 임베딩 · 리랭커다. 파인튜닝 · 선호학습의 라벨은 현업이 확정한 판정 이력과 Inform Note 다 - 별도 라벨링 공수가 없다. 승인 게이트의 채택 · 수정 · 반려가 입력이 된다. 결합 가중치는 선행 프로토타입 실측으로 BM25 등가중이 최적임을 확인했다. 월 4 회 돌려 골든셋 회귀 통과분만 배포한다. 선행 프로토타입 실측 - 26 질의 $\text{hit@1} 1.000$, 하드셋 38 질의(패러프레이즈 · 교차언어) 0.957, 코퍼스 2.4 배 확장 뒤에도 0.962 · 1.29 초다. 검색기 계열이 달라 본 과제 값이 아니다 - Qwen3 로 다시 쟀다.			

IIII. 경영효과

예상 성과 산출식이 명시된 예상 성과다. 기준 4시간 · 목표 2시간은 실측 전 가정이다.


유형 효과 (정량)



[(개선 전 4h ÷ 8h) - (개선 후 2h ÷ 8h)] × 연봉 80,000,000원 × 1,000명 = 연 200억 원
 연봉 80,000,000원 = 사내 산정 기준값 · 1,000명 = 제조기술센터 품질·공정 엔지니어
4h → 2h 는 실측 전 가정 — 그림자 운영 로드로 대체한다

- 200 억은 인원 감축이 아니라 판정 업무 시간을 사내 산정 기준 연봉으로 환산한 값이다. 투자는 연 347,794,165 원이다.
- 1 차년은 효과를 계상하지 않는다. 통과 조건은 일치율 기준선 확보와 무인 접수 2주 연속 누락 0 건이다.

이 표는 절감폭만 혼든다. 기준 4시간은 그림자 운영 로드로 실측해 대체하며, 실측이 낮으면 효과도 같은 비율로 내린다.



무형 효과 (정성)

야간 조사 공백	판단 편차 축소	감사 대응력	노하우 자산화	타 조직 이관
야간·주말에 생긴 이상도 그 자리에서 조사된다	같은 현상에 같은 조사 경로가 적용된다	판정마다 근거 원문·신뢰도·모델 버전이 남는다	조사규칙·Inform Note 로 남아 사람에게 안 묶인다	확산 표준안으로 코어를 그대로 넘긴다

선행 추진 실적 - 백지에서 시작하지 않는다

구현	조사 코어 스켈레톤 실행 확인, 검증기 5 칩 구현, prod 백엔드 4 종
평가	골든 시나리오 4 건 · 회귀 러너 구축. 검색 recall@10 = 0.500 실측 (골든 4 건 / 색인 50 건)
선행 프로토타입	agentic RAG 전 요소와 이미지 유사 검색 · 메타 키 조회가 동작한다. 불량 이미지 임베딩 군집 AMI 0.956 · ARI 0.860 · 노이즈 0.52% (43 class × 30 장 = 900 wafer)
설계	시스템설계서 · 구축 로드맵 · Tool 카탈로그 · 그라운드링 설계 · 조사규칙 등 31 종

요소 기술은 실측으로 확인했다. 남은 것은 실데이터 연결과 그림자 운영 검증이다.

검증 방법

- 2Q 그림자 운영 - 조치 미실행, 일치율 기준선과 4시간 가정을 실측한다.
- 4Q 무인 접수 - 처리 시간 · 이벤트 누락 · 조치 승인율을 분기마다 보고한다.
- 2 차년 자동조치 개방 - 시나리오 단위로만 연다. 승인율 · 오탐율이 기준을 넘은 시나리오를 개별 심의하고, 승격 뒤에는 실행 로그를 전건 사후 리뷰한다.