

AX Award 지원서

I. 개요

지원부문	제조 AX 부문		
팀/그룹	제조기술센터 품질기술그룹	대표자	홍길동
제목	완전한 품질 AI Agent Orchestration 구축 - 감지부터 판단·조치·자동조치까지 스스로 수행하는 살아있는 품질 관리 시스템		
분류	적용시점	2026-09-01 ~ 2028-08-31 (24개월) · 2개년 단계 과제 - 1차년 구축·검증 / 2차년 확산·자동화	
	형전개 범위	1차년 포토 1개 공정 → 2차년 etch·CMP 확산(3개 공정). 확산 완료 후 품질·공정 엔지니어 약 1,000명 · DRAM·NAND 전 제품군 전면 적용. 확산 표준안으로 타 조직에 이관한다.	

II. Process

문제 정의

1. 현행 업무 - 불량 하나를 판단하는 데 네 가지가 반복된다

시간 SPC-MES 를 오가며 손으로 대조하는 데 판정 시간의 대부분이 쓰인다 계측 : 처리 시간 로그	편차 같은 CD shift 를 두고 무엇을 봤는지가 사람마다 달라 결론이 갈린다 계측 : 같은 현상의 장이 판정 이력	공백 야간에 뜬 Map 이상은 다음 근무까지 밀린다. 같은 원인의 불량이 계속 나온다 계측 : 야간 발생 건의 처리 착수 시각	회발 판단 근거가 사람 머릿속에 남아 담당자가 바뀌면 처음부터 본다 계측 : 담당 교체 후 재조사 건
--	--	---	---

2. 기존 대안으로는 해결되지 않는다

사내 LLM API ⊗ 사내 DB 도 이미지도 못 본다. 우리 데이터로 정확해질 경로가 없다	사내 공용 RAG ⊗ 적재는 사내 API 로 된다. 손잡이가 tokenizer 하나뿐이다 — 반도체 사전 등록·용어 병기·메타 필터가 안 된다
BI·대시보드 ⊗ 불 화면을 늘릴 뿐 판단을 대신하지 않는다	규칙 기반 SPC 알람 → 이상이다까지만 말한다. 트리거 입력으로 그대로 쓴다

3. 현업 관점의 중요도 - 상시·대량 업무이고, 오판 비용이 크다



오판 비용 : 진성을 놓치면 유출·클레임, 가성을 Hold 하면 라인 정지 — 판정 1건이 수율·TAT 에 직결된다. 오탐이 잦으면 현업이 알림을 꺼 시스템이 사장된다.

4. 지금 시작해야 하는 이유

✓ 판정 이력·Inform Note 학습 자산으로 쓸 만한 양에 도달했다
✓ 공개 모델 사내에 들릴 수 있는 모델이 성숙했다
✓ 설계·검증 체계 회귀 러너·recall 실측까지 서 있다



지금 시작


Process
재설계

1. 대상 E2E Process - 코어는 하나, 입구는 둘 (예시 : PHOD03 CD 급등)


입구 ① Chat - 엔지니어 질문	입구 ② 무인 감지 - SPC 알람 트리거로 기동
---------------------	--------------------------------

adapter → 증상 분류	investigator → 도구 호출	judgment → 검증 5 척	action → 조치안	answer → 근거 인용	register 확정(사람)
인지	조사	판정	조치 결정	보고	이력 등록

※ 붉은 칸 이 아래 업무 5 단계를 대신한다. 승인과 등록 확정은 사람 몫이다.




2. 조치는 다섯 단계로 올라간다 - 마지막 단계가 자동조치다




승인 이력이 쌓인 시나리오만 개별 심의로 자동조치에 올린다. 승격 뒤에도 전건 사후 리뷰한다. 설비 제어성 조치는 2차년에도 사람 승인 대상이다.

3. 단일 기능 개선이 아니다 - 시작·중간·끝을 모두 바꿨다



4. 현업 활용과 확산 - 현업 노하우가 등록되어야 자라는 구조다



확산 표준안 = 조사 코어 + 공정별 조사규칙 템플릿 + 골든셋 구축 절차

2 차년 통과 조건 - 코어 변경 0 · 반려율 상승 없음. 코어는 공정을 모른다 - 늘어나는 것은 조사규칙 문서와 색인이지 모델이 아니다. 공정이 3 개로 늘어도 추가 자원을 요청하지 않는다.

현업 몫 - 조사규칙 초안(3Q · 공정 담당 엔지니어) · 조치 승인 · 반려(상시) · 골든셋 확정(분기).

현업 점점 - 무인 감지 건은 야간 · 주말에도 교대자에게 통보되고, L2 이상은 승인 전 미실행이다. 오답이 잦으면 아무도 안 본다 - 이벤트 그룹핑으로 알람 빈도를 조정한다. 조회는 정보계 경유 · 전용, 1Q 통과 조건이다.


III. Tech

기술적 해결 방안

1. 왜 AI Agent Orchestration 이어야 하는가

- 조사 순서를 미리 정할 수 없다 : 무엇을 다음에 볼지가 사안마다 다르다. 규칙으로 쓰면 분기가 폭발하고 새 공정마다 발산한다.
- 한 사안에 이중 모달이 섞인다 : 시계열 · 이미지 · 문서 · 정형 DB 를 함께 봐야 한다. 단일 ReAct 한 덩어리로 두면 도구 선택이 서로를 방해한다.
- 정답이 라벨이 아니라 근거를 갖춘 설명이다 : 분류 모델은 Hold/Release 를 찍을 뿐 왜인지를 내지 못한다. 판정은 결론보다 근거가 감사 대상이다.
- 임계 기판으로는 안 걸린다 : 임계 아래로 완만히 흐르는 shift 는 못 잡는다.

2. 오케스트레이션 구성 - 마스터 Agent 가 전문 Agent 와 사내 시스템을 부린다



근거 사슬 - LLM 이 지어낸 자리가 없다

불량 이미지 투입

- ↳ 유사도 검색 후보만 좁힌다. 여기서 확정하지 않는다
- ↳ 메타 · 경로 키 이 키가 그 사고를 특정한다
 - ↳ 사고 RDB 현업이 기입한 원본 - 원인 · 조치가 여기 있다
 - ↳ 보고서 원문 경로로 찾아 읽고 그 문장을 인용한다

※ 계획이 아니다 - 질의 재작성, 하이브리드 검색, cross-encoder 리랭커, 재검색 루프가 선행 프로토타입에서 돈다.

설계 결정 : 계산은 시스템, 연결은 LLM / 검증기 통과분만 채택 / 조치는 권한별 승인 / 등록은 현업 확정분만.

3. 도구 구성의 근거 - 하나씩 붙여 답이 어떻게 달라지는지 비교했다

예시 시나리오 한 건 - 02:14 CD +0.8nm 급등에 대한 답을 도구별로 비교했다.

기본 LLM	02시부터 급등 — 시점 없음
+ Trend Agent	02:14 CD +0.8nm — 시점·변화량
+ Image Agent	Map edge 국부 집중 — Focus 편차형
+ 유사사례 검색	PHOD01 동일 패턴 — Scanner Focus 드리프트
+ 설비 이력 조회	PM 직후 재보정 누락 — 원인 확정
+ 조치 생성	근거 3종 인용 — 진행 금지·조치 코드

도구를 하나 빼면 답이 어느 단계로 후퇴하는지가 그대로 보인다.

SQL 5
get_spc_trend · commonality_analysis · get_master_info
· get_interlock_history · search_fab_data

Vision 2
classify_wafer_map ·
analyze_defect_image

RAG 1
search_inform_notes

조회 전용 — 통계·공통성 분석은 코드가 계산한다. 마스터 Agent 가 사안마다 골라 5~15회 부른다

기술적 해결 방안

4. 알고리즘 선택 근거

코어	GLM-5.2 743B-A39B 판단·tool call·코딩을 한 모델에 묶는다 □ 역할별 모델 분리 — 문맥·캐시 공유가 깨진다	ReAct 루프 (LangGraph) 결과를 보고 다음 도구를 정한다 □ 고정 파이프라인 — 분기가 폭발한다	
	PatchTST + CUSUM/BOCPD 변화점은 코드가 찍는다 □ LSTM·Prophet — 변화 시점을 못 찍는다	ConvNeXt V2 라벨 있는 불량은 분류로 끝낸다 □ VLM — 낭비다	PatchCore + WRN-50-2 거리 기반. 확신 낮으면 미지로 반환 □ 분류 모델 — 라벨 없으면 못 잡는다
감지	Qwen3.5-397B-A17B · Qwen3.6-35B-A3B 정밀 판독은 대형, 상시 감시는 경량 □ 한 모델 통일 — 요구 정밀도가 다르다	Qwen3 Embedding · Reranker 임베딩·리랭커를 튜닝할 수 있는 계열이다 □ 임베딩 단독 — 설비 ID 를 놓친다	Qwen3-VL-Embeddin 메타·경로 키 로 RDB 에서 확정한다 □ 유사도로 확정 — 후보만 좁힌다
	판독·검색		

모델마다 버린 대안이 있다 — 성능이 아니라 자리에 맞춰 골랐다

5. 그럴듯한 오답은 코드가 걸러낸다 - 다섯 관문



※ 탈락하면 재생성하고, 계속 실패하면 판단 불가로 강등해 사람에게 넘긴다. 도구 호출이 잘못되면 판단 이전에 구조 전체가 흔들린다 - 1 차년 1Q 최우선 검증 대상이다. 구조화 출력 재시도 래퍼를 두고, 반복 실패하면 라우팅만 규칙 기반으로 돌린다.

6. 성능 지표와 배포 게이트

recall@10 0.500 골든 4건 → 30건 확장 예정 · 색인 50건 · 회귀 러너 실측 — 회귀 검출용 기준선이다	0 건으로 관리한다 ■ 근거 없는 판단 채택 ■ 미승인 L2 조치 실행 ■ 무인 접수 누락 검증기 차단 로그와 감사 로그로 센다
--	--

- 판정 정답률은 그림자 운영 실측 뒤에 정한다 - 임의의 퍼센트를 지금 적지 않는다. 일치율(AI 판단 대 엔지니어 판단, 조치 미실행) · recall@10 · 처리 시간 · 반려율이 떨어지면 배포를 막는다.

7. 알고리즘 개선을 위해 수행한 과정

문서 1 건 → 세 층 분기(서로 참조 금지) · 하이브리드 후보 200 → 리랭커 상위 20
 └ content 원문 그대로 - 답변이 인용할 원본
 └ embedding 용어 병기 확장문을 임베딩한다
 └ search_tsv ID 보호 → 형태소 → 품사 필터. PHOD03 은 통째로 지킨다

- 색인 5,291 청크 / 103 문서 규모로 선행 프로토타입을 검증했다. 다음은 Qwen3 임베딩 · 리랭커 교체와 재측정이다.
- 환각 발생원 제거 : 통계 · 공통성 분석 · map 분류 · SQL 을 코드로 옮기고 LLM 에는 결과만 넘겼다. 숫자를 지어낼 자리가 구조적으로 없다.
- 재학습 : 대상은 검색기 임베딩 · 리랭커다. 라벨은 현업이 확정판정 이력과 Inform Note 다. 결합 가중치는 실측으로 BM25 등가중이 최적이다. 월 4 회 돌려 골든셋 회귀 통과분만 배포한다.

※ 선행 프로토타입 실측 - 26 질의 hit@1 1.000. 하드셋 38 질의(패러프레이즈 · 교차언어 · distractor) 0.957. 검색기 계열이 다르다 - Qwen3 재측정.

IIII. 경영효과

예상 성과 산출식이 명시된 예상 성과다. 기준 4시간 · 목표 2시간은 실측 전 가정이다.

유형 효과 (정량)

200억

원 / 년

확산 완료 후 1,000명 전면 적용

57.5배

연간 ROI

투자 347,794,165원 대비

6.3일


투자 회수

2개년 총투자 기준 12.7일

[(개선 전 4h ÷ 8h) - (개선 후 2h ÷ 8h)] × 연봉 80,000,000원 × 1,000명 = 연 200억 원
 연봉 80,000,000원 = 사내 산정 기준값 · 1,000명 = 제조기술센터 품질·공정 엔지니어
 4h → 2h 는 실측 전 가정 — 그림자 운영 로그로 대체한다

- 200 억은 인원 감축이 아니라 판정 업무 시간을 사내 산정 기준 연봉으로 환산한 값이다. 투자는 연 347,794,165 원이다. 1 차년은 포토 1 개 공정 실측 구간이라 효과를 계상하지 않는다.

※ 이 표는 절감폭만 혼든다. 기준 4시간은 그림자 운영 로그로 실측해 대체하며, 실측이 낮으면 효과도 같은 비율로 내린다.



무형 효과 (정성)

야간 조사 공백

야간·주말에 생긴 이상도 그 자리에서 조사된다 (처리 착수 시각)

판단 편차 축소

같은 현상에 같은 조사 경로가 적용된다 (일치율)

감사 대응력

판정마다 근거 원문·신뢰도·모델 버전이 남는다

노하우 자산화

조사규칙·Inform Note 로 남아 사람에게 안 묶인다

타 조직 이관

확산 표준안으로 코어를 그대로 넘긴다

선행 추진 실적 - 백지에서 시작하지 않는다

구현

검증기 5척

조사 코어 스케레톤 실행 확인 · prod 백엔드 4중

평가

recall@10 0.500

골든 4건 / 색인 50건 · 회귀 러너 실측

선행 프로토타입

AMI 0.956 · ARI 0.860

불량 이미지 임베딩 군집 지표. 노이즈 0.52% (43 class · 900 wafer). agentic RAG 전 요소와 이미지 유사 검색·메타 키 조회가 돈다

설계

31종

시스템설계서 · 로드맵 · Tool 카탈로그 · 그라운드링 · 조사규칙

요소 기술은 자체 실측으로 확인했다. 남은 것은 실데이터 연결과 그림자 운영 검증이다.

검증 방법

2Q 그림자 운영

조치 미실행. 공정 담당 엔지니어 판정을 정답으로 두고 일치율 기준선과 4시간 가정을 실측한다

조치 미실행

4Q 무인 접수

처리 시간·이벤트 누락·조치 승인율을 분기마다 보고한다

2주 연속 누락 0건

2차년 자동조치 개방

시나리오 단위로만 연다. 승인율·오탐율이 기준을 넘는 시나리오를 개별 심의하고, 승격

전건 감사