

AX Award 지원서

I. 개요

지원부문	제조 AX 부문		
팀 / 그룹	제조기술센터 품질기술그룹	대표자	홍길동
제목	완전한 품질 AI Agent Orchestration 구축 - 감지부터 판단·조치·자동조치까지 스스로 수행하는 살아있는 품질 관리 시스템		
적용시점	2026-09-01 ~ 2028-08-31 (24 개월) - 1 차년 구축·검증 / 2 차년 확산·자동화		
형전개 범위	1 차년 포토 1 개 공정 → 2 차년 etch·CMP 3 개 공정 → 품질·공정 엔지니어 약 1,000 명 · DRAM·NAND 전 제품군. 확산 표준안으로 타 조직 이관.		

II. Process

문제 정의	1. 새벽 이상 1건의 실제 동선 - 검출은 2초, 그러나 원인을 아는 사람이 없었다  이 판정 하나에 필요한 지식은 셋이다 - ① 이 item의 trend 이력 ② 직전 변경점(PM·레시피·자재) ③ 같은 조합에서 과거에 났던 불량. 새벽·주말 취약시간에는 ②③을 아는 사람이 현장에 없다. 그래서 단순 파라미터 보정으로 trend만 스펙 안으로 되돌리고 넘어간다. 숫자는 정상처럼 보이지만 원인은 그대로 남는다 - 같은 불량에 재발·확산된 뒤에야 주간에 드러난다. 이것이 매번 반복되는 사고의 전형이다. 02:14→08:30 무대응 공백 6h - 야간 알람은 "이상이다"에 서 멈춘다 인수·파악 - 전달 손실 교차 조사 4h+ - SPC·YMS·MES·EngrNote 수집 화면 수 등 대조 보고·결재 - 회 의·품의 16시가 되어야 lot 처리가 결정된다. 특별한 사고가 아니라 매일의 기본 동선이다. 단계 시간은 산정치 - 가동 후 처리 시간 로그로 실측 보정. 2. 동선 안에 반복되는 구조 결함 4 - 측정 가능한 문제로 적는다 조사 공수가 크다 - 판정 한 건에 SPC·MES·YMS·EngrNote 를 다 띄워놓고 손으로 대조한다. 반나절짜리 공수가 매일 반복 된다 · 계측: 건당 처리 시간 판단이 상향 평준화되지 않는다 - 같은 trend를 봐도 베테 랑과 신임의 결론이 다르다. 기준이 시스템이 아니라 사람 머릿 속에 있다 · 계측: 동일 현상 판정 일치율 취약시간에 사고가 난다 - 야간·주말엔 변경점·과거 사례를 아는 사람이 없어 trend만 맞추는 임시 대응이 나온다 · 계측: 발생→조사 착수 시각차 기록 없이 각자 알아서 변경한다 - 근거가 문서로 안 남아 개 인 판단으로 보정하고 지나간다. 담당이 바뀌면 같은 조사를 처 음부터 · 계측: 담당 교체 후 재조사 건수 3. 기존 대안 검토 - 셋은 기각, 하나는 트리거로 편입 <table><tr><td>사내 LLM API</td><td>기각</td><td>질문을 넣으면 일반 지식으로 답할 뿐 - SPC·MES 조회, Map·SEM 판독, 변경점 대조를 할 손 이 없다. 물어보는 사람의 지식만큼만 나온다</td></tr><tr><td>사내 공용 RAG</td><td>기각</td><td>문서를 통째로 벡터로 넣는 구조 - 설비 ID·공정 약어가 임베딩에서 뭉개져 검색 정확도가 낮고, 반도체 사전·용어 병기·메타 필드 같은 손잡이가 없다</td></tr><tr><td>BI·대시보드</td><td>기각</td><td>보는 화면만 늘어난다 - 대조·판단·조치는 여전히 사람 공수로 남는다</td></tr><tr><td>규칙 기반 SPC 알람</td><td>편입</td><td>spec-rule 기반이라 정해진 임계만 잡는다 - 완전한 drift·복합 이상은 통과. 상시 감지는 Trend Agent가 대신하고, SPC 알람은 무인 기동 트리거로만 쓴다</td></tr></table>		사내 LLM API	기각	질문을 넣으면 일반 지식으로 답할 뿐 - SPC·MES 조회, Map·SEM 판독, 변경점 대조를 할 손 이 없다. 물어보는 사람의 지식만큼만 나온다	사내 공용 RAG	기각	문서를 통째로 벡터로 넣는 구조 - 설비 ID·공정 약어가 임베딩에서 뭉개져 검색 정확도가 낮고, 반도체 사전·용어 병기·메타 필드 같은 손잡이가 없다	BI·대시보드	기각	보는 화면만 늘어난다 - 대조·판단·조치는 여전히 사람 공수로 남는다	규칙 기반 SPC 알람	편입	spec-rule 기반이라 정해진 임계만 잡는다 - 완전한 drift·복합 이상은 통과. 상시 감지는 Trend Agent가 대신하고, SPC 알람은 무인 기동 트리거로만 쓴다
사내 LLM API	기각	질문을 넣으면 일반 지식으로 답할 뿐 - SPC·MES 조회, Map·SEM 판독, 변경점 대조를 할 손 이 없다. 물어보는 사람의 지식만큼만 나온다												
사내 공용 RAG	기각	문서를 통째로 벡터로 넣는 구조 - 설비 ID·공정 약어가 임베딩에서 뭉개져 검색 정확도가 낮고, 반도체 사전·용어 병기·메타 필드 같은 손잡이가 없다												
BI·대시보드	기각	보는 화면만 늘어난다 - 대조·판단·조치는 여전히 사람 공수로 남는다												
규칙 기반 SPC 알람	편입	spec-rule 기반이라 정해진 임계만 잡는다 - 완전한 drift·복합 이상은 통과. 상시 감지는 Trend Agent가 대신하고, SPC 알람은 무인 기동 트리거로만 쓴다												

문제 정의
(계속)

4. 왜 중요한가 — 상시·대량 업무이고, 오판 비용이 비대칭으로 크다

4h
/ 근무 8h

근무의 절반이 판정 조사·대조에 쓰인다 [가정
— 로그로 실측 대체]

× 약 1,000명
만 명 규모 제조 조직의 품질·공정 엔지니어 전원의 매일 업무

전성 능력 **가성 Hold**

불량 유출

후공정·클래임 증폭

라인 정지

수출 TAT 직접 손실

어느 쪽으로도 기울일 수 없다

오판 비용이 **양쪽** 다 크다. 그래서 판정은 낮고 보수적이 된다 — 사람이 시간을 더 쓰는 이유가 게으름이 아니라 **비용 구조**다. 시스템도 같은 함정을 밟는다: **오탐이 잦으면 현업이 알람을 꺼 사장된다** — 알람 신뢰를 관리 지표로 둔다.

5. 왜 지금인가

① **데이터 자산 일체 도달** — 사고 이력 RDB·EngrNote·문서저장소 ·SPC/MES/YMS/EES/QMS가 학습·검 색 자산으로 쓸 양에 도달

② **공개 모델 성숙** — 사내 반입 가능한 모델이 판단·판독 요구 수준에 도달

③ **검증 체계 완비** — 회귀 러너 ·recall 실측까지 서 있다. 백지 출발이 아니다

지금 시작

Process
재설계

1. E2E 전체 대체 — 6단계 업무가 무엇을 받아 무엇을 내는지까지 설계했다



2. 조치 권한 승격 구조 — 무엇을 실행하고, 누가 확정하고, 무엇을 넘어야 올라가나



3. 시작·중간·끝이 모두 바뀐다 — 끝이 다음 시작을 키운다



4. 현업 활용·확산 — 코어는 그대로, 조사규칙과 색인만 늘린다

- **확산 표준안** = 조사 코어 + 공정별 조사규칙 템플릿 + 골든셋 구축 절차. 2차년 통과 조건 — 코어 변경 0 · 반려율 상승 없음. 공정이 3개 로 늘어도 추가 자원을 요청하지 않는다.
- **현업 룰** — 조사규칙 초안(3Q·공정 담당) · 조치 승인·반려(상시) · 골든셋 확정(분기). 노하우가 등록될수록 시스템이 그 팀에 맞게 자란 다. 오탐 남발은 이벤트 그룹핑·수신자 피드백으로 조정(조치는 정보계 경유 전용 — 1Q 통과 조건).



III. Tech



1. 왜 Agent Orchestration 인가 — 규칙·분류기·단일 LLM이 각각 실패하는 지점

조사 순서를 미리 못 정한다 — 다음에 볼 데이터가 직전 결과에 따라 달라진다. 고정 파이프라인은 분기가 폭발한다.

이중 모델이 한 사안에 섞인다 — 시계열·이미지·문서·정형 DB. 각 모델은 전용 모델이 정확하고, 종합은 LLM이 한다.

정답이 라벨이 아니라 근거 있는 설명이다 — 분류기는 Hold/Release만 찍는다. 판정은 결론보다 근거가 감사 대상이다.

임계 기반으로는 안 걸린다 — 임계 아래로 완만히 흐르는 shift는 규칙 알람이 못 잡는다. 변화점 검정이 필요하다.

2. 아키텍처 — Router가 결과를 보고 다음 도구를 정하는 tool calling 루프



3. 무엇이 새로운가 — 이 설계의 기술적 신규성 셋


01 **검증 게이트 오케스트레이션**
채택 조건이 "그럴듯함"이 아니라 코관 통과다. 탈락은 판단 불가로 강등 — 침묵 실패가 구조적으로 없다.

02 **2단 확정 검색**
유사도는 후보 생성까지만 — 확정 메타·경로 키의 RDB 조회. 벡터의 모호함이 인용·판정에 유입될 수 없다.

03 **업무가 곧 라벨링인 페루프**
승인·수정·반려가 그대로 학습 라벨 — 별도 라벨링 조직 없이 SFT·선호학습(DPO-KTO)·검색기 파인튜닝이 월 4회 돈다.

4. 전문 모델의 밑단 — 이미지·Trend 두 갈래 모두 자체 개발로 이미 돌고 있다

이미지 · unknown-contrastive — 라벨 없이 배우는 대비학습 무라벨 SEM-Failbit 이미지 쌍으로 같은 것은 가깝게, 다른 것은 멀게 (InfoNCE — Global-Local-Queue-위음성 필터 4부품). ConvNet V2+TAPT, 384² → 128-d 좌표. 사고 대표는 **클래스당 30장 평균 anchor**, 운영 확정은 **composite map·멤버 이미지 육안** — 지표가 육안을 대체하지 않는다.



Trend · anomaly-detection — 라벨 한계를 생성 데이터로 돌파 실패데이터에 라벨이 없는 불량 구간을 **합성 주입** (mean_shift-drift-spike-level_step 등)해 학습하고, 현업이 불량으로 오인하던 **복귀형 파형은 정상 클래스에 추가** — "우측 끝이 깨끗한가"로만 갈리게 설계했다.

1단 양·불 전용 감지 모델 — 판정 범위를 좁혀야 감지 성능이 최대가 되므로, 여기서는 양불만 가른다

2단 LLM 판독 — 변경점 이력은 프롬프트로, trend 원값은 JSON(장 구간은 일 평균 다문생물)으로 투입 → **변화 시점 특정 + 어원 설비 작업과 연관인지까지 연결한다**

운영 장치 — Grad-CAM으로 모델이 본 구간을 시각 근거로 남기고, AUROC-임계스윙(FN/FP 표)으로 게이트 기준을 잡으며, 현업 CSV 추가학습으로 라인별 적응한다.

기술적
해결 방안
(계속)

5. 실행 트레이스 두 갈래 — 데이터가 실제로 이렇게 흐른다 (호출 → 틀 내부 동작 → 반환값 → 프롬프트 적재)

A · 불량 이미지(EDS-SEM) 진입 — 유사도 → 경로:meta → 문서

입력 eds_0731.png 첨부 — "이 불량 뭐지? 과거 유사 사사 있었나?"
스택 = [system · 도구 스키마 10층 · 판정서 스키마]

1 Router "이미지가 있으니 유사도부터" →
analyze_defect_image(img)
틀 내부 — contrastive 384→128-d L2 → 사고 이미지 스토리지 걸러리 코
사인 top-10 → 임계 0.82 것
↳ {top1:edge_ring, sim:0.93, incident:PHOD01-2847,
path:/rpt/2847.pptx}
스택 += 판독 라벨 · 이미지 경로 · meta 키

2 Router "경로:meta 나왔으니 그 키로 문서" →
search_engr_notes(meta)
틀 내부 — ① meta 조회로 참조 문서 먼저 선택 ② 그 안에서만 tsvector ||
halfvec ③ RRF 융합 ④ 리랭크 top-20
스택 += 참조문서 3건 · 인용 원문 문장

3 Router "원인·대책 원본 필요" (필요시) →
get_incident("PHOD01-2847")
↳ {규모:lot 3 · 피해:yield -1.2% · 원인:대책·잠못된 점}
스택 += 사고 원장 행 — 담당 엔지니어가 직접 쓴 확정 필드

4 병렬 Trend · 사내 DB · Eng'r Inform 동시 호출 (서로 독립이라 병렬)
스택 += Trend 반환 · 설비 이력 — 과거 원인이 어떤 설비에서 재현됨을 교차
확인

종료 근거 3층 확보 · 미결 질문 없음 → 도구 루트 종료, Q/A 역할로 인계

B · 사고 문의·알람 진입 — 원장 → meta 선택 → 문서

입력 SPC 알람 {param:CD, lot:L42, Δ:+0.8nm, t:02:14} 또는 "이
사고 어떻게 됐었나" 질문

1 Router "사고 건이므로 원장이 첫 조회 — 검색이 아니라 조회다" →
search_incidents(drift, PHOD)
틀 내부 — 담당 엔지니어가 손으로 쓴 RDB: 사고명·규모·피해·원인·대책·
조치·잠못된 점. **신뢰 최상이라 여기부터**
↳ {2847: 원인 PM 후 재보정 누락 · 대책 offset -0.4 · yield
-1.2%}
스택 += 사고 원장 행 (확정 사실)

2 Router 사고명·meta로 참조 문서 선택 →
search_engr_notes(meta) — A의 2단계와 동일 경로 (진입만 다르
다)
스택 += 참조문서 · 인용 원문

3 Trend Agent 2-stage — 1단 양·불 게이트, 2단 LLM이 변경점 이력 +
일평균 JSON 판독
↳ {변화점 02:14, drift행, 6/28 PM 연관 의심}
스택 += 변화 시점·변화량·연관 작업

4 사내 DB Agent get_interlock_history(SCN-07) ↳ PM 06/28
후 재보정 기록 없음
스택 += 설비 이력 — 가설이 실제 이력과 맞물림

종료 근거 부족 시 최대 3회 재검색, 그래도 모자라면 "확인 불가"를 스택에 적
고 넘긴다

역할별 temperature — 같은 엔진, 다른 온도

Router LLM · T = 0

내는 것 — 도구 이름 + 인자 JSON (문장이
아니다)
온도를 조금만 줬도 72h가 48h로, lot 범위가
다른 값으로 흔들려 같은 사건에 다른 조사 경
로가 나온다 — 감사에서 재현이 안 되면 판정
이 무효다
top_p 1.0 · seed 고정 — 호출 시킨스
재현

Q/A LLM · T ≈ 0.3

내는 것 — 스택을 읽고 쓴 문장 (판정서 서술)
argmax인 이으면 표현이 굳어 원인이 달라도
서술이 안 갈린다. 0.3은 서술만 풀어주는 폭
— 수치·사고번호·인용문은 스택에서 복사하
므로 온도가 값을 못 혼돈다
top_p 0.9 · 세는 건 검증기 @ 사실 대조
가 잡는다

최종 Q/A 호출에 실제로 들어가는 것 — 4층 스택

- ① 고정층 — system:조사규칙·판정서 스키마 (프릭스 케이스 적용)
- ② 사건층 — 질문 원문 또는 알람 JSON · 첨부 이미지 행들
- ③ 증거층 — 도구 반환 누락 5~15회: 원장 행 · 참조문서 인용 ·
판독 라벨 · Trend · 설비 이력 ← 사건마다 자라는 층
- ④ 출력 지시층 — 스택 밖 사실 금지 · 수치는 반환값 그대로
복사 · 근거 3층 · 부족분은 "확인 불가"

↓ Q/A LLM T 0.3 → 판정서 → 검증기 5회

답의 수준은 모델이 아니라 스택이 정한다 — 3단계를 빼면 "과거에 비슷한 게 있었
다"에서 멈추고, 4단계를 빼면 "이번 설비가 그랬는지"를 못 쓴다.

6. 조치한 출력 — 무엇을 얼마나 바꿀지, 한도와 사이드 이펙트까지가 한 세트다

판정서 #Q-1042 · PHOD03 CD drift

신뢰도 High · 근거 3중 · L3 권고

원인 — Scanner SCN-07 Focus 드리프트 (PM 06/28 후 재보정 누락 · 과거
PHOD01-2847 동일 패턴)

조치 — Focus offset -0.4 재보정 권고 | **가드: 1회 변경 한도** | Δ| ≤ 0.5 · PM 주기
당 1회 · 한도 초과 입력은 자동 반려

사이드 이펙트 — 과보정 시 center CD 역방향 shift 위험 → 모니터 lot 2매 선행 확인
후 분류 적용


근거 인용 — ① Trend {02:14, +0.8nm} ② Map edge_ring 0.92 ③ PHOD01-
2847 보고서 p.14 조치 문장

● 조치가 곧 명령이 아니다 — 파라미터 가드(변경량 상
한·횟수 제한·되돌림 가능성)을 조치 등급표가 강제한다.
"많이 바꾸는" 답은 구조적으로 못 나간다.

● 근거 사슬이 실물에 닿는다 — 유사도는 후보만, 확정
은 메타·경로 키로 RDB에서. 인용은 원문 문장 그대로.

7. Agent를 하나씩 열어줄 때마다 답이 자란다 — 프롬프트에 무엇이 들어가 답이 어떻게 달라지나

(ablation · 같은 사례 실측)



최종 프롬프트 스택 = system(조사규칙·판정서 스키마) + 사건 카드 + tool 반환 JSON 5~15개 + 인용 원문 발췌 — 이 스택 전체가 판정서 생성의 입력이다. 답의 수
준 차이는 모델이 아니라 스택에 쌓인 증거의 차이다.

원장 2 사고 건이면 여기가 1번

search_incidents ·
get_incident

SQL 5 get_spc_trend ·
commonality_analysis ·
get_master_info ·
get_interlock_history ·
search_fab_data

Vision 2

classify_wafer_map ·
analyze_defect_image


RAG 1

search_engr_notes

도구는 조회 전용 — 통계·공통성 분석은 코드가 계산한다. 도구를 하나 빼면 답이 어느 단계로 후퇴하는지가 그대로 보인다.

기술적
해결 방안
(계속)

8. 그럴듯한 오답은 코드가 거른다 — 다섯 관문



관문을 지날수록 통로가 좁아진다 — **점록 실패가 없다**, 모르는 것은 모른다고 적는 것까지가 관문이고, 반복 실패는 사람에게 넘어간다.

9. Agentic RAG 설계 — 사람이 정리한 사고 DB가 항상 먼저고, 확정은 키 조회다



10. 지표는 실측으로만 — 임의의 %를 지금 적지 않는다

회귀 기준선 · recall@10

0.500

골든 4건→30건 확장 예정 · 색인 50건 · 회귀 러너 실측

0건으로 관리한다

● 근거 없는 판단 채택 ● 미승인 L2 조치 실행 ● 무인 접수 누락 — 검증기 차단 로그·감사 로그로 센다

선행 프로토타입 실측

26질의 hit@1 **1.000** · 하드셋 38질의 **0.957** · 군집 품질 AMI **0.956**/ARI 0.860 — Qwen3 교체 후 재측정

판정 정당률은 그림자 운영 실측 뒤 확정한다. 일지율(AI 대 엔지니어 판정)·recall@10·처리 시간·반려율이 떨어지면 배포를 막는다.

IIII. 경영효과

예상 성과

200억 원/년

판정 업무 시간 환산 가치 — 확산 완료 후 1,000명 적용 시

57.5배

연간 ROI — 투자 연 347,794,165원 대비

6.3일

투자 회수 — 2개년 총투자 기준 12.7일

[(개선 전 4h ÷ 8h) - (개선 후 2h ÷ 8h)] × 연봉 80,000,000원 × 1,000명 = 연 200억 원

연봉 8,000만 = 사내 산정 기준값 · 인원 감축이 아니라 시간의 환산 가치 · 1차년은 실측 구간이라 효과 미계상 · 4h→2h는 실측 전 가정, 그림자 운영 로고로 대체

2.0h (목표) 57.5배 · 200억

2.5h 43.1배 · 150억

3.0h 28.8배 · 100억

3.5h 14.4배 · 50억

민감도 — 실측이 낮으면 같은 비율로 하향. 절감이 반이여도 ROI 14배.

구현

검증기 5칙 가동
조사 코어 스텝레온 실행 · prod 백엔드 4종

평가

recall@10 0.500
골든 4건/색인 50건 · 회귀 러너 실측

선행 프로토타입

군집 품질 AMI 0.956 · ARI 0.860
노이즈 0.52% · 43 class-900 wafer — RAG 전 요소·유사 검색·메타 키 조회 가동

설계

설계 문서 31종
시스템설계서·로드맵·Tool 카탈로그·조사규칙

2Q 그림자 운영 (조치 미실행)
공정 담당 판정을 정답으로 일치를 기준선-4h 가장 실측

4Q 무인 접수 (2주 연속 누락 0건)
처리 시간·누락·조치 승인을 분기 보고

2차년 자동조치 개방 (전건 감사)
승인율·오타를 기준 넘은 시나리오만 개별 심의 승격

● **야간 공백 해소** — 야간·주말도 그 자리에서 조사 (착수 시각)

● **판단 편차 축소** — 같은 현상에 같은 조사 경로 (일치율)

● **감사 대응력** — 근거 원문·신뢰도·모델 버전이 판정마다 남는다

● **노하우 자산화** — 조사규칙-EngrNote로 남아 사람에 안 묶인다

● **타 조직 이관** — 확산 표준안으로 코어를 그대로 넘긴다