

AX Award 지원서

I. 개			
지원부문	제조 AX 부문		
팀 / 그룹	제조기술센터 품질기술그룹	대표자	홍길동
제목	완전한 품질 AI Agent Orchestration 구축 — 감지부터 판단·조치·자동조치까지 스스로 수행하는 살아있는 품질 관리 시스템		
적용시점	2026-09-01 ~ 2028-08-31 (24개월) — 1차년 구축·검증 / 2차년 확산·자동화		
형전개 범위	1차년 포토 1개 공정 → 2차년 etch·CMP 3개 공정 → 품질·공정 엔지니어 약 1,000명 · DRAM·NAND 전 제품군. 확산 표준안으로 타 조직 이관.		

II. Process

문제의 정의

1. 새벽 이상 1건의 실제 동선 — 검출은 2초, 그러나 원인을 아는 사람이 없었다

이 판정 하나에 필요한 지식은 셋이다 — ① 이 item의 trend 이력 ② 직전 변경점(PM·레시파·자재) ③ 같은 조합에서 과거에 났던 불량.

새벽 주말 취약시간에는 ②③을 아는 사람이 현장에 없다. 그래서 단순 파라미터 보정으로 trend만 스펙 안으로 되돌리고 넘어간다. 숫자는 정상처럼 보이지만 원인은 그대로 남는다 — 같은 불량이 재발·확산된 뒤에야 주간에 드러난다. 이것이 매번 반복되는 사고의 전형이다.

2. 동선 안에 반복되는 구조 결함 4 — 측정 가능한 문제로 적는다

조사 공수가 크다 — 판정 한 건에 SPC·MES·YMS·EngrNote를 다 띄워놓고 손으로 대조한다. 반나절짜리 공수가 매일 반복된다 · 계측: 건당 처리 시간

취약시간에 사고가 난다 — 야간·주말엔 변경점·과거 사례를 아는 사람이 없어 trend만 맞추는 임시 대응이 나온다 · 계측: 발생→조사 착수 시각차

판단이 상향 평균화되지 않는다 — 같은 trend를 봐도 베테랑과 신임의 결론이 다르다. 기준이 시스템이 아니라 사람 머릿속에 있다 · 계측: 동일 현상 판정 일치율

기록 없이 각자 알아서 변경한다 — 근거가 문서로 안 남아 개인 판단으로 보정하고 지나간다. 담당이 바뀌면 같은 조사를 처음부터 · 계측: 담당 교체 후 재조사 건수

3. 기존 대안 검토 — 셋은 기각, 하나는 트리거로 편입

사내 LLM API	기각	질문을 넣으면 일반 지식으로 답할 뿐 — SPC·MES 조회, Map·SEM 판독, 변경점 대조를 할 손이 없다. 물어보는 사람의 지식만큼만 나온다
사내 공용 RAG	기각	문서를 통짜 벡터로 넣는 구조 — 설비 ID·공정 약어가 임베딩에서 뭉개져 검색 정확도가 낮고, 반도체 사전·용어 병기·메타 필터 같은 손잡이가 없다
BI·대시보드	기각	보는 화면만 늘어난다 — 대조·판단·조치는 여전히 사람 공수로 남는다
규칙 기반 SPC 알람	편입	spec·rule 기반이라 정해진 임계만 잡는다 — 완만한 drift·복합 이상은 통과. 상시 감지는 Trend Agent가 대신하고, SPC 알람은 무인 기동 트리거로만 쓴다

문제 정의
(계속)

4. 왜 중요한가 — 상사·대량 업무이고, 오판 비용이 비대칭으로 크다



근무의 절반이 판정 조사·대조에 쓰인다 [가정
— 로그로 실측 대체]

× 약 1,000명

만 명 규모 제조 조직의 품질·공정 엔지니어 전원의 매일 업무



오판 비용이 양쪽 다 크다. 그래서 판정은 낮고 보수적이 된다 — 사람이 시간을 더 쓰는 이유가 게으름이 아니라 비용 구조다. 시스템도 같은 함정을 밟는다. **오판이 잦으면 현업이 알람을 꺼 사장된다** — 알람 신뢰를 관리 지표로 둔다

5. 왜 지금인가

① 데이터 자산 일체 도달 — 사고 이력 RDB·EngrNote·문서저장소 ·SPC/MES/YMS/EES/QMS가 학습·검색 자산으로 쓸 양에 도달

② 공개 모델 성숙 — 사내 반입 가능한 모델이 판단·판독 요구 수준에 도달

③ 검증 체계 완비 — 회귀 러너·recall 실측까지 서 있다. 백지 출발이 아니다


지금 시

Process 재설계


1. E2E 전체 대체 — 6단계 업무가 무엇을 받아 무엇을 내는지까지 설계했다



2. 조치 권한 승격 구조 — 무엇을 실행하고, 누가 확정하고, 무엇을 넘어야 올라가나



3. 시작·중간·끝이 모두 바뀐다 — 끝이 다음 시작을 키운다



4. 현업 활용·확산 — 코어는 그대로, 조사규칙과 색인만 늘린다

- **확산 표준안** = 조사 코어 + 공정별 조사규칙 템플릿 + 골든셋 구축 절차. 2차년 통과 조건 — 코어 변경 0 · 반례를 상생 없음. 공정이 3개로 늘어도 추가 자원을 요청하지 않는다.
- **현업 룰** — 조사규칙 초안(3Q·공정 담당) · 조치 승인·반려(상사) · 골든셋 확정(분기). 노하우가 등록될수록 시스템이 그 팀에 맞게 자란다. 오탐 남발은 이벤트 그룹핑·수신자 피드백으로 조정(조치는 정보계 경유 전용 — 1Q 통과 조건).



III. Tech

기술적 해결 방안



1. 왜 Agent Orchestration 인가 — 규칙·분류기·단일 LLM이 각각 실패하는 지점


조사 순서를 미리 못 정한다 — 다음에 볼 데이터가 직전 결과에 따라 달라진다. 고정 파이프라인은 분기가 폭발한다.

정답이 라벨이 아니라 근거 있는 설명이다 — 분류기는 Hold/Release만 찍는다. 판정은 결론보다 근거가 감사 대상이다.

이중 모달이 한 사안에 섞인다 — 시계열·이미지·문서·정형 DB, 각 모달은 전용 모델이 정확하고, 종합은 LLM이 한다.

임계 기반으로는 안 걸린다 — 임계 아래로 완만히 흐르는 shift는 규칙 알람이 못 잡는다. 변화점 검정이 필요하다.

2. 아키텍처 — Router가 결과를 보고 다음 도구를 정하는 tool calling 루프



3. 무엇이 새로운가 — 이 설계의 기술적 신규성 셋

- 01** 검증 게이트 오케스트레이션

체택 조건이 "그렇듯함"이 아니라 코드 관문 통과다. 탈락은 판단 불가로 강등 — 침묵 실패가 구조적으로 없다
- 02** 2단 확정 검색

유사도는 후보 생성까지만 — 확정 은 메타-경로 키의 RDB 조회. 벡터의 모호함이 인용·판정에 유입될 수 없다
- 03** 업무가 곧 라벨링인 페루프

승인·수정·반려가 그대로 학습 라벨 — 별도 라벨링 조직 없이 SFT·선호 학습(DPO-KTO)·검색기 파인튜닝이 월 4회 돈다.

4. 전문 모델의 밑단 — 이미지·Trend 두 갈래 모두 자체 개발로 이미 돌고 있다

이미지 · unknown-contrastive — 라벨 없이 배우는 대비학습
무라벨 SEM-Failbit 이미지 쌍으로 같은 것은 가깝게, 다른 것은 멀게 (InfoNCE — Global-Local-Queue-위용성 필터 4부품). ConvNeXt V2+TAPT, 384² → 128-d 좌표. 사고 대표는 클래스당 30장 평균 anchor, 운영 확정은 composite map·멤버 이미지 육안 — 지표가 육안을 대체하지 않는다.

Global 6.20% +Local 3.93 +Queue 1.31 +필터 0.52
부품 사다리 실측 — 오직재 6.20→0.52% · 군집 ARI 0.823→0.860 (43 class-900 wafer)

Trend · anomaly-detection — 라벨 한계를 생성 데이터로 돌파
실데이터에 라벨이 없는 불량 구간을 합성 주입 (mean_shift-drift-spike-level_step 등)해 학습하고, 현업이 불량으로 오인하던 복귀형 파형은 정상 클래스에 추가 — "우측 끝이 깨끗한가"로만 길게 설계했다.

1단 양·불 전용 감지 모델 — 판정 범위를 좁혀 감지 성능이 최대가 되므로, 여기서는 양불만 가른다

2단 LLM 판독 — 변경점 이력은 프롬프트로, trend 원값은 JSON(장구 간은 일 평균 다운샘플)으로 투입 → 변화 시점 특정 + 어떤 설비 작업과 연관인지까지 연결한다

운영 장치 — Grad-CAM으로 모델이 본 구간을 시각 근거로 남기고, AUROC·임계 스윙(FN/FP 표)으로 게이트 기준을 잡으며, 현업 CSV 추가학습으로 라인별 적용한다.

5. 실행 트레이스 두 갈래 — 데이터가 실제로 이렇게 흐른다 (호출 → 툴 내부 동작 → 반환값 ← 프롬프트 적재)

A · 불량 이미지(EDS-SEM) 진입 — 유사도 → 경로-meta → 문서

입력 eds_0731.png 첨부 — “이 불량 뭐지? 과거 유사 사고 있었나?”
스택 = [system · 도구 스기마 10중 · 판정서 스기마]

1 Router “이미지가 있으니 유사도부터” →
analyze_defect_image(img)
툴 내부 — contrastive 3842→128-d L2 → 사고 이미지 스토리지 갤러리 코사
인 top-10 → 일계 0.82 컷
“ {top1:edge_ring, sim:0.93, incident:PHOD01-2847,
path:/rpt/2847.pptx} ”
스택 += 판독 라벨 · 이미지 경로 · meta 키

2 Router “경로-meta 나왔으니 그 키로 문서” →
search_engr_notes(meta)
툴 내부 — ① meta 조회로 참조 문서 먼저 선택 ② 그 안에서만 tsvector ||
halfvec ③ RRF 융합 ④ 리랭크 top-20
스택 += 참조문서 3건 · 인용 원문 문장

3 Router “원인-대책 원본 필요” (필요시) → get_incident("PHOD01-2847")
“ {규모:lot 3 · 피해:yield -1.2% · 원인:대책-장동된 점 } ”
스택 += 사고 원장 행 — 담당 엔지니어가 직접 쓴 확정 필드

4 병렬 Trend · 사내 DB · Engr Inform 동시 호출 (서로 독립이라 병
스택 += Trend 반환 · 설비 이력 — 과거 원인이 이번 설비에서 재현될
교차 확인

종료 근거 3중 확보 · 미결 질문 없음 → 도구 루프 종료, Q/A 역할로 인
계

B · 사고 문의-알람 진입 — 원장 → meta 선택 → 문서

입력 SPC 알람 {param:CD, lot:L42, Δ:+0.8nm, t:02:14} 또는 “이 사
고 어떻게 됐었나” 질문

1 Router “사고 건이므로 원장이 첫 조회 — 검색이 아니라 조회다”
→ search_incidents(drift, PHOD)
툴 내부 — 담당 엔지니어가 손으로 쓴 RDB: 사고명·규모·피해·원인·대책·조자·
잘못된 점. 신뢰 최상이라 여기부터
“ {2847: 원인 PM 후 재보정 누락 · 대책 offset -0.4 · yield -1.2% } ”

스택 += 사고 원장 행 (확정 사실)

2 Router 사고명-meta로 참조 문서 선택 →
search_engr_notes(meta) — A의 2단계와 동일 경로 (진입만 다르
다)
스택 += 참조문서 · 인용 원문

3 Trend Agent 2-stage — 1단 양봉 게이트, 2단 LLM이 변경점 이력
+ 일평균 JSON 판독
“ {변화점 02:14, drift형, 6/28 PM 연관 의심} ”
스택 += 변화 시점-변화량-연관 작업

4 사내 DB Agent get_interlock_history(SCN=07) — PM 06/28 후
재보정 기록 없음
스택 += 설비 이력 — 가설이 실제 이력과 맞물림

종료 근거 부족 시 최대 3회 재검색, 그래도 모자라면 “확인 불가”를 스택
에 적고 넘긴다

역할별 temperature — 같은 엔진, 다른 온도

Router LLM · T = 0
내는 것 — 도구 이름 + 인자 JSON (문장이
아니다)
온도를 조금만 줘도 72h가 48h로, lot 범위가
다른 값으로 흔들려 같은 사건에 다른 조사
경로가 나온다 — 감사에서 재현이 안 되면
판정이 무효다
top_p 1.0 · seed 고정 — 호출 시퀀스 재
현

Q/A LLM · T ~ 0.3
내는 것 — 스택을 읽고 쓴 문장 (판정서 서
술@max만 이으면 표현이 굳어 원인이 달라
도 서술이 안 걸린다. 0.3은 서술만 풀어주는
폭 — 수치·사고번호·인용문은 스택에서 복사
하므로 온도가 값을 못 흔든다
top_p 0.9 · 세는 건 검증기 a 사실 대조가
잡는다

최종 Q/A 호출에 실제로 들어가는 것 — 4중 스택

① 고정종 — system-조사규칙-판정서 스기마 (프리픽스 캐시 적용)

② 사건종 — 질문 원문 또는 알람 JSON · 첨부 이미지 행들

③ 증거종 — 도구 반환 능력 5~15회: 원장 행 · 참조문서 인용 ·
판독 라벨 · Trend · 설비 이력 ← 사건마다 자라는 종

④ 출력 지시종 — 스택 밖 사실 금지 · 수지는 반환값 그대로
복사 · 근거 3중 · 부족분은 “확인 불가”

↓ Q/A LLM T 0.3 → 판정서 → 검증기 5

답의 수준은 모델이 아니라 스택이 정한다 — 3단계를 빼면 “과거에 비슷한 게
있었다”에서 멈추고, 4단계를 빼면 “이번 설비가 그랬는지”를 못 쓴다.

6. 조치안 출력 — 무엇을 얼마나 바꿀지, 한도와 사이드 이펙트까지가 한 세트다

판정서 #Q-1042 · PHOD03 CD drift 신뢰도 High · 근거 3중 · L3 권고

원인 — Scanner SCN-07 Focus 드리프트 (PM 06/28 후 재보정 누락 · 과거
PHOD01-2847 동일 패턴)


조치 — Focus offset -0.4 재보정 권고 || 가드: 1회 변경 한도 |Δ|≤0.5 · PM 주기
당 1회 · 한도 초과 입력은 자동 반려

사이드 이펙트 — 과보정 시 center CD 역방향 shift 위험 → 모니터 lot 2매 선행
확인 후 분류 적용

근거 인용 — ① Trend {02:14, +0.8nm} ② Map edge_ring 0.92 ③ PHOD01-2847 보
고서 p.14 조치 문장

- 조치가 곧 명령이 아니다 — 파라미터 가드(변경량
상한·횟수 제한·되돌림 가능성)을 조치 등급표가 강제
한다. “많이 바꾸는” 답은 구조적으로 못 나간다.
- 근거 사실이 실물에 닿는다 — 유사도는 후보만,
확정은 메타-경로 키로 RDB에서, 인용은 원문 문장
기반

7. Agent를 하나씩 열어줄 때마다 답이 자란다 — 프롬프트에 무엇이 들어가 답이 어떻게 달라지나 (ablation · 같은 사례 실측)



원장 2 사고 건이면 여기가 1번

search_incidents ·
get_incident

SQL 5

get_spc_trend ·
commonality_analysis · get_master_info ·
get_interlock_history · search_fab_data

Vision 2

classify_wafer_map ·
analyze_defect_image


RAG 1

search_engr_notes

도구는 조회 전용 — 통계·공통성 분석은 코드가 계산한다. 도구를 하나 빼면 답이 어느 단계로 후퇴하는지가 그대로 보인다.

기술적
해결
방안
(계속)

8. 그럴듯한 오답은 코드가 거른다 — 다섯 관문



관문을 지날수록 통로가 좁아진다 — **침묵 실패가 없다**. 모르는 것은 모른다고 적는 것까지가 관문이고, 반복 실패는 사람에게 넘겨진다.

9. Agentic RAG 설계 — 사람이 정리한 사고 DB가 항상 먼저고, 확정은 키 조회다



10. 지표는 실측으로만 — 임의의 %를 지금 적지 않는다

회귀 기준선 · recall@10

0.500

골든 4건→30건 확정 · 색인 50건 · 회귀 러너 실측

0점으로 관리한다

- 근거 없는 판단 채택
- 미승인 L2 조치 실행
- 무인 접수 누락 — 검증기 차단 로그감사 로 그로 센다

선행 프로토타입 실측

26질의 hit@1 **1.000** · 하드셋 38질의 **0.957** · 군집 품질 AMI **0.956**/ARI 0.860 — Qwen3 코 체 후 재측정

판정 정답률은 그림자 운영 실측 뒤 확정한다. 일치율(AI 대 엔지니어 판정)-recall@10:처리 시간-변태율이 떨어지면 배포를 막는다.

III. 경영효과

예상 성과

200억 원/년

판정 업무 시간 환산 가치 — 확산 완료 후 1,000명 적용 시

57.5배

연간 ROI — 투자 연 347,794,165원 대비

6.3일

투자 회수 — 2개년 총투자 기준 12.7일

[(개선 전 4h ÷ 8h) - (개선 후 2h ÷ 8h)] × 연봉 80,000,000원 × 1,000명 = 연 200억 원

연봉 8,000만 = 사내 산정 기준값 · 인원 감축이 아니라 시간의 환산 가치 · 1차년은 실측 구간이라 효과 미계상 · 4h→2h는 실측 전 가정, 그림자 운영 로그로 대체

2.0h (목표)

2.5h 57.5배 · 200억 43.1배 · 150억

3.0h 28.8배 · 100억

3.5h 14.4배 · 50억

민감도 — 실측이 낮으면 같은 비율로 하향. 절감이 반영되어도 ROI 14배.

구현 검증기 5척 가동

조사 코어 스텝레온 실행 · prod 백엔드 4중

평가 recall@10 0.500

골든 4건/색인 50건 · 회귀 러너 실측

선행 프로토타입

군집 품질 AMI 0.956 · ARI 0.860

노이즈 0.52% · 43 class-900 wafer — RAG 전 요소유사 검색-메타 키 조회 가동

설계 설계 문서 31중

시스템설계서-로드맵-Tool 카탈로그-조사규칙

2Q 그림자 운 조치 미실 → 4Q 무인 점 2주 연속 누락 0 → 2차년 자동조치 개 전건 감

영정 담당 판정을 정답으로 일치율 기준선-4h 가정 실측 측리 시간-누락-조치 정답을 분기 보고 행인율-오합을 기준 넘은 시나리오만 개별 심의 승격