


AX Award 지원서

I. 개요			
지원부문	제조 AX 부문		
팀 / 그룹	제조기술센터 품질기술그룹	대표자	홍길동
제목	완전한 품질 AI Agent Orchestration 구축 — 감지부터 판단·조치·자동조치까지 스스로 수행하는 살아있는 품질 관리 시스템		
적용시점	2026-09-01 ~ 2028-08-31 (24개월) — 1차년 구축·검증 / 2차년 확산·자동화		
형전개 범위	1차년 포토 1개 공정 → 2차년 etch·CMP 3개 공정 → 품질·공정 엔지니어 약 1,000명 · DRAM·NAND 전 제품군. 확산 표준안으로 타 조직 이관.		

II. Process	
문제 정의	1. 새벽 이상 1건의 실제 동선 — 검출은 2초, 그러나 원인을 아는 사람이 없었다  이 판정 하나에 필요한 지식은 셋이다 — ① 이 item의 trend 이력 ② 직전 변경점(PM·레시파·자재) ③ 같은 조합에서 과거에 났던 불량. 새벽 주말 취약시간에는 ②③을 아는 사람이 현장에 없다. 그래서 단순 파라미터 보정으로 trend만 스펙 안으로 되돌리고 넘어간다. 숫자는 정상처럼 보이지만 원인은 그대로 남는다 — 같은 불량이 재발·확산된 뒤에야 주간에 드러난다. 매번 이렇게 흘러간다. 02:14→08:30 무대응 공백 6h — 야간 알람은 "이상이다"에서 멈춘다 인수·파악 — 전달 손실 교차 조사 4h+ — SPC·YMS·MES·EngrNote 수신회면수 보고·결재 — 회의·품의 등 대조 16시가 되어야 lot 처리가 결정된다. 특별한 사고가 아니라 매일의 기본 동선이다. 단계 시간은 산정치 — 가동 후 처리 시간 로그로 실측 보정. 2. 동선 안에 반복되는 구조 결함 4 — 측정 가능한 문제로 적는다 조사 공수가 크다 — 판정 한 건에 SPC·MES·YMS·EngrNote를 다 띄워놓고 손으로 대조한다. 반나절짜리 공수가 매일 반복된다 · 계측: 건당 처리 시간 취약시간에 사고가 난다 — 야간 주말엔 변경점·과거 사례를 아는 사람이 없어 trend만 맞추는 임시 대응이 나온다 · 계측: 발생→조사 착수 시각차 사람마다 결론이 갈린다 — 같은 trend를 봐도 베테랑과 신입의 결론이 다르다. 기준이 시스템이 아니라 사람 머릿속에 있다 · 계측: 동일 현상 판정 일치율 기록 없이 각자 알아서 변경한다 — 근거가 문서로 안 남아 개인 판단으로 보정하고 지나간다. 담당이 바뀌면 같은 조사를 처음부터 · 계측: 담당 교체 후 재조사 건수 3. 왜 중요한가 — 상시·대량 업무이고, 오판 비용이 비대칭으로 크다 4h / 근무 8h 근무의 절반이 판정 조사·대조에 쓰인다 [가정 — 로그로 실측 대체] × 약 1,000명 만 명 규모 제조 조직의 품질·공정 엔지니어 전원의 매일 업무 전성 능력 불량 유출 후공정·클래임 증폭 가성 Hold 리인 정지 수율·TAT 직접 손실 어느 쪽으로도 못 기운다 오판 비용이 양쪽 다 크다. 그래서 판정은 낮고 보수적이 된다 — 사람이 시간을 더 쓰는 이유가 게으름이 아니라 비용 구조다. 시스템도 여기서 똑같이 무너진다. 오탐이 잦으면 현업이 알람을 꺼 사장된다 — 알람 신뢰를 관리 지표로 둔다.

문제 정의 (계속)	4. 기존 대안 검토 — 셋은 기각, 하나는 트리거로 편입		
	사내 LLM API	기각	질문을 넣으면 일반 지식으로 답할 뿐 — SPC-MES 조회, MapSEM 판독, 변경점 대조를 할 손이 없다. 물어보는 사람의 지식만큼만 나온다
	사내 공용 RAG	기각	문서를 통째 벡터로 넣는 구조 — 설비 ID-공정 약어가 임베딩에서 뭉개져 검색 정확도가 낮고, 반도체 사전-용어 병가-메타 필터 같은 손잡이가 없다
	BI-대시보드	기각	보는 화면만 늘어났다 — 대조-판단-조치는 여전히 사람 공수로 남는다
	규칙 기반 SPC 알람	편입	spec-rule 기반이라 정해진 임계만 잡는다 — 완전한 drift-복합 이상은 통과. 상시 감지는 Trend Agent가 대신하고, SPC 알람은 무인 기동 트리거로만 쓴다
5. 왜 지금인가			
① 쓸 만큼 데이터가 쌓였다 — 사고 이력 RDB-EngrNote-문서저장소 ·SPC/MES/YMS/EES/QMS가 학습-검색 자산으로 쓸 양에 도달 ② 들어올 만한 모델이 나왔다 — 사내 반입 가능한 모델이 판단-판독 요구 수준에 도달 ③ 검증 체계가 먼저 섰다 — 회귀 러너-recall 실측까지 서 있다. 백지 출발이 아니다			
			지금 시작

Process
재설계

1. E2E 전체 대체 — 6단계 업무가 무엇을 받아 무엇을 내는지까지 설계했다

사람
= 14h

인지 조사 판정 조치 결정 보고 이력 등록

수신분 수사분 심사분 심사분 심사분

adapter investigator judgment action answer register

확정 이력 - 다음 사건의 검색, 근원화, 분류

Q-Agent 수 초

다섯 단계가 통째로 내려온다 - 자율 tool calling, 접근 수 초

adapter 알람 JSON-질문 → 표준 사건 카드 investigator 도구 5~15회 → 증거 묶음 judgment 검증 5척 통과분만 판정서로 action 조치안+등급+파라미터 가드 answer 근거 3종 인용 보고서 register 사람 승인-수정-반려 → 확정분이 코퍼스재학습 라벨

2. 조치 권한 승격 구조 — 무엇을 실행하고, 누가 확정하고, 무엇을 넘어야 올라가나

1차년 즉시 개방 — 통보성 (되돌릴 것 없음)

L1 알림 이상 동보 — 야간에도 교대자에게

L2 소견 공유 유형 유사 사고 소견 첨부

L3 점검 권고 조치안 제시 — 실행은 현업 판단

확정 주체: 시스템 발신 · 사람은 수신-채택

→ 채택-반려 이력 축적

사람 승인 후 실행

L4 lot Hold 승인 전 미실행 — 승인-반려가 기록

확정 주체: 담당 엔지니어

→ 승인율-오함을 기준 통과

2차년 개별 심의 승격

L5 자동조치 되돌릴 수 있는 조치만 · 전건 사후 리뷰

실비 제어성 조치는 2차년에 도 승인 대상

3. 시작-중간-끝이 모두 바뀐다 — 끝이 다음 시작을 만든다

시작 — 사람이 아니다

Chat 질문 · 무인 감지 이벤트

→

중간 — 코어 하나

조사→판정→조치안 · 검증 통과분만

→

끝 — 자산이 된다

승인-등록 확정분이 코퍼스-라벨로

4. 현업 활용-확산 — 코어는 그대로, 조사규칙과 색인만 늘린다

- 확산 표준안 = 조사 코어 + 공정별 조사규칙 템플릿 + 골든셋 구축 절차. 2차년 통과 조건 — 코어 변경 0 · 반려율 상승 없음. 공정이 3개로 늘어도 추가 자원을 요청하지 않는다.
- 현업 몫 — 조사규칙 초안(3Q-공정 담당) · 조치 승인-반려(상시) · 골든셋 확정(분기). 노하우가 등록될수록 시스템이 그 팀에 맞게 자란다. 오람 남발은 이벤트 그룹핑-수신자 피드백으로 조정(조회는 정보계 경유 전용 — 1Q 통과 조건).

1차년 · 구축-검증

3Q 그림자 → Chat 파일럿

포토 공정 담당 엔지니어

1차년 · 구축-검증

4Q 무인 접수 개시

야간-주말 누락 0건 · 채택률 집계

2차년 · 확산-자동화

5-6Q etch-CMP 확산

3개 공정 — 코어 변경 0

2차년 · 확산-자동화

8Q 약 1,000명 전면

표준안으로 자원 증설 없이 이관

III. Tech

기술적 해결 방안



1. 왜 Agent Orchestration 인가 — 규칙·분류기·단일 LLM이 각각 실패하는 지점

조사 순서를 미리 못 정한다 — 다음에 볼 데이터가 직전 결과에 따라 달라진다. 고정 파이프라인은 분기가 폭발한다.

정답이 라벨이 아니라 근거 있는 설명이다 — 분류기는 Hold/Release만 찍는다. 판정은 결론보다 근거가 감사 대상이다.

이중 도달이 한 사안에 섞인다 — 시계열·이미지·문서·정형 DB. 각 모델은 전용 모델이 정확하고, 종합은 LLM이 한다.

임계 기반으로는 안 걸린다 — 임계 아래로 완만히 흐르는 shift는 규칙 알람이 못 잡는다. 변화점 검정이 필요하다.

2. 아키텍처 — Router가 결과를 보고 다음 도구를 정하는 tool calling 루프



3. 무엇이 새로운가 — 이 설계에서 새로 만든 것 셋

- 01** 검증 게이트 오케스트레이션

재제 조건이 "그릴드함"이 아니라 코드 관문 통과다. 탈락은 판단 불가로 강등 — 침묵 실패가 구조적으로 없다.
- 02** 2단 확정 검색

유사도는 후보 생성까지만 — 확정은 메타·경로 키의 RDB 조회. 백터의 모호함이 인용·판정에 유입될 수 없다.
- 03** 업무가 곧 라벨링인 페루프

승인·수정·반려가 그대로 학습 라벨 — 별도 라벨링 조직 없이 SFT·선호 학습(DPO·KTO)·검색기 파인튜닝이 월 4회 돈다.

4. 전문 모델의 밑단 — 이미지·Trend 두 갈래 모두 자체 개발로 이미 들고 있다



5. 실행 트레이스 두 갈래 — 데이터가 실제로 이렇게 흐른다 (호출 → 툴 내부 동작 → 반환값 ← 프롬프트 적재)

A · 불량 이미지(EDS-SEM) 진입 — 유사도 → 경로-meta → 문서

입력 eds_0731.png 첨부 — “이 불량 뭐지? 과거 유사 사고 있었나?”
스택 = [system · 도구 스키마 10종 · 판정서 스키마]

1 Router “이미지가 있으니 유사도부터” →
analyze_defect_image(img)
툴 내부 — contrastive 3842→128-d L2 → 사고 이미지 스토리지 갤러리 코사인 top-10 → 일계 0.82 컷
← {top1:edge_ring, sim:0.93, incident:PHOD01-2847, path:/rpt/2847.pptx}
스택 += 판독 라벨 · 이미지 경로 · meta 키

2 Router “경로-meta 나왔으니 그 키로 문서” →
search_engr_notes(meta)
툴 내부 — ① meta 조회로 참조 문서 먼저 선택 ② 그 안에서만 tsvector || halfvec ③ RRF 융합 ④ 리랭크 top-20
스택 += 참조문서 3건 · 인용 원문 문장

3 Router “원인-대책 원본 필요” (필요시) → get_incident("PHOD01-2847")
← {규모:lot 3 · 피해:yield -1.2% · 원인:대책-장동된 점}
스택 += 사고 원장 행 — 담당 엔지니어가 직접 쓴 확정 필드

4 병렬 Trend · 사내 DB · Engr Inform 동시 호출 (서로 독립이라 병렬)
스택 += Trend 반환 · 설비 이력 — 과거 원인이 이번 설비에서 재현될음 교차 확인

종료 근거 3종 확보 · 미결 질문 없음 → 도구 루프 종료, Q/A 역할로 일계

B · 사고 문의-알람 진입 — 원장 → meta 선택 → 문서

입력 SPC 알람 {param:CD, lot:L42, Δ:+0.8nm, t:02:14} 또는 “이 사고 어떻게 됐었나” 질문

1 Router “사고 건이므로 원장이 첫 조회 — 검색이 아니라 조회다” → search_incidents(drift, PHOD)
툴 내부 — 담당 엔지니어가 손으로 쓴 RDB: 사고명·규모·피해·원인·대책·조치·잘못된 점. 신뢰 최상이라 여기부터
← {2847: 원인 PM 후 재보정 누락 · 대책 offset -0.4 · yield -1.2%}

스택 += 사고 원장 행 (확정 사실)

2 Router 사고명-meta로 참조 문서 선택 → search_engr_notes(meta) — A의 2단계와 동일 경로 (진입만 다르다)
스택 += 참조문서 · 인용 원문

3 Trend Agent 2-stage — 1단 양봉 게이트, 2단 LLM이 변경점 이력 + 일평균 JSON 판독
← {변화점 02:14, drift형, 6/28 PM 연관 의심}
스택 += 변화 사항-변화량-연관 작업

4 사내 DB Agent get_interlock_history(SCN=07) · PM 06/28 후 재보정 기록 읽음
스택 += 설비 이력 — 가설이 실제 이력과 맞물림

종료 근거 부족 시 최대 3회 재검색, 그래도 모자라면 “확인 불가”를 스택에 적고 넘긴다

역할별 temperature — 같은 엔진, 다른 온도

Router LLM · T = 0
내는 것 — 도구 이름 + 인자 JSON (문장이 아니다)
온도를 조금만 줘도 72h가 48h로, lot 범위가 다른 값으로 흔들려 같은 사건에 다른 조사 경로가 나온다 — 검사에서 재현이 안 되면 판정이 무효다
top_p 1.0 · seed 고정 — 호출 시퀀스 재현

Q/A LLM · T ~ 0.3
내는 것 — 스택을 읽고 쓴 문장 (판정서 서술이 max이면 표현이 굳어 원인이 달라져 서술이 안 걸린다. 0.3은 서술만 풀어주는 폭 — 수치·사고번호·인용문은 스택에서 복사하므로 온도가 값을 못 쓴다)
top_p 0.9 · 세는 건 검증기 a 사실 대조가 잡는다

최종 Q/A 호출에 실제로 들어가는 것 — 4층 스택

① 고정층 — system-조사규칙-판정서 스키마 (프릭스 캐시 적용)
② 사건층 — 질문 원문 또는 알람 JSON · 첨부 이미지 행들
③ 증거층 — 도구 반환 능력 5~15회: 원장 행 · 참조문서 인용 · 판독 라벨 · Trend · 설비 이력 ← 사건마다 자라는 층
④ 출력 지시층 — 스택 밖 사실 금지 · 수지는 반환값 그대로 복사 · 근거 3종 · 부족분은 “확인 불가”

↓ Q/A LLM T 0.3 → 판정서 → 검증기 5식

답의 수준은 모델이 아니라 스택이 정한다 — 3단계를 빼면 “과거에 비슷한 게 있었다”에서 멈추고, 4단계를 빼면 “이번 설비가 그랬는지”를 못 쓴다.

6. 조치안 출력 — 무엇을 얼마나 바꿀지, 한도와 사이드 이펙트까지가 한 세트다

판정서 #Q-1042 · PHOD03 CD drift 신뢰도 High · 근거 3종 · L3 권고

원인 — Scanner SCN-07 Focus 드리프트 (PM 06/28 후 재보정 누락 · 과거 PHOD01-2847 동일 패턴)

조치 — Focus offset -0.4 재보정 권고 || 가드: 1회 변경 한도 |Δ|≤0.5 · PM 주기당 1회 · 한도 초과 입력은 자동 반력

사이드 이펙트 — 과보정 시 center CD 역방향 shift 위험 → 모니터 lot 2매 선행 확인 후 분류 적용

근거 인용 — ① Trend {02:14, +0.8nm} ② Map edge_ring 0.92 ③ PHOD01-2847 보고서 p.14 조치 문장

- 조치가 곧 명령이 아니다 — 파라미터 가드(변경량 상한·횟수 제한·되돌림 가능성)을 조치 등급표가 강제한다. “많이 바꾸는” 답은 구조적으로 못 나간다.
- 근거 사실이 실물에 맞는다 — 유사도는 후보만, 확정은 메타-경로 키로 RDB에서. 인용은 원문 문장 그대로.

7. Agent를 하나씩 열어줄 때마다 답이 자란다 — 프롬프트에 무엇이 들어가 답이 어떻게 달라지나 (ablation · 같은 사례 실험)

LLM 단독 ctx: 알람 원문본

+ Trend Agent +{02:14, +0.8nm, drift}

+ Image Agent +{edge_ring, 0.92}

+ 유사사례 RAG +사고번호·원인·조치 문장

+ 설비 이력 Tool +PM-인터랙 기록

+ 조치 생성 +조치 등급표·가드 한도

“02시경부터 CD가 오르는 것으로 보입니다. 계속 재확인을 권장합니다.” 모호 — 시간-근거 없음

“02:14에 변화점, +0.8nm drift형입니다. 순간 뒀이 아니라 지속 이동 — 계속 오류가 아닙니다.” 시점-변화량 확보

“같은 시각 Map이 edge ring 패턴(0.92) — 공간 분포까지 겹칩니다. Focus 계열 이상이 의심됩니다.” 불량 유형 특정

“PHOD01-2847과 동일 패턴입니다. 당시 원인은 PM 후 Scanner Focus 재보정 누락이었습니다.” 원인 후보 확보

“SCN-07은 06/28 PM 이후 재보정 기록이 없습니다 — 가설이 설비 이력과 맞물립니다. 원인 확정.” 교차 검증 완료

“Focus offset -0.4 재보정을 권고합니다. 한도 |Δ|≤0.5-PM 주기당 1회, 모니터 lot 2매 선행 확인.” 실행 가능

최종 프롬프트 스택 = system(조사규칙-판정서 스키마) + 사건 카드 + tool 반환 JSON 5~15개 + 인용 원문 발행 — 이 스택 전체가 판정서 생성의 입력이다. 답의 수준 차이는 모델이 아니라 스택에 쌓인 증거의 차이다.

원장 2 사고 건이면 여기가 1번

search_incidents ·
get_incident

SQL 5

get_spc_trend ·
commonality_analysis · get_master_info ·
get_interlock_history · search_fab_data

Vision 2

classify_wafer_map ·
analyze_defect_image


RAG 1

search_engr_notes

도구는 조회 전용 — 통계·공통성 분석은 코드가 계산한다. 도구를 하나 빼면 답이 어느 단계로 후퇴하는지가 그대로 보인다.

기술적
해결
방안
(계속)

8. 그럴듯한 오답은 코드가 거른다 — 다섯 관문



↓ 탈락분은 재생성 — 반복 실패 시 판단 불가로 강동
관문을 지날수록 통로가 좁아진다 — **침묵 실패가 없다.** 모르는 것은 모른다고 적는 것까지가 관문이고, 반복 실패는 사람에게 넘어간다.

9. Agentic RAG 설계 — 사람이 정리한 사고 DB가 항상 먼저고, 확정은 키 조회다



이 파이프는 세 갈래로 배운다 — 승인-수정-반려가 그대로 라벨 (월 4회 · 골든셋 회귀 통과분만 배포)

검색기 파인튜닝	확정 판정-문서 쌍으로 임베딩-리랭커 튜닝 · 전: "ACI 급등" 질의에 일반 세정 문서가 상위 → 후: 세정 후 계속 문서가 top-1 — 현장 용어를 배운다
SFT 지시학습	확정 판단서를 지시-응답 쌍으로 · 전: "CD 상승 원인은 다양할 수 있습니다" 서술 → 후: 원인-근거 3중 인용-조치 코드의 판정서 스키마로만 답한다
선호학습 DPO-KTO	채택=선호/반려=수정=비선호 쌍(DPO) + 단전 채택반려 선호(KTO) · 전: 근거 2개로 Hold까지 제안 → 후: 근거 미달이면 스스로 '판단 불가'를 고른다

추후 확장 (2차년 검토) — 지식을 '검색'에서 '읽고 걸는' 구조로

조사규칙 v12	LLM Wiki — 확정 판정-용어-조사규칙을 LLM이 자동 문서화하고 서로 링크한다. 신임도 검색어를 몰라도 읽어서 도달하는 살아있는 지식 베이스 — 갱신은 등록 확정문에서 자동.
용어: ACI → 세정 후 계속	
사고 2847 요약 ↔ 원문	



Graph RAG — 설비-PM-불량-사고-조치를 지식 그래프로 잇는다. "이 설비 PM 뒤 자주 난 불량과 그때 조치는?" 같은 다단(hop) 질의를 그래프 탐색으로 답한다 — 벡터 검색이 못 있는 관계를 걷는다.

10. 지표는 실측으로만 — 임의의 %를 지금 적지 않는다

회귀 기준선 · recall@10 0.500 골든 4건→30건 확정 · 예정 · 색인 50건 · 회귀 러너 실측	0점으로 관리한다 ● 근거 없는 판단 채택 ● 미승인 L2 조치 실행 ● 무인 접수 누락 — 검증기 차단 로그감사 로 그로 센다	선행 프로토타입 실측 26질의 hit@1 1.000 · 하드셋 38질의 0.957 · 군집 품질 AMI 0.956 /ARI 0.860 — Qwen3 코체 후 재측정
--	--	--

판정 정답률은 그림자 운영 실측 뒤 확정한다. 일치율(AI 대 엔지니어 판정)-recall@10-처리 시간-반려율이 떨어지면 배포를 막는다.

III. 경영효과

예상 성과

200억 원/년

판정 업무 시간 환산 가치 — 확산 완료 후 1,000명 적용 시

57.5배


연간 ROI — 투자 연 347,794,165원 대비

6.3일

투자 회수 — 2개년 총투자 기준 12.7일

[(개선 전 4h ÷ 8h) - (개선 후 2h ÷ 8h)] × 연봉 80,000,000원 × 1,000명 = 연 200억 원

연봉 8,000만 = 사내 산정 기준값 · 원원 검증이 아니라 시간의 환산 가치 · 1차년은 실측 구간이라 효과 미계상 · 4h→2h는 실측 전 가정, 그림자 운영 로그로 대체



민감도 — 실측이 낮으면 같은 비율로 하향, 절감이 반영되어도 ROI 14배.

구현 검증기 5칙 가동
조사 코어 스텝레온 실행 · prod 백엔드 4중

평가 recall@10 0.500
골든 4건/색인 50건 · 회귀 러너 실측

선행 프로토타입
군집 품질 AMI 0.956 · ARI 0.860
노이즈 0.52% · 43 class-900 wafer — RAG 전 요소유사 검색-메타 키 조회 가동

설계 설계 문서 31중
시스템설계서-로드맵-Tool 카탈로그-조사규칙

2Q 그림자 운영 — 조치 미실
공정 담당 판정을 정답으로 일치율 기준선-4h 가정 실측

4Q 무인 접수 — 2주 연속 누락 0
처리 시간-누락-조치 일정을 분기 보고

2차년 자동조치 개방 — 현관 검사
승인율-오합을 기준 넘은 시나리오만 개별 심의 승격