

AX Award 지원서

I. 개요

지원부문	제조 AX 부문		
팀 / 그룹	제조기술센터 품질기술그룹	대표자	홍길동
제목	품질 이상 접수부터 확정 이력 재사용까지 연결하는 AI Agent Orchestration 구축 — SPC 이벤트와 Chat 질문을 접수해 조사, 판정, 조치안 작성, 이력 등록을 연결하고 승인 범위에 따라 자동조치까지 확대하는 품질 관리 시스템		
적용시절	2026-09-01 ~ 2028-08-31 (24개월) — 1차년 구축, 검증 / 2차년 확산, 자동화		
형전개 범위	1차년 포토 1개 공정 → 2차년 etch, CMP 3개 공정 → 품질, 공정 엔지니어 약 1,000명, DRAM, NAND 전 제품군. 확산 표준안으로 타 조직 이관.		

II. Process

문제 정의

1. 해결하려는 문제 - 이상 감지 이후 분석과 판정이 대부분 Manual이다

품질 이상이 발생하면 담당 엔지니어가 SPC Trend, MES 이력, 설비 작업 이력, 변경점, 불량 이미지, 과거 사고 보고서를 하나씩 열어 대조한 뒤 원인을 판단하고 대응을 정한다. 이상 검출은 수 초면 끝나지만 그 뒤 조사와 판정은 대부분 수작업이라, 빠르게 잡아내고도 처리 결정까지 수 시간이 걸린다.

이상 발생 알람 확인 Trend 확인 MES, 설비 이력 조회 변경점 확인 과거 사고 검색 원인 판단 대응 결정 보고 이력 등록

↑ 진한 구간이 병목 여섯 단계가 전부 사람이 화면을 열어 대조하는 일이다. 교차 조사에만 4시간 이상, 야간에는 담당자 출근 전까지 조사 자체가 시작되지 않는다.

사례형 시나리오 예시: PHOD03 CD 급등 — 검출 02:14, 조사 착수 08:30, 처리 결정 16:00

판정 한 건에 필요한 정보는 세 가지다 — ① 이 item의 Trend 이력 ② 직전 변경점(PM, 레시피, 자재) ③ 같은 조합에서 과거에 났던 불량. 새벽과 주말 취약시간에는 ②③을 아는 담당자가 없다. 그래서 파라미터만 보정해 Trend를 스펙 안으로 되돌리고 넘어간다. 숫자는 정상으로 보이지만 원인은 남아, 같은 불량이 재발, 확산된 뒤 주간에 드러난다.

02:14→08:30 무대응 6h

인수, 파악

교차 조사 4h+

보고, 결정

2. 현장에서 반복되는 문제 4가지

조사 시간이 길다 — 판정 한 건에 SPC, MES, YMS, EngrNote를 모두 열어 손으로 비교한다. 같은 형태의 조사가 이상이 나올 때마다 반복된다. **측정: 건당 처리 시간**

담당자별 판정 편차가 크다 — 같은 Trend를 봐도 숙련도에 따라 조사 범위와 결론이 달라질 수 있다. 판정 기준이 시스템화되지 않고 개인 경험에 의존한다. **측정: 동일 현상 판정 일치율**

야간과 주말 대응 공백이 발생한다 — 야간과 주말엔 변경점과 과거 사례를 아는 담당자가 없어 원인 조사가 지연되고, 파라미터를 정상 범위로 되돌리는 임시 대응만 남는다. **측정: 발생→조사 착수 시각차**

변경 근거와 이력이 표준화되어 있지 않다 — 근거가 문서로 안 남아 개인 판단으로 보정하고 지나간다. 담당이 바뀌면 같은 조사를 처음부터 다시 수행한다. **측정: 담당 교체 후 재조사 건수**

3. 현업 관점의 중요도와 개선 필요성



근무의 절반이 판정 조사와 대조에 쓰인다 [산정치 — 로고로 실측 대체]

× 약 1,000명

품질과 공정 엔지니어 전원이 매일 하는 상시 업무다

진성 놓침 — 불량이 후공정과 고객까지 확대된다

어느 쪽으로도 기울일 수 없다

가성 Hold — 정상 Lot을 세워 수율과 TAT에 손실이 난다

진성 이상을 놓치거나 정상 Lot을 불필요하게 Hold하면 손실이 크다. 따라서 이상 감지만으로는 충분하지 않다. 감지 이후 데이터 수집, 원인 조사, 판정, 대응, 이력 등록까지 전체 Process를 개선해야 한다. 개선 효과는 조사 착수 시간, 건당 처리 시간, 판정 일치율, 재조사 건수로 측정한다.

4. 기존 수단의 한계

사내 LLM API 각각 SPC, MES 조회, Map 판독, 변경점 대조 기능이 없다

사내 공용 RAG 각각 공정별 시스템 조회, 조사 순서 결정, 승인 연계를 지원하지 않는다


BI, 대시보드 각각 조회 화면만 늘 뿐 판단은 사람 몫으로 남는다

규제 기반 SPC 알람 편입 임계만 잡으므로 감지는 Trend Agent가 맡고 알람은 기동 트리거로 쓴다


현재 적용 가능한 기반 — 사고 원장, 설비 이력, Trend, 이미지, 문서가 축적돼 있다. 사내 LLM, Vision, Tool Calling을 사용할 수 있고, 골든샷, 회귀 Runner, 검증기 5척으로 모델 변경 전후를 비교할 수 있다.

Process 재설계


1. E2E 전체 Process 재설계 — 접수부터 확정 이력 재사용까지 연결



2. 조치 권한 체계 — 실행 범위와 승인 주체



3. 접수부터 확정 이력 재사용까지 연결




4. Process 확산 가능성 — 새로 개발하지 않고 공정별 규칙과 연결 범위만 추가한다

- 확산 표준안 = 공통 조사 Core + 공정별 조사규칙 템플릿 + 골든셋 구축 절차. 5Q etch 통과 조건 — Core 변경 0건, 반려를 기준으로 대비 상승 없음. 공통 Core는 재개발하지 않고 공정별 조사 규칙과 데이터 연결만 추가한다.
- 현업 역할 — 조사규칙 초안(3Q, 공정 담당), 조치 승인, 반려(상사), 골든셋 확정(분기). 확정 이력은 공정별 검색 데이터와 평가셋에 반영한다. 과다 알림은 이벤트 그룹핑, 수신자 피드백으로 조정(조치는 정보계 경유 전용 — 1Q 통과 조건).



5. 현행 Workflow와 개선 Workflow — 어디를 대체했는지



붉은 구간은 기존 수작업 병목이고, 짙은 구간은 Agent 처리로 전환한 영역이다. 접수부터 확정 이력의 다음 사건 재사용까지 E2E Process 전체를 연결한다 — 조사, 판정, 조치안, 보고, 등록은 Agent가 처리하고 승인과 현장 조치는 사람이 담당한다.

기술적 해결 방안



1. 기존 자동화만으로 해결하기 어려운 이유

조사 순서를 사전에 고정하기 어렵다 — 다음에 볼 데이터가 직전 결과에 따라 달라진다. 고정 파이프라인은 조건별 분기가 급증해 유지보수가 어렵다.

판정 근거를 함께 제시해야 한다 — Hold/Release 결과와 판단 근거를 모두 추적할 수 있어야 한다.

한 건의 판정에 시계열, 이미지, 문서, DB를 함께 확인해야 한다 — 각 데이터는 전용 모델로 처리하고 LLM이 종합한다.


고정 임계값만으로는 완전한 Drift를 놓칠 수 있다 — 변화점 검정이 필요하다.

2. 문제별 알고리즘 선택 근거

풀어야 할 문제	× 각각 대한	✓ 채택 — 이유
Trend 이상 검출	× 규칙, 임계 알람 — 임계 아래로 흐르는 완전한 drift를 통과시킨다	✓ 합성 데이터 학습 감지 모델 라벨 없는 구간을 합성으로 만들고, 1단은 정상과 이상만 판별해 성능을 올린 뒤 변경점 연관은 2단이 읽는다
불량 이미지 판독	× 분류기 단독 — 라벨 밖 새 패턴을 못 잡는다	✓ ConvNeXt V2 분류 + contrastive 유사 검색 Known 유형은 분류 모델로 판정하고 Unknown 유형은 임베딩 거리로 유사 사례를 검색한다
사고 문서 검색	× 임베딩 단독 — 설비 ID와 공정 약어의 식별력이 낮다	✓ 원장 우선 조회 + 키워드, 임베딩 하이브리드 ID는 키워드가, 증상 서술은 의미 검색이 강하다. 확정은 사고번호 조회로 한다
조사 순서 결정	× 고정 Pipeline — 신규 공정마다 조건 분기와 Workflow 추가 개발이 필요하다	✓ Router LLM tool calling 루프, T=0 다음에 볼 데이터가 직전 반환값에 따라 달라지므로 순서를 미리 못 정한다
최종 판정	× 분류 모델 — Hold/Release 판정은 가능하지만 근거를 제시하기 어렵다	✓ Q/A LLM, T=0.3 + 코드 검증기 근거를 묶어 판정서를 쓰고, 근거 실패와 수치 대조는 코드가 검사한다

3. 전문 모델 구성과 개선 과정 — 이미지와 Trend의 한계를 단계적으로 보완

이미지 unknown-contrastive — 라벨 밖 패턴을 유사도로 탐색
무라벨 SEM, Failbit 쌍에 InfoNCE(Global, Local, Queue, 위음성 필터)를 적용한다. ConvNeXt V2+TAPT, 384²→128-d. 대표는 클래스당 30장 평균 anchor, 최종 확정은 composite map, 멜버 이미지 육안로 확인한다.



Trend, anomaly-detection — 라벨 부족을 합성 데이터로 보완

라벨이 부족한 불량 구간에 합성 주입(mean_shift, drift, spike, level_step)하고, 복귀형 파형은 정상 클래스에 추가해 학습한다.

1단 정상/이상 전용 감지 모델 — 1단은 정상/이상을 감지하고, 2단 LLM은 변화 시점과 설비 작업 연관을 분석한다

2단 LLM 판독 — 변경점 이력과 Trend JSON을 입력해 변화 시점과 관련 설비 작업까지 연결한다

운영 검증 — Grad-CAM 근거, AUROC와 FN/FP 임계 스텝, 라인별 CSV 추가 학습.

4. 대표 실행 시나리오 — 이미지와 사고 문의가 동일한 조사 코어로 연결된다

A. 이미지 진입

EDS, SEM 첨부 → search_similar_image

B. 사고 문의. 알람

{CD + 0.8nm, 02:14} → search_incidents

Router, T = 0 도구 선택 → 인자 생성 → 변환 해석 → 가설 갱신 → 계속/중단 판단
입구는 둘, 코어는 하나 — 진입 도구만 다르고 이후 경로는 같다

기술적 해결 방안

(계속)

Image / Trend	불량 이미지가 들어오면 대조 학습 유사도로 후보를 찾고 , 해당 이미지의 경로와 meta로 RAG, 사내 DB를 조회한다. Trend Agent는 변화점을 반환한다 — $\leftarrow$ (edge_ring 0.92, incident:PHOD01-2847), $\leftarrow$ {변화점 02:14, drift, 6/28 PM 연관}
사고 원장 → RAG	사고 건이면 담당자가 확정된 사고 원장을 먼저 조회 하고 사고명과 meta로 관련 보고서를 증인 뒤 필요한 Tool을 추가 호출한다 — $\leftarrow$ 원인, 대책 원문 인용
사내 DB 교차 확인	get_interlock_history(SCN-07) $\leftarrow$ PM 06/28 후 재보정 기록 없음 — 가설과 설비 이력이 일치
Q/A, T=0.3	더 부를 도구가 없으면 증거 스택 전체로 판정서를 쓴다. 근거 부족 시 최대 3회 재검색, 그래도 모자라면 “확인 불가”로 남긴다

유사도는 후보만 제시하고 확정은 사고번호 조회로 한다. 반환값은 판정서 근거로 사용한다.

역할별 Temperature 설정

Router LLM, T = 0

내는 것은 도구 이름 + 인자 JSON. Router는 T=0으로 변동을 줄이며, 지원 환경에서는 seed를 고정한다. top_p=1.0으로 sampling을 제한하지 않는다.

Q/A LLM, T ≈ 0.3

내는 것은 스택을 읽고 쓴 문장, 수치와 인용은 도구 반환값에서 복사한다. top_p 0.9, 검증기 ③이 차단

최종 Q/A 입력 구성 — 4개 계층

① 고정층 조사규칙과 판정서 스키마 (고정) → ② 사건층 질문, 알람 JSON, 이미지 → ③ 증거층 원장, 문서, Trend, 설비 이력 → ④ 출력층 지시층 근거 밖 사실 금지, 부족분은 “확인 불가”

5. 도구별 근거 추가에 따른 판정 내용 변화 (예시 시나리오 기준)



6. Agentic RAG — 확정 사고 원장을 먼저 조회하고 관련 문서로 검색 범위를 확장



유사도는 후보이며 확정은 키 조회로 한다. 합류점은 Router에 쌓이는 증거 스택이며, 증거 스택의 원문을 바탕으로 Q/A LLM이 판정서를 생성한다.

향후 모델 개선 계획 — 승인, 수정, 반례를 라벨로 축적하고 회귀 통과 모델만 배포

검색기 파인튜닝	확정 판정과 참조 문서 쌍으로 검색기를 학습해 관련 사고 문서가 상위에 검색되도록 한다.
SFT 지시학습	현업 확정 판정서로 원인, 근거, 조치를 정해진 판정서 형식으로 출력하도록 학습한다.
선호학습 DPO, KTO	채택, 수정, 반례 이력을 선호 신호로 사용해 근거가 부족하면 조치를 제안하지 않도록 보장한다.

2차년 확장 설계 — 확정 이력을 관계 탐색까지 연결한다

조사규칙 v12	LLM Wiki — 확정된 판정 결과와 현장 용어, 조사규칙을 계층형 문서로 관리한다. 원문 출처와 관련 문서를 연결하고 현업이 승인한 이력만 반영한다.
용어: ACI ↔ 세팅 후 계속	
사고 2847 요약 ↔ 원문	



Graph RAG — 설비, PM, 불량, 사고, 조치를 노드로 구성한다. 발생, 선행, 원인, 조치 Edge를 multi-hop 탐색해 벡터 검색만으로 찾기 어려운 다단 관계를 조회한다.

7. 성능 지표와 검증 체계

현재 회귀 기준선, recall@10

0.500

골든 4건, 색인 50건. 30건으로 확대 예정

운영 목표 0건

● 근거 없는 판정 ● 미승인 L2 조치 실행 ● 무인 접수 누락 — 차단 로그로 집계

성능 관리 체계

골든셋 확대 30건, AI와 엔지니어 판정 일치율, 건당 처리 시간 추적, 조치 반려율과 기준 미달 배포 차단

예 상 성 과

1. 유형효과 예상 업무시간 환산 가치 기준

200억 원/년 예상 업무시간 환산 가치 — 확산 완료 후 약 1,000명 기준

57.5배

예상 연간 편익 / 연간 투자비

6.3일

연간 투자비 기준 예상 회수 기간 — 2개년 총투자비 기준 12.7일


$[(\text{개선 전 } 4\text{h} \div 8\text{h}) - (\text{개선 후 } 2\text{h} \div 8\text{h})] \times \text{연봉 } 80,000,000\text{원} \times 1,000\text{명} = \text{연 } 200\text{억 원}$

인력 감축 효과가 아니라 반복 조사 업무시간의 환산 가치다. 4h→2h와 1,000명 적용은 사전 산정 가정이며, 3Q Shadow 운영에서 실제 처리 시간, 사용 빈도, 적용 인원을 측정해 보정한다

2.0h 절감  200억, 57.5배

1.5h 절감  150억, 43.1배

1.0h 절감  100억, 28.8배

0.5h 절감  50억, 14.4배

업무시간 절감 폭에 따른 예상값이며, 실제 값은 3Q Shadow 운영에서 보정한다.

● 야간 공백 해소 — 야간과 주말에도 즉시 조사 착수

● 판단 편차 축소 — 동일 현상에 동일한 조사 기준 적용

● 감사 대응력 — 근거 원문, 신뢰도, 모델 버전이 판정마다 남는다

● 노하우 자산화 — 조사규칙과 EngrNote를 축적해 개인 경험에 대한 의존도 감소

● 타 조직 이관 — 공통 Core를 재사용해 타 조직으로 확산

구현

검증기 5척 가동

조사 코어 스켈레톤 실행, prod 백엔드 4종

평가

recall@10 0.500

골든 4건/색인 50건, 회귀 러너 실행

연계 검증

RAG, 유사 검색 연계 검증

사고 원장, 문서 검색, 이미지 유사 검색, 메타키 조회 흐름을 선행 구현

설계

설계 문서 31종

시스템설계서, 로드맵, Tool 카탈로그, 조사규칙

3Q 그림자 운영

조치 미실행

공정 담당 판정을 정답으로 일치를 기준선, 4h 가정 실측

4Q 무인 접수

2주 연속 누락 0건

처리 시간, 누락, 조치 승인을 분기 보고

2차년 자동조치 개방

전건 감사

승인을, 오심을 기준 넘은 시나리오만 개별 심의 승격

3. 선행 추진 실적

설계

설계 문서 31종

시스템설계서, 로드맵, Tool 카탈로그, 조사규칙

구현

조사 코어 스켈레톤 실행

검증기 5척 가동, prod 백엔드 4종 연결

평가

회귀 러너 + recall

실측 recall@10 0.500, 골든 4건, 색인 50건

데이터

사고 DB, 색인 구축

원장 테이블, 문서 파싱 색인, 이미지 갤러리

자원

GPU 수요 등록 완료

1차년 학습 및 추론 물량을 인프라 수요에 반영

검증 게이트

3Q 그림자 운영 조치 미실행, 담당 판정을 정답으로 일치를 기준선과 4h 가정 실측

→

4Q 무인 접수 2주 연속 누락 0건, 처리 시간과 조치 승인을 분기 보고

→

2차년 자동조치 승인을과 오탐을 기준 통과 시나리오만 개별 심의로 승격, 전건 사후 감사

성과 수치는 Shadow 운영에서 확정한다. 일치를, recall@10, 건당 처리 시간, 반려율을 회귀 Gate로 관리하고 기존 미달 버전은 배포하지 않는다.