

AX Award 지원서

I. 개요

지원부문	제조 AX 부문		
팀 / 그룹	제조기술센터 품질기술그룹	대표자	홍길동
제목	완전한 품질 AI Agent Orchestration 구축 — 감지부터 판단·조치·자동조치까지 스스로 수행하는 살아있는 품질 관리 시스템		
적용시점	2026-09-01 ~ 2028-08-31 (24개월) — 1차년 구축·검증 / 2차년 확산·자동화		
형전개 범위	1차년 포토 1개 공정 → 2차년 etch·CMP 3개 공정 → 품질·공정 엔지니어 약 1,000명 · DRAM·NAND 전 제품군. 확산 표준안으로 타 조직 이관.		

II. Process

II. Process

문제 정의

1. 새벽 이상 1건의 실제 동선 — 검출은 2초, 그러나 원인을 아는 사람이 없었다

이 판정 하나에 필요한 지식은 셋이다 — ① 이 item의 trend 이력 ② 직전 변경점(PM·레시피·자재) ③ 같은 조합에서 과거에 났던 불량.

새벽·주말 취약시간에는 ②③을 아는 사람이 현장에 없다. 그래서 단순 파라미터 보정으로 trend만 스펙 안으로 되돌리고 넘어간다.

숫자는 정상처럼 보이지만 원인은 그대로 남는다 — 같은 불량이 재발·확산된 뒤에야 주간에 드러난다. 이것이 매번 반복되는 사고의 전형이다.

2. 동선 안에 반복되는 구조 결함 4 — 측정 가능한 문제로 적는다

3. 기존 대안 검토 — 셋은 기각, 하나는 트리거로 편입

사내 LLM API	기각	질문을 넣으면 일반 지식으로 답할 뿐 — SPC·MES 조회, Map·SEM 판독, 변경점 대조를 할 손 이 없다. 물어보는 사람의 지식만큼만 나온다
사내 공용 RAG	기각	문서를 통째 벡터로 넣는 구조 — 설비 ID·공정 약어가 임베딩에서 뭉개져 검색 정확도가 낮고, 반도체 사전·용어 병기·메타 필터 같은 손잡이가 없다
BI·대시보드	기각	보는 화면만 늘어난다 — 대조·판단·조치는 여전히 사람 공수로 남는다
규칙 기반 SPC 알람	편입	spec·rule 기반이라 정해둔 임계만 잡는다 — 완만한 drift·복합 이상은 통과. 상시 감지는 Trend Agent가 대신하고, SPC 알람은 무인 기동 트리거로만 쓴다

4h

/ 근무 8h

근무의 절반이 판정 조사·대조에 쓰인다 [가정
— 로그로 실측 대체]

× 약 1,000명

만 명 규모 제조 조직의 품질·공정 엔지니어 전원의 매일 업무

진성 놓침

가성 Hold

불량 유출

라인 정지

후공정·클래임 증폭

수율-TAT 직접 손실

어느 쪽으로도 기울일 수 없다

오판 비용이 양쪽 다 크다. 그래서 판정은 늦고 보수적이 된다 — 사람이 시간을 더 쓰는 이유가 게으름이 아니라 비용 구조다. 시스템도 같은 함정을 밟는다: 오탐이 잦으면 현업이 알림을 꺼 사장된다 — 알림 신뢰를 관리 지표로 둔다.

5. 왜 지금인가

① 데이터 자산 임계 도달 — 사고 이력 RDB·EngrNote·문서저장소 ·SPC/MES/YMS/EES/QMS가 학습·검색 자산으로 쓸 양에 도달

② 공개 모델 성숙 — 사내 반입 가능한 모델이 판단·판독 요구 수준에 도달

③ 검증 체계 완비 — 회귀 러너·recall 실측까지 서 있다. 백지 출발이 아니다

지금 시작

1. E2E 전체 대체 — 6단계 업무가 무엇을 받아 무엇을 내는지까지 설계했다

인지

조사

판정

조치 결정

보고

이력 등록

사람

≈ 14h

수분

수분

반납

수분

수분

수분

adapter

investigator

judgment

action

answer

register

Q-Agent

수조

다섯 정거장이 통째로 내려온다 — 자율 tool calling, 합산 수조

adapter

알람 JSON·질문 → 표준 사건 카드

investigator

도구 5~15회 → 증거 묶음

judgment

검증 5척 통과분만 판정서로

action

조치안+등급

answer

근거 3종 인용 보고서

register

사람 승인·수정·반려 → 확정분이 코퍼스·재학습 라벨

2. 조치 권한 승격 구조 — 무엇을 실행하고, 누가 확정하고, 무엇을 넘어야 올라가나

1차년 즉시 개방 — 통보성 (되돌릴 것 없음)

L1 알림

이상 통보 — 야간에도 교대자에게

L2 소견 공유

유형·유사 사고 소견 첨부

L3 점검 권고

조치안 제시 — 실행은 현업 판단

확정 주체: 시스템 발신 · 사람은 수신·채택

→

채택·반려 이력 축적

사람 승인 후 실행

L4 lot Hold

승인 전 미실행 — 승인·반려가 기록

확정 주체: 담당 엔지니어

→

승인율·오탐률 기준 통과

2차년 개별 심의 승격

L5 자동조치

되돌릴 수 있는 조치만 · 전건 사후 리뷰

설비 제어성 조치는 2차년에도 승인 대상

3. 시작·중간·끝이 모두 바뀐다 — 끝이 다음 시작을 키운다

시작 — 사람이 아니다

Chat 질문 · 무인 감지 이벤트

→

중간 — 코어 하나

조사→판정→조치안 · 검증 통과분만

→

끝 — 자산이 된다

승인·등록 확정분이 코퍼스·라벨로

4. 현업 활용·확산 — 코어는 그대로, 조사규칙과 색인만 늘린다

● 확산 표준안 = 조사 코어 + 공정별 조사규칙 템플릿 + 골든셋 구축 절차. 2차년 통과 조건 — 코어 변경 0 · 반려율 상승 없음. 공정이 3개로 늘어도 추가 자원을 요청하지 않는다.

● 현업 몫 — 조사규칙 초안(3Q·공정 담당) · 조치 승인·반려(상시) · 골든셋 확정(분기). 노하우가 등록될수록 시스템이 그 팀에 맞게 자란다. 오탐 남발은 이벤트 그룹핑·수신자 피드백으로 조정(조치는 정보계 경유 전용 — 1Q 통과 조건).

1차년 · 구축·검증

3Q 그림자 → Chat 파일럿

포토 공정 담당 엔지니어

1차년 · 구축·검증

4Q 무인 접수 개시

야간·주말 누락 0건 · 채택률 집계

2차년 · 확산·자동화

5·6Q etch·CMP 확산

3개 공정 — 코어 변경 0

2차년 · 확산·자동화

8Q 약 1,000명 전면

표준안으로 자원 증설 없이 이관


문제 정의 (계속)

Process 재설계

- 2 -

품질 AI Agent Orchestration — 전체 동작 한 장

감지·질문에서 조치 실행·이력 등록·제학습까지, 한 코어로 담는다



1. 왜 Agent Orchestration 인가 — 규칙·분류기·단일 LLM이 각각 실패하는 지점

조사 순서를 미리 못 정한다 — 다음에 볼 데이터가 직전 결과에 따라 달라진다. 고정 파이프라인은 분기가 폭발한다.

정답이 라벨이 아니라 근거 있는 설명이다 — 분류기는 Hold/Release만 짚는다. 판정은 결론보다 근거가 감사 대상이다.

이중 모달이 한 사안에 섞인다 — 시계열·이미지·문서·정형 DB. 각 모달은 전용 모델이 정확하고, 종합은 LLM이 한다.

임계 기반으로 안 걸린다 — 임계 아래로 완만히 흐르는 shift는 규칙 알람이 못 잡는다. 변화점 검정이 필요하다.

2. 아키텍처 — Router가 결과를 보고 다음 도구를 정하는 tool calling 루프



기술적
해결
방안


3. 무엇이 새로운가 — 이 설계의 기술적 신규성 셋

01 검증 게이트 오케스트레이션
채택 조건이 "그럴듯함"이 아니라 코드 관문 통과다. 탈락은 판단 불가로 강등 — 침묵 실패가 구조적으로 없다.

02 2단 확정 검색
유사도는 후보 생성까지만 — 확정은 메타·경로 키의 RDB 조회. 벡터의 모호함이 인용·판정에 유입될 수 없다.

03 업무가 곧 라벨링인 페루프
승인·수정·반려가 그대로 학습 라벨 — 별도 라벨링 조직 없이 SFT·선호학습(DPO·KTO)·검색기 파인튜닝이 월 4회 된다.

4. 전문 모델의 밑단 — 이미지·Trend 두 갈래 모두 자체 개발로 이미 들고 있다



5. 실행 트레이스 두 갈래 — 데이터가 실제로 이렇게 흐른다 (호출 → 틀 내부 동작 → 반환값 ↔ 프롬프트 적재)

A · 불량 이미지(EDS-SEM) 진입 — 유사도 → 경로·meta → 문서

- 입력** eds_0731.png 첨부 — "이 불량 뭐지? 과거 유사 사고 있었나?"
스택 = [system · 도구 스키마 10종 · 판정서 스키마]
- 1 Router** "이미지가 있으니 유사도부터" →
analyze_defect_image(img)
틀 내부 — contrastive 384→128-d L2 → 사고 이미지 스토리지 갤러리 코
사인 top-10 → 임계 0.82 컷
↔ {top1:edge_ring, sim:0.93, incident:PHOD01-2847,
path:/rpt/2847.pptx}
스택 += 판독 라벨 · 이미지 경로 · meta 키
- 2 Router** "경로·meta 나왔으니 그 키로 문서" →
search_engr_notes(meta)
틀 내부 — ① meta 조회로 참조 문서 먼저 선별 ② 그 안에서만 tsvector ||
halfvec ③ RRF 융합 ④ 리랭크 top-20
스택 += 참조문서 3건 · 인용 원문 문장
- 3 Router** "원인·대책 원본 필요" (필요시) →
get_incident("PHOD01-2847")
↔ {규모:lot 3 · 피해:yield ~1.2% · 원인:대책·잘못된 점}
스택 += 사고 원장 행 — 담당 엔지니어가 직접 쓴 확정 필드
- 4 병렬 Trend · 사내 DB · Eng'r Inform** 동시 호출 (서로 독립이라 병렬)
스택 += Trend 반환 · 설비 이력 — 과거 원인이 이번 설비에서 재현됨을 교차
확인
- 종료** 근거 3중 확보 · 미결 질문 없음 → 도구 루프 종료, Q/A 역할로 인계

B · 사고 문의·알람 진입 — 원장 → meta 선별 → 문서

- 입력** SPC 알람 {param:CD, lot:L42, Δ:+0.8nm, t:02:14} 또는 "이 사고 어떻게 됐었나" 질문
- 1 Router** "사고 건이므로 원장이 첫 조회 — 검색이 아니라 조회다" →
search_incidents(drift, PHOD)
틀 내부 — 담당 엔지니어가 손으로 쓴 RDB: 사고명·규모·피해·원인·대책·
조치·잘못된 점. **신뢰 최상이라 여기부터**
↔ {2847: 원인 PM 후 재보정 누락 · 대책 offset -0.4 · yield
~1.2%}
스택 += 사고 원장 행 (확정 사실)
- 2 Router** 사고명·meta로 참조 문서 선별 →
search_engr_notes(meta) — A의 2단계와 동일 경로 (진입만 다르
다)
스택 += 참조문서 · 인용 원문
- 3 Trend Agent** 2-stage — 1단 양·불 게이트, 2단 LLM이 변경점 이력 +
일평균 JSON 판독
↔ {변화점 02:14, drift행, 6/28 PM 연관 의심}
스택 += 변화 시점·변화량·연관 작업
- 4 사내 DB Agent** get_interlock_history(SCN-07) ↔ PM 06/28
후 재보정 기록 없음
스택 += 설비 이력 — 가설이 실제 이력과 맞물림
- 종료** 근거 부족 시 최대 3회 재검색, 그래도 모자라면 "확인 불가"를 스택에 적
고 넘긴다

역할별 temperature — 같은 엔진, 다른 온도

Router LLM · T = 0

내는 것 — 도구 이름 + 인자 JSON (문장이
아니다)
온도를 조금만 줘도 72h가 48h로, lot 범위가
다른 값으로 흔들려 같은 사건에 다른 조사 경
로가 나온다 — 감사에서 재현이 안 되면 판정
이 무효다
top_p 1.0 · seed 고정 — 호출 시퀀스
재현

Q/A LLM · T ≈ 0.3

내는 것 — 스택을 읽고 쓴 문장 (판정서 서술)
argmax만 이으면 표현이 굳어 원인이 달라도
서술이 안 걸린다. 0.3은 서술만 풀어주는 쪽
— 수치·사고번호·인용문은 스택에서 복사하
므로 온도가 값을 못 흔든다
top_p 0.9 · 세는 건 검증기 @ 사실 대조
가 잡는다

최종 Q/A 호출에 실제로 들어가는 것 — 4층 스택

- ① 고정층 — system:조사규칙·판정서 스키마 (프릭스 캐시 적중)
- ② 사건층 — 질문 원문 또는 알람 JSON · 첨부 이미지 핸들
- ③ 증거층 — 도구 반환 누적 5~15회: 원장 행 · 참조문서 인용 ·
판독 라벨 · Trend · 설비 이력 ← **사건마다 자라는 층**
- ④ 출력 지시층 — 스택 밖 사실 금지 · 수치는 반환값 그대로
복사 · 근거 3중 · 부족분은 "확인 불가"

↓ Q/A LLM T 0.3 → 판정서 → 검증기 5회

답의 수준은 모델이 아니라 스택이 정한다 — 3단계를 빼면 "과거에 비슷한 게 있었
다"에서 멈추고, 4단계를 빼면 "이번 설비가 그랬는지"를 못 쓴다.

6. 조치안 출력 — 무엇을 얼마나 바꿀지, 한도와 사이드 이펙트까지가 한 세트다

판정서 #Q-1042 · PHOD03 CD drift

신뢰도 High · 근거 3중 · L3 권고

원인 — Scanner SCN-07 Focus 드리프트 (PM 06/28 후 재보정 누락 · 과거
PHOD01-2847 동일 패턴)

조치 — Focus offset -0.4 재보정 권고 || **가드: 1회 변경 한도 $|\Delta| \leq 0.5$ · PM 주기
당 1회 · 한도 초과 입력은 자동 반력**

사이드 이펙트 — 과보정 시 center CD 역방향 shift 위험 → **모니터 lot 2매 선행 확인
후 분류 적용**

근거 인용 — ① Trend {02:14, +0.8nm} ② Map edge_ring 0.92 ③ PHOD01-
2847 보고서 p.14 조치 문장

● **조치가 곧 명령이 아니다** — 파라미터 가드(변경량 상
한·횟수 제한·되돌림 가능성)을 조치 등급표가 강제한다.
"많이 바꾸는" 답은 구조적으로 못 나간다.

● **근거 사실이 실물에 닿는다** — 유사도는 후보만, **확정
은 메타·경로 키로 RDB에서**. 인용은 원문 문장 그대로.

7. Agent를 하나씩 열어줄 때마다 답이 자란다 — 프롬프트에 무엇이 들어가 답이 어떻게 달라지나

(ablation · 같은 사례 실측)

- LLM 단독 ctx: 알람 원문본
 - + Trend Agent {02:14, +0.8nm, drift}
 - + Image Agent {edge_ring, 0.92}
 - + 유사사례 RAG {사고번호·원인·조치 문장}
 - + 설비 이력 Tool {PM·인터락 기록}
 - + 조치 생성 {조치 등급표·가드 한도}
- "02시경부터 CD가 오르는 것으로 보입니다. 계속 재확인을 권장
합니다."
- "02:14에 변화점, +0.8nm drift형입니다. 순간 틈이 아니라 지속
이동 — 계속 오류가 아닙니다."
- "같은 시각 Map이 edge ring 패턴(0.92) — 공간 분포까지 겹칩
니다. Focus 계열 이상이 의심됩니다."
- "PHOD01-2847과 동일 패턴입니다. 당시 원인은 PM 후
Scanner Focus 재보정 누락이었습니다."
- "SCN-07은 06/28 PM 이후 재보정 기록이 없습니다 — 가설
이 설비 이력과 맞물립니다. 원인 확정."
- "Focus offset -0.4 재보정을 권고합니다. 한도 $|\Delta|$
 ≤ 0.5 ·PM 주기당 1회, 모니터 lot 2매 선행 확인."
- 모호 — 시점·근거 없음
- 시점·변화량 확보
- 불량 유형 특정
- 원인 후보 확보
- 교차 검증 완료
- 실행 가능

최종 프롬프트 스택 = system(조사규칙·판정서 스키마) + 사건 카드 + tool 반환 JSON 5~15개 + 인용 원문 발췌 — 이 스택 전체가 판정서 생성의 입력이다. 답의 수
준 차이는 모델이 아니라 **스택에 쌓인 증거의 자이다**.

원장 2 사고 건이면 여기가 1번

search_incidents ·
get_incident

SQL 5 get_spc_trend ·
commonality_analysis ·
get_master_info ·
get_interlock_history ·
search_fab_data

Vision 2

classify_wafer_map ·
analyze_defect_image

RAG 1

search_engr_notes

도구는 조회 전용 — 통계·공통성 분석은 코드가 계산한다. 도구를 하나 빼면 답이 어느 단계로 후퇴하는지가 그대로 보인다.

기술적
해결
방안
(계속)

8. 그럴듯한 오답은 코드가 거른다 — 다섯 관문

①스키마 ②근거 실재 ③사실 대조 ④신뢰도 ⑤공백 금지

판단서 초안

형식 위반 없는 증거 인용 원문에 없는 수치 근거 3개 미만 부족분 미명시

↓ 탈락분은 재생성 — 반복 실패 시 판단 불가로 강등

관문을 지날수록 통로가 좁아진다 — 침묵 실패가 없다. 모르는 것은 모른다고 적는 것까지가 관문이고, 반복 실패는 사람에게 넘어간다.

9. Agentic RAG 설계 — 사람이 정리한 사고 DB가 항상 먼저고, 확정은 키 조희다

트랙 ① 텍스트

① 사고 원장 RDB — 무 조건 1번
담당 엔지니어가 손으로 쓴 원장 — 규모·피해·원인·대책·잘못된 점까지. 신뢰 최상

② 사고 고유 번호
이후 모든 검색의 필터 키

③ meta 조회로 문서 선별 → 범위 내 검색
사고명·번호·공정·설비·기간 meta로 후보를 좁힌 뒤, 그 안에서만 tsvector(BM25) || halfvec(임베딩)

④ RRF 융합
→ cross-encoder 리랭크 top-20

⑤ 부족 시 재검색
질의 재작성 후 ③으로 루프

트랙 ② 이미지

① 신규 불량 이미지
현장 SEM-Failbit 첨부

② contrastive 임베딩
128-d L2 좌표화

③ 갤러리 코사인 top-10
유사 사고 이미지 지정

④ 그 이미지의 경로·메타 키
사고번호·클래스 확보

⑤ 경로·meta로 RAG DB 조회
사고 DB는 필요시

유사도는 후보만 — 확정은 언제나 키 조회. 합류점은 사고번호가 아니라 Router에 쌓이는 증거 스택이다 — 최종 인용은 원문 문장 그대로. Router에 tool 반환이 계속 쌓이고 — 필요시 Trend-Image-사내 DB-EngrNote agent까지 — 더 부를 도구가 없을 때 Q/A LLM이 답을 달는다.

이 파이프는 세 갈래로 배운다 — 승인·수정·반려가 그대로 라벨 (월 4회 · 골든넷 회귀 통과분만 배포)

검색기 파인튜닝

확정 판정-문서 쌍으로 임베딩·리랭크 튜닝 · 전: "ACI 급등" 질의에 일반 세정 문서가 상위 → 후: 세정 후 계속 문서가 top-1 — 현장 용어를 배운다

SFT 지시학습

확정 판단서를 지시-응답 쌍으로 · 전: "CD 상승 원인은 다양할 수 있습니다" 서술 → 후: 원인·근거 3종 인용·조치 코드의 판정서 스키마로만 답한다

선호학습 DPO-KTO

채택=선호/반려·수정=비선호 쌍(DPO) + 단건 채택·반려 신호(KTO) · 전: 근거 2개로 Hold까지 제안 → 후: 근거 미달이면 스스로 '판단 불가'를 고른다

추후 확장 (2차년 검토) — 지식들 '검색'에서 '읽고 걷는' 구조로

조사규칙 v12

LLM Wiki — 확정 판정·용어·조사규칙을 LLM이 자동 문서화하고 서로 링크한다. 신입도 검색어를 몰라도 어디서 도달하는 살아있는 지식 베이스 — 갱신은 등록 확정분에서 자동.

용어: ACI ↔ 세정 후 계속

사고 2847 요약 ↔ 원문

Graph RAG — 설비-PM-불량-사고-조치를 지식 그래프로 잇는다. "이 설비 PM 뒤 자주 난 불량과 그때 조치는?" 같은 다단(hop) 질의를 그래프 탐색으로 답한다 — 백터 검색이 못 잇는 관계를 걷는다.

10. 지표는 실측으로만 — 임의의 %를 지금 적지 않는다

회귀 기준선 · recall@10 0.500

골든 4건→30건 확장 예정 · 색인 50건 · 회귀 러너 실측

0건으로 관리한다

● 근거 없는 판단 채택 ● 미승인 L2 조치 실행 ● 무인 접수 누락 — 검증기 차단 로그·감사 로그로 센다

선행 프로토타입 실측

26질의 hit@1 1.000 · 하드셋 38질의 0.957 · 군집 품질 AMI 0.956/ARI 0.860 — Qwen3 교체 후 재측정

판정 정당률은 그림자 운영 실측 뒤 확정한다. 일치율(AI 대 엔지니어 판정)·recall@10·처리 시간·반려율이 떨어지면 배포를 막는다.

Ⅲ. 경영효과

200억 원/년

판정 업무 시간 환산 가치 — 확산 완료 후 1,000명 적용 시

57.5배

연간 ROI — 투자 연 347,794,165원 대비

6.3일

투자 회수 — 2개년 총투자 기준 12.7일

[(개선 전 4h ÷ 8h) - (개선 후 2h ÷ 8h)] × 연봉 80,000,000원 × 1,000명 = 연 200억 원

연봉 8,000만 = 사내 산정 기준값 · 인원 감축이 아니라 시간의 환산 가치 · 1차년은 실측 구간이라 효과 미계상 · 4h→2h는 실측 전 가정, 그림자 운영 로그로 대체

2.0h (목표)

2.5h

3.0h

3.5h

57.5배 · 200억

43.1배 · 150억

28.8배 · 100억

14.4배 · 50억

야간 공백 해소 — 야간·주말도 그 자리에서 조사 (착수 시작)

판단 편차 축소 — 같은 현상에 같은 조사 경로 (일치율)

감사 대응력 — 근거 원문·신뢰도·모델 버전이 판정마다 남는다

노하우 자산화 — 조사규칙·EngrNote로 남아 사람에게 안 묶인다

타 조직 이관 — 확산 표준안으로 코어를 그대로 넘긴다

구현

검증기 5척 가동

조사 코어 스켈레톤 실행 · prod 백엔드 4종

평가

recall@10 0.500

골든 4건/색인 50건 · 회귀 러너 실측

선행 프로토타입

군집 품질 AMI 0.956 · ARI 0.860

노이즈 0.52% · 43 class·900 wafer — RAG 전 요소·유사 검색·메타 키 조회 가동

설계

설계 문서 31종

시스템설계서·로드맵·Tool 카탈로그·조사규칙

2Q 그림자 운영

조치 미실행

공정 담당 판정을 정답으로 일치율 기준선·4h 가정 실측

4Q 무인 접수

2주 연속 누락 0건

처리 시간·누락·조치 승인율 분기 보고

2차년 자동조치 개방

전건 감사

승인율·오타율 기준 넘은 시나리오만 개별 심의 승격

- 5 -